


Parte 1 Bases de datos y datasets en Orange

Actividad 1:


Distributions

Tue Sep 15 26, 20:45:24



Distribution of 'quality'

3.1 Actividad 1 - Cantidad de vinos por nivel de calidad



Actividad 3:

SQL Table:

SQL Table - Orange

Server

PostgreSQL

localhost

curso_analitica

postgres

.....

Connect

Data Selection

Table:

Select a table

Custom SQL:

SELECT quality, COUNT(*) AS num_vinos, ROUND(AVG(ph), 2) AS ph_promedio FROM vinos GROUP BY quality ORDER BY quality;

Materialize to table

Execute

Auto-discover categorical variables

6

Data Table

Data Table (2) - Orange

Info

6 instances (no missing data)
3 features
No target variable.
No meta attributes.

Variables

Show variable labels (if present)

Visualize numeric values

Color by instance classes

Selection

Clear Selection

Select full rows

Restore Original Order


Send Automatically

	quality	num_vinos	ph_promedio
1	3	10	3.4
2	4	53	3.38
3	5	681	3.3
4	6	638	3.32
5	7	199	3.29
6	8	18	3.27

6

6

6



3.3 Actividad 3 - Cantidad de vinos por nivel de calidad SQL

Workflow Parte 1

```
graph LR; File[File] -- Data --> DT[Data Table]; DT -- Data --> Distributions[Distributions]
```

Actividad 1: Dataset en formato CSV - Wine Quality

Comparando con `vinos['quality'].value_counts()` del notebook, los conteos sí coinciden exactamente cuando el Bin width del widget Distributions está en su valor mínimo, ya que en ese ajuste cada barra corresponde a un único valor entero de calidad, igual que las categorías de `value_counts()`. Al aumentar el bin width, Orange agrupa varios valores enteros consecutivos en una sola barra, generando un histograma más suavizado/uniforme que ya no coincide con los conteos exactos por nivel — porque deja de ser un conteo por categoría discreta y pasa a ser un conteo por rango continuo.

```
graph LR; ST[SQL Table] -- Data --> ED[Edit Domain]; ED -- Data --> DT2[Data Table (2)]; ED -- Data --> BP[Bar Plot]
```

Actividad 3 – Base de datos SQL - Wine Quality

El resultado coincide exactamente con la tabla `resumen_sql` del notebook: 10, 53, 681, 638, 199 y 18 vinos para las calidades 3 a 8 respectivamente. Ambos provienen de la misma consulta `GROUP BY quality` sobre la misma base de datos.

```
graph LR; F1[File (1)] -- Data --> DT1[Data Table (1)]; DT1 -- Data --> SP[Scatter Plot]
```


Actividad 2 : Dataset en formato Raw Text - Auto MPG

Sí, se observa la misma tendencia en ambas gráficas: a mayor potencia (caballos de fuerza), menor eficiencia de combustible (mpg). La nube de puntos en Orange reproduce la misma forma descendente que el gráfico de Matplotlib del notebook. Además, el color confirma el patrón: los vehículos con más cilindros (colores cálidos/amarillos en ambos gráficos) se concentran en la zona de alta potencia y baja eficiencia, mientras que los de menos cilindros (colores fríos/azules-morados) se agrupan en baja potencia y alta eficiencia. La relación es consistente entre las dos herramientas.


Parte 2 Tipos de variables y visualización en Orange


Actividad 1:

(a)




(b)





Distribution of 'track_genre'

Actividad 2 - Distributions: Frecuencia de track_genre



Distribution of 'tempo'

Actividad 2 - Distributions: Histograma de tempo

Workflow Parte 2

Actividad 1

(a) No coincide. Orange detectó track_genre como Texto (variable de texto libre / meta), mientras que en el notebook la clasificamos como cualitativa nominal.

Esto ocurre porque el detector automático de Orange no analiza el significado estadístico de la variable, sino simplemente cuántos valores distintos tiene la columna. Cuando una columna de tipo texto supera un umbral de valores únicos, Orange asume que probablemente es texto libre en vez de una categoría manejable, y la deja como "Text" por defecto.

(b) - Tipos de variable: key y mode

Mode sí coincide: Orange la detectó como Categorical feature, que corresponde exactamente a la clasificación cualitativa nominal que hicimos en el notebook (mayor/menor son dos categorías sin orden).

Key no coincide: Orange la detectó como Numeric feature, cuando en realidad también es cualitativa nominal cada valor (0 a 11, o -1) representa una nota musical, sin ninguna jerarquía numérica real entre ellas.

Por qué es importante corregir key a Categorical: si se deja como numérica, cualquier widget (Distributions, Correlations, Scatter Plot, PCA, un modelo de regresión) va a asumir que tiene orden y magnitud reales. Calculará un "promedio de key" sin sentido musical, o una correlación de Pearson asumiendo que key=11 está once unidades lejos de key=0, cuando en la rueda de tonos son notas vecinas. Cambiarla manualmente a Categorical evita estas conclusiones estadísticamente inválidas.

Reflexion Final

Prefiero Orange en escenarios de exploración rápida y comunicación visual: widgets como Distributions o Bar Plot generan gráficos legibles en segundos, sin escribir código, lo cual es valioso para revisar tendencias generales o presentar resultados a alguien no técnico. Sin embargo, note que Orange detecta el tipo de variable de forma heurística (basada en la cantidad de valores distintos), lo que llevó a clasificaciones incorrectas como key (numérica en vez de categórica) que requirieron corrección manual. En Python, con Pandas, uno declara y controla el tipo de dato desde el inicio, evitando ese riesgo. Preferiríamos Python cuando el flujo requiere limpieza de datos complejos o conexión a bases de datos: conectar SQLite fue una sola línea de código con sqlite3, mientras que en Orange tuvimos que instalar y configurar un servidor PostgreSQL.

Actividad 2 - Distributions: track_genre y tempo

Género musical (track_genre): El gráfico de barras de Orange muestra la misma tendencia que el del notebook: los primeros 10 géneros (acoustic, afrobeat, alt-rock, alternative, ambient, anime, black-metal, bluegrass, blues, brazil) coinciden exactamente entre ambas herramientas, cada uno con 1000 canciones. La diferencia visual es que el notebook solo grafica el Top 10, mientras que Orange muestra las 114 categorías completas del dataset.

Tempo: El histograma de Orange reproduce la misma forma que el de Matplotlib: una distribución aproximadamente unimodal, con el pico de mayor frecuencia entre 120 y 130 BPM, cola más larga hacia tempos altos (asimetría positiva) y muy pocas canciones por debajo de 50 BPM o por encima de 200 BPM. La forma general coincide entre ambas herramientas.

