

18/09/2026

Laboratorio de Simulación 2 Implementación en Orange Data Minin

Módulo: 2 Transformación y visualización de datos

Curso: Analítica de Datos (Aprendizaje de máquina)

PRESENTADO POR:

- Marlyn Nathalia Mora Riascos
- Ever Daniel Hernandez Tulcan
- Miguel Angel Estrada Ocampo

PRESENTADO A:

- Diego Fabian Collazos Huertas

Parte 1 Preprocesamiento y transformación en Orange :

1.1 Cargar el dataset y diagnosticar datos faltantes

Solución actividad :



Figura 1: columna de faltantes de Feature Statistics




Figura 2: columnas con datos faltantes en el notebook de python




Figura 3: Comparación de datos faltantes

1.2 Dividir train/test y tratar los datos sin fuga de información

Solución actividad :





Figura 4: Comparación valor imputado en Age y con la mediana que calculo el notebook

1.3 Discretización de la edad y codificación de categorías



Solución actividad :

Equal frequency:

	Survived	Name	Ticket	PassengerId	Pclass	Sex	Age	SibSp	ParCh	Fare	Embarked
1	0	Becker, Master...	230136	184	2	male	< 29.0739	2	1	39.0000	S
2	0	Seward, Mr. Fre...	113794	440	1	male	≥ 29.0739	0	0	26.5000	S
3	0	Graham, Mrs. ...	PC 17582	269	1	female	≥ 29.0739	0	1	153.4625	S
4	0	Futrelle, Mr. Jac...	113803	138	1	male	≥ 29.0739	1	0	53.1000	S
5	0	Buss, Miss. Kate	27040	308	2	female	≥ 29.0739	0	0	13.0000	S
6	0	Danbom, Mrs. E...	347080	424	3	female	< 29.0739	1	1	14.4000	S
7	0	Sinkkonen, Miss...	250648	740	2	female	≥ 29.0739	0	0	13.0000	S
8	0	Longley, Miss. ...	12502	628	1	female	< 29.0739	0	0	77.9583	S
9	0	Burke, Mr. Jens...	365222	144	3	male	< 29.0739	0	0	6.7500	Q
10	0	Bystrom, Mrs. E...	236852	866	2	female	≥ 29.0739	0	0	13.0000	S
11	0	Kilgannon, Mr. ...	36865	779	3	male	≥ 29.0739	0	0	7.7375	Q
12	0	Petroff, Mr. Ne...	348212	878	3	male	< 29.0739	0	0	7.8958	S
13	0	West, Miss. Con...	C.A. 34451	59	2	female	< 29.0739	1	2	27.7500	S
14	0	Skoog, Miss. M...	347088	643	3	female	< 29.0739	3	2	27.9000	S
15	0	Kelly, Mr. James	363582	697	3	male	≥ 29.0739	0	0	8.0500	S
16	0	Isham, Miss. An...	PC 17595	178	1	female	≥ 29.0739	0	0	28.7125	C
17	0	Sandstrom, Mrs...	PP 9549	395	3	female	< 29.0739	0	2	16.7000	S
18	0	Herman, Mrs. S...	230845	755	2	female	≥ 29.0739	1	2	65.0000	S
19	0	Bacini, Miss. Eu...	2696	645	3	female	< 29.0739	2	1	18.2583	C
20	0	Lewens, Mr. Ra...	345781	771	3	male	< 29.0739	0	0	9.5000	S
21	0	Frolicher, Miss...	13568	540	1	female	< 29.0739	0	2	48.5000	C
22	0	Hippach, Mrs. L...	111361	524	1	female	≥ 29.0739	0	1	57.9792	C
23	0	Allen, Miss. Elis...	24160	731	1	female	< 29.0739	0	0	211.3375	S
24	0	Shelley, Mrs. Will...	230433	881	2	female	< 29.0739	0	1	26.0000	S
25	0	Dentcheff, Mr. ...	348203	795	3	male	< 29.0739	0	0	7.8958	S
26	0	Rolsson, Mrs. Ni...	349909	568	3	female	< 29.0739	0	4	21.0750	S
27	0	Richards, Master...	29106	408	2	male	< 29.0739	1	1	18.7500	S
28	0	Reynolds, Mr. E...	230434	444	2	female	< 29.0739	0	0	13.0000	S
29	0	Skoog, Master. ...	347088	64	3	male	< 29.0739	3	2	27.9000	S
30	0	Devaney, Mr. W...	PC 17361	545	1	male	≥ 29.0739	1	0	196.4750	C

Frecuencia uniforme (Equal frequency): Divide la edad en la mediana (~29.07 años), garantizando que quede la misma cantidad de pasajeros en cada grupo.

Equal width:

	Survived	Name	Ticket	Pclass	Sex	Age	Fare	Embarked
1	1	Becker, Master. ...	230136	< 2.5	male	< 37.21	10.48125 - 52.2...	S
2	1	Seward, Mr. Fre...	113794	< 2.5	male	< 37.21	10.48125 - 52.2...	S
3	1	Graham, Mrs. ...	PC 17582	< 2.5	female	≥ 37.21	≥ 52.2771	S
4	0	Futrelle, Mr. Jac...	113803	< 2.5	male	< 37.21	≥ 52.2771	S
5	1	Buss, Miss. Kate	27849	< 2.5	female	< 37.21	10.48125 - 52.2...	S
6	0	Danbom, Mrs. E...	347080	≥ 2.5	female	< 37.21	10.48125 - 52.2...	S
7	1	Sinkkonen, Mis...	250648	< 2.5	female	< 37.21	10.48125 - 52.2...	S
8	1	Longley, Miss. ...	13502	< 2.5	female	< 37.21	≥ 52.2771	S
9	0	Burke, Mr. Jere...	365222	≥ 2.5	male	< 37.21	< 10.48125	Q
10	1	Bystrom, Mrs. (...)	236852	< 2.5	female	≥ 37.21	10.48125 - 52.2...	S
11	0	Kilgannon, Mr. ...	36865	≥ 2.5	male	< 37.21	< 10.48125	Q
12	0	Petroff, Mr. Ne...	348212	≥ 2.5	male	< 37.21	< 10.48125	S
13	1	West, Miss. Cor...	C.A. 34651	< 2.5	female	< 37.21	10.48125 - 52.2...	S
14	0	Skoog, Miss. M...	347088	≥ 2.5	female	< 37.21	10.48125 - 52.2...	S
15	0	Keily, Mr. James	363592	≥ 2.5	male	≥ 37.21	< 10.48125	S
16	0	Isham, Miss. An...	PC 17595	< 2.5	female	≥ 37.21	10.48125 - 52.2...	C
17	1	Sandstrom, Mrs...	PP 9549	≥ 2.5	female	< 37.21	10.48125 - 52.2...	S
18	1	Herman, Mrs. S...	220845	< 2.5	female	≥ 37.21	≥ 52.2771	S
19	1	Baclini, Miss. E...	2666	≥ 2.5	female	< 37.21	10.48125 - 52.2...	C
20	0	Lievens, Mr. Re...	345781	≥ 2.5	male	< 37.21	< 10.48125	S
21	1	Frolicher, Miss. ...	13568	< 2.5	female	< 37.21	10.48125 - 52.2...	C
22	1	Hippach, Mrs. L...	111361	< 2.5	female	≥ 37.21	≥ 52.2771	C
23	1	Allen, Miss. Elis...	24160	< 2.5	female	< 37.21	≥ 52.2771	S
24	1	Shelley, Mrs. Wi...	230433	< 2.5	female	< 37.21	10.48125 - 52.2...	S
25	0	Dantcheff, Mr. ...	349203	≥ 2.5	male	< 37.21	< 10.48125	S
26	0	Palsson, Mrs. Ni...	349909	≥ 2.5	female	< 37.21	10.48125 - 52.2...	S
27	1	Richards, Maste...	29106	< 2.5	male	< 37.21	10.48125 - 52.2...	S
28	1	Reynaldo, Ms. E...	230434	< 2.5	female	< 37.21	10.48125 - 52.2...	S
29	0	Skoog, Master. ...	347088	≥ 2.5	male	< 37.21	10.48125 - 52.2...	S
30	0	Douglas, Mr. W...	PC 17761	< 2.5	male	≥ 37.21	≥ 52.2771	C
31	1	Carter, Mr. Willi...	113760	< 2.5	male	< 37.21	≥ 52.2771	S
32	0	Webber, Mr. Ja...	SOTON/OQ 31...	≥ 2.5	male	< 37.21	< 10.48125	S
33	0	Ilmakangas, Mis...	STON/O2. 3101...	≥ 2.5	female	< 37.21	< 10.48125	S
34	0	Yousif, Mr. Wazli	2647	≥ 2.5	male	< 37.21	< 10.48125	C
35	0	Milling, Mr. Jac...	234360	< 2.5	male	≥ 37.21	10.48125 - 52.2...	S


Ancho uniforme (*Equal width*): Corta la edad según el rango numérico (~37.21 años), sin importar cuántos datos caigan de cada lado.

Emtreepy-MDL

	Survived	Name	Ticket	PassengerId	Class	Sex	Age	SibSp	Parth	Fare	Embarked
1	0	Becker, Master...	230136	104	2	male	< 29.0739	2	1	39.0000	S
2	0	Seward, Mr. Fre...	113794	440	1	male	> 29.0739	0	0	26.5500	S
3	0	Graham, Mrs. ...	PC 17562	269	1	female	> 29.0739	0	1	153.4625	S
4	0	Futrelle, Mr. Jac...	113803	130	1	male	> 29.0739	1	0	53.1000	S
5	0	Boss, Miss. Kate	27949	300	2	female	> 29.0739	0	0	13.0000	S
6	0	Carlson, Mrs. E...	347080	404	3	female	< 29.0739	1	1	14.4000	S
7	0	Serkkunen, Mrs...	250640	740	2	female	> 29.0739	0	0	13.0000	S
8	0	Longley, Miss. ...	113502	620	1	female	< 29.0739	0	0	77.9583	S
9	0	Burke, Mr. Jere...	365222	144	3	male	< 29.0739	0	0	6.7500	Q
10	0	Bystrom, Mrs. L...	234052	866	2	female	> 29.0739	0	0	13.0000	S
11	0	Kilgannon, Mr...	36865	779	3	male	> 29.0739	0	0	7.7375	Q
12	0	Petroff, Mr. Na...	348212	870	3	male	< 29.0739	0	0	7.8958	S
13	0	West, Miss. Con...	C.A. 34051	59	2	female	< 29.0739	1	2	27.7500	S
14	0	Skog, Miss. M...	347088	643	3	female	< 29.0739	3	2	27.9000	S
15	0	Kelly, Mr. James	362592	697	3	male	> 29.0739	0	0	8.0500	S
16	0	Wheam, Miss. An...	PC 17595	170	1	female	> 29.0739	0	0	28.7125	C
17	0	Sandstrom, Mrs...	PP 3540	395	3	female	< 29.0739	0	2	16.7000	S
18	0	Herman, Mrs. S...	220645	755	2	female	> 29.0739	1	2	65.0000	S
19	0	Bachin, Miss. Eu...	2666	645	3	female	> 29.0739	2	1	19.2583	C
20	0	Livers, Mr. Re...	345781	771	3	male	< 29.0739	0	0	9.5000	S
21	0	Frolicher, Miss...	113568	540	1	female	< 29.0739	0	2	49.5000	C
22	0	Hippach, Mrs. L...	111361	524	1	female	> 29.0739	0	1	57.8750	C
23	0	Allen, Miss. Elie...	24780	731	1	female	< 29.0739	0	0	211.3375	S
24	0	Shelley, Mrs. W...	230423	801	2	female	< 29.0739	0	1	26.0000	S
25	0	Davicheff, Mr...	348203	795	3	male	< 29.0739	0	0	7.8958	S
26	0	Pattison, Mrs. N...	349909	560	3	female	< 29.0739	0	4	21.0750	S
27	0	Richards, Master...	29106	400	2	male	< 29.0739	1	1	18.7500	S
28	0	Reynolds, Mr. E...	230434	444	2	female	< 29.0739	0	0	13.0000	S
29	0	Skog, Master...	347080	64	3	male	< 29.0739	3	2	27.9000	S
30	0	Thomson, Mr. W...	PC 17562	545	1	male	> 29.0739	1	0	106.4250	C


Entropía-MDL (*Entropy-MDL*): Evalúa la relación directa con la variable objetivo (Survived). Al aplicar la penalización por complejidad (MDL), Orange determina que la edad en general no aporta suficiente ganancia de información para justificar una regla, descartando la columna o unificándola.

Resultado en Python: La búsqueda supervisada por entropía (árbol de decisión de profundidad 1) halló un umbral óptimo entre 5.0 y 6.5 años, lo que evidencia la regla histórica de "mujeres y niños primero".



Resultado en Orange: El algoritmo Entropy-MDL aplica una penalización por complejidad (MDL). Al evaluar la ganancia de información, determina que no es suficiente para justificar la creación de un corte supervisado, manteniendo la edad en un único intervalo.

Comparación: Python fuerza a encontrar el mejor corte posible, mientras que Orange evalúa si el corte es estadísticamente relevante según la penalización MDL antes de aplicarlo.



One-hot encoding (One-hot encoding / One feature per value): Genera 3 columnas (Embarked=C, Embarked=Q, Embarked=S). Reproduce exactamente el resultado de `pd.get_dummies()` en Python.
Codificación Dummy (First value as base): Genera 2 columnas (Embarked=Q, Embarked=S), omitiendo la primera categoría como nivel de referencia para prevenir la multicolinealidad.

Parte 2 Visualización en Orange :

2.1 Cargar el dataset y explorar la distribución:




Figura 5. Distribución con bin width igual a 2 (ancho de columna de 2)




Figura 6. Distribución con bin width igual a 10 (ancho de columna de 10)

Column	Distribution	Mean	Mode	Median	Dispersion	Min.	Max.	Missing
Rank		8300.61	1	8300.50	0.58	1	16600	0 (0 %)
NA_Sales		0.2647	0.00	0.08	3.0856	0.00	41.49	0 (0 %)
EU_Sales		0.1467	0.00	0.02	3.4458	0.00	29.02	0 (0 %)
JP_Sales		0.0778	0.00	0.00	3.9763	0.00	10.22	0 (0 %)
Other_Sales		0.0481	0.00	0.01	3.9237	0.00	10.57	0 (0 %)
Global_Sales		0.5374	0.02	0.17	2.8933	0.01	82.74	0 (0 %)
Platform			DS		2.79			0 (0 %)
Genre			Action		2.36			0 (0 %)

Figura 7. Statistics (información estadística de las variables)

Al comparar el histograma obtenido en el widget **Distributions** de Orange con el histograma del notebook, se observa un comportamiento similar: la distribución de **Global Sales** presenta una gran concentración de videojuegos con ventas bajas y una cola larga hacia la derecha, correspondiente a pocos videojuegos con ventas considerablemente mayores. Esta cola se aprecia mejor utilizando un **Bin Width pequeño**, ya que permite observar con mayor detalle la distribución de los datos.

En **General Statistics**, Orange obtiene una media de **0,5374** y una mediana de **0,17**; valores que coinciden aproximadamente con los calculados en el notebook, donde se obtuvo una media de $\approx 0,54$ y una mediana de $\approx 0,17$. Orange no muestra directamente el valor numérico de la **asimetría (skewness)** en este widget, pero esta se evidencia gráficamente en **Distributions** mediante la cola larga hacia la derecha, indicando una **asimetría positiva y elevada**.

Que la media sea mucho mayor que la mediana significa que **unos pocos videojuegos con ventas extremadamente altas elevan la media**, mientras que la mayoría de los videojuegos tienen ventas considerablemente menores.

2.2 Diagrama de caja, valores atípicos y variables categóricas:




Figura 8. Box plot para el dataset (con respecto a global sales).




Figura 9. Bar plot para el dataset (por género).

Análisis del Diagrama de Caja (Global_Sales)

Al analizar la variable de ventas globales mediante el diagrama de caja en Orange, se observa un comportamiento coherente con el modelo desarrollado en el *notebook*.

- **Comparación de Valores Atípicos:** El *notebook* identifica de forma explícita **1827 juegos atípicos**, lo que representa el **11.2%** del total de observaciones, utilizando el límite superior basado en la regla del rango intercuartílico. Por su parte, el widget **Box Plot** de Orange aplica internamente esta misma lógica matemática, graficando una concentración masiva de puntos extremos a la derecha de la distribución. Esto valida que ambos entornos detectan la misma proporción de valores atípicos, reflejando el sesgo positivo del mercado de videojuegos donde una minoría de títulos acumula ventas extraordinarias.

Análisis del Gráfico de Barras (Género de Videojuegos)

Para estudiar la variable categórica *genre*, se configuró el widget **Bar Plot** conectándolo a la fuente de datos.

- **Comparación del Género Más Frecuente:** El análisis previo en el *notebook* determina que el género predominante es **Action**, con un registro de **3253 juegos**. Al verificar la visualización generada en Orange, los resultados **coinciden plenamente**, situando a

action en la primera posición con la barra de mayor altura. Esto confirma la consistencia en el procesamiento y conteo de las categorías entre ambas herramientas de análisis.

2.3 Relaciones entre variables y serie temporal :




Figura 10. Scatter plot.



Figura 11. Correlations.




Figura 12. Bar plot (ventas por año)

1. Análisis de Relación entre Ventas (NA vs. EU)

- Dirección y forma de la relación:** Al analizar el diagrama de dispersión (*Scatter Plot*) entre las ventas de Norteamérica (**NA_Sales**) y Europa (**EU_Sales**), se observa una tendencia ascendente. Los datos se concentran densamente en la región inferior izquierda (debido a la gran cantidad de títulos con volúmenes de venta moderados o bajos) y se extienden de manera diagonal hacia la esquina superior derecha. Esto evidencia una **relación lineal directa y positiva**: a mayor volumen de ventas en el mercado norteamericano, mayor tiende a ser también el consumo y las ventas en el mercado europeo.
- Comparación con el widget Correlations:** El coeficiente de correlación arrojado por Orange entre ambas variables es de **0.768** (aproximadamente **0.77**), lo cual coincide de manera exacta con el valor obtenido en el *notebook* de Google Colab. Esta cifra confirma estadísticamente una **correlación fuerte y positiva** entre ambas regiones.

2. Análisis de Ventas Globales por Año y Solución de Visualización Temporal

- **Año de mayores ventas:** Al examinar la evolución temporal de las ventas globales, se confirma visualmente que **el año 2008** registra el pico máximo histórico de todo el conjunto de datos (superando las 650 millones de copias), lo cual valida y coincide plenamente con el resultado de 2008 reportado en el *notebook* original.

Justificación técnica del uso del Bar Plot en lugar del Line Plot:

Durante el desarrollo del ejercicio en Orange, se intentó utilizar el widget *Line Plot* para representar la serie temporal agrupada por año. Sin embargo, el lienzo se mostraba completamente en blanco debido a una limitación técnica nativa de la herramienta: el campo **Year** venía tipificado originalmente como una variable de texto (*String*) desde el archivo de datos.

El widget *Line Plot* en Orange está diseñado exclusivamente para interpretar ejes X numéricos continuos y se bloquea cuando intenta trazar líneas temporales sobre categorías de texto plano. Para cumplir estrictamente con los objetivos del análisis temporal sin alterar la estructura original del archivo de entrada (*File*), se sustituyó el widget por un **Bar Plot** configurando la categoría en **Year** y la altura en la suma de **Global_Sales**. Esto permitió renderizar correctamente la distribución cronológica completa de las ventas, superando la restricción técnica del software de manera práctica y visualmente precisa.

Reflexión final :

REFLEXION FINAL :

Entender la división de los datos (train/test) y prevenir la mezcla de información resultó mucho más claro gracias al enfoque visual de Orange. Observar la separación de los flujos en el Data Sampler facilita la asimilación del concepto, a diferencia de las funciones abstractas de Python. Asimismo, la discretización y codificación de variables fue un proceso rápido e intuitivo. Los widgets Discretize y Continuize nos permitieron evaluar diferentes opciones con unos pocos clics, obteniendo resultados inmediatos sin necesidad de programar.