

	Column	Distribution	Mean	Mode	Median	Dispersion	Min.	Max.	Missing
N	PassengerId		446	1	446	0.58	1	891	0 (0 %)
N	Pclass		2.31	3	3	0.36	1	3	0 (0 %)
N	Age		29.6991		28.00	0.4888	0.42	80.00	177 (20 %)
N	SibSp		0.52	0	0	2.11	0	8	0 (0 %)
N	Parch		0.38	0	0	2.11	0	6	0 (0 %)
N	Fare		32.204208	8.0500	14.4542	1.542206	0.00	512.3292	0 (0 %)
C	Sex			male		0.649			0 (0 %)
C	Embarked			S		0.76			2 (0 %)
C	Cabin					4.9			687 (77 %)
C	Survived			0		0.666			0 (0 %)

Los porcentajes de datos faltantes de cada campo coinciden

Data

Data instances: 178
Features: PassengerId, Pclass, Sex, Age, SibSp, Parch, Fare, Embarked
Meta attributes: Name, Ticket
Target: Survived

Template data

Features: PassengerId, Pclass, Sex, Age, SibSp, Parch, Fare, Embarked
Meta attributes: Name, Ticket
Target: Survived

Transformed data

Data instances: 178
Features: PassengerId, Pclass, Sex, Age, SibSp, Parch, Fare, Embarked
Meta attributes: Name, Ticket
Target: Survived

El dato edad fue imputado con el valor del promedio que es aproximadamente 29.14, mientras que en python se imputó con la mediana de 28.5

Default setting: keep

Variables

PassengerId:
Pclass:
Age (entropy):
SibSp:
Parch:
Fare:

Al discretizar con MDL, se elimina automáticamente la variable "Age", lo que sugiere que el algoritmo considera la variable edad como una variable no informativa.

Categorical variables

Preset: first value as base
Embarked: first value as base

Numeric variables

keep as it is

Unlisted

Any unlisted attributes default to preset option, and unlisted meta attributes and target variables are kept as they are

Tanto al aplicar One-hot como Dummy, se agregan la misma cantidad de columnas que en el script de python, 3 y 2 columnas respectivamente.