UNIVERSIDAD NACIONAL DE COLOMBIA
SEDE MANIZALES

Laboratorio de Simulación 3
Implementación en Orange Data Minin

Módulo: 3 No supervisado

Curso: Analtica de Datos (Aprendizaje de maquina)

PRESENTADO POR:

Marlyn Nathalia Mora Riascos
Ever Daniel Hernandez Tulcan
Miguel Angel Estrada Ocampo

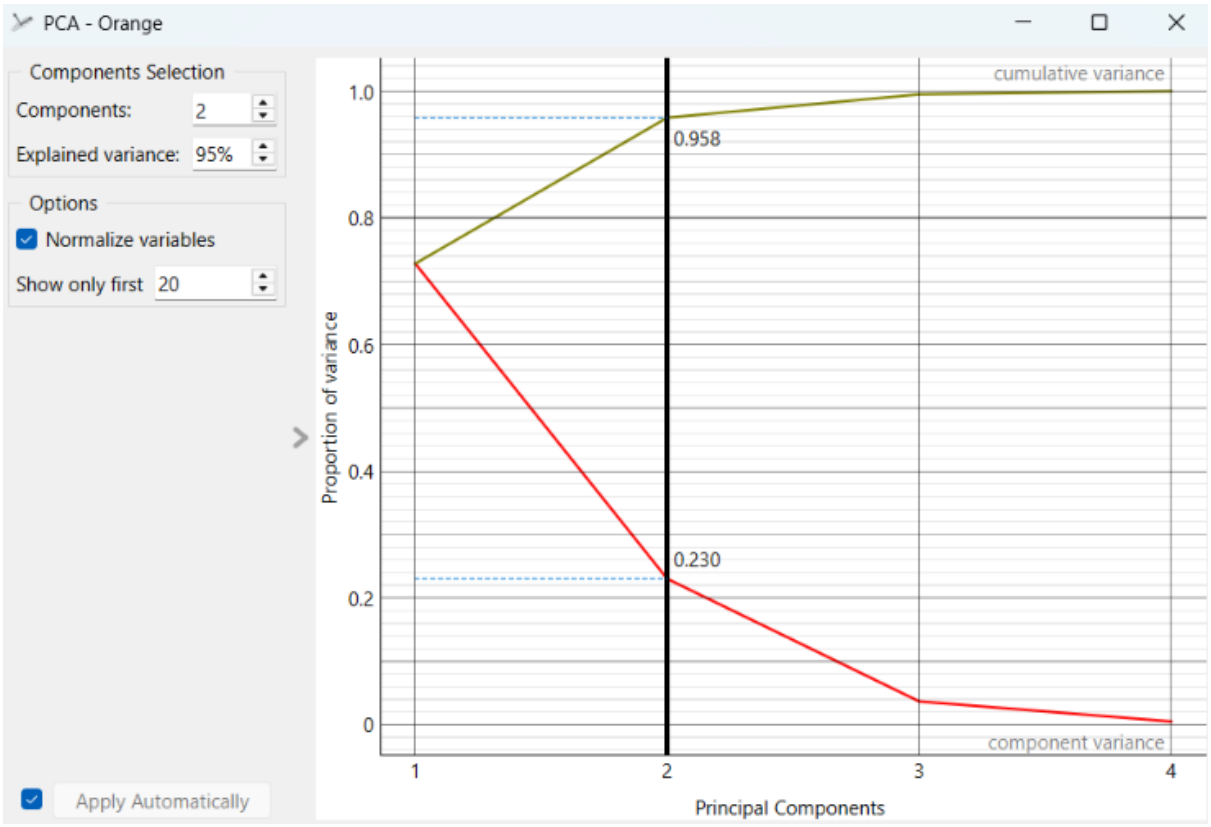
PRESENTADO A:

Diego Fabian Collazos Huertas

UNIVERSIDAD NACIONAL DE COLOMBIA – SEDE MANIZALES

Parte 1)

- **1.2 Aplicar PCA:**

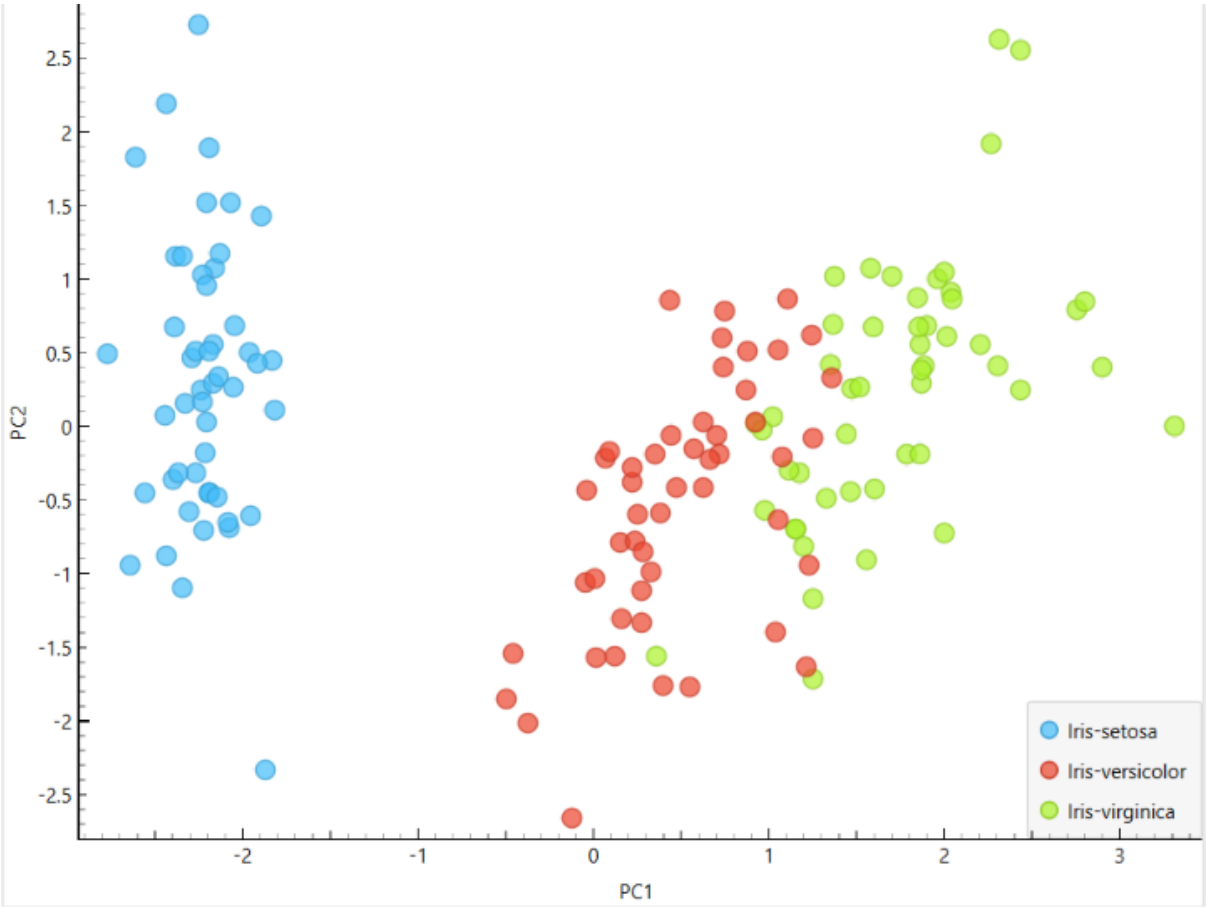


- Resultados en Iris (Orange): Al seleccionar 2 componentes principales en el dataset Iris, el PC1 captura el 72.8% de la varianza y el PC2 el 23.0%, alcanzando una varianza explicada acumulada del 95.8%.

- Comparación con Wine (Google: En Wine, los dos primeros componentes explican únicamente el **55%** de la varianza total PC1~36% y PC2~19%, requiriendo aproximadamente 10 componentes para superar el umbral del 95%.

- Conclusión: En Iris **no se necesitan más componentes**. Debido a la alta correlación entre las 4 variables originales de Iris, la reducción a 2 dimensiones (2D) logra conservar casi la totalidad de la información (95.8%) sin perder detalle relevante, a diferencia de Wine, donde la varianza se encuentra distribuida en una mayor cantidad de dimensiones.

- **1.3 Visualizar en el espacio de componentes:**



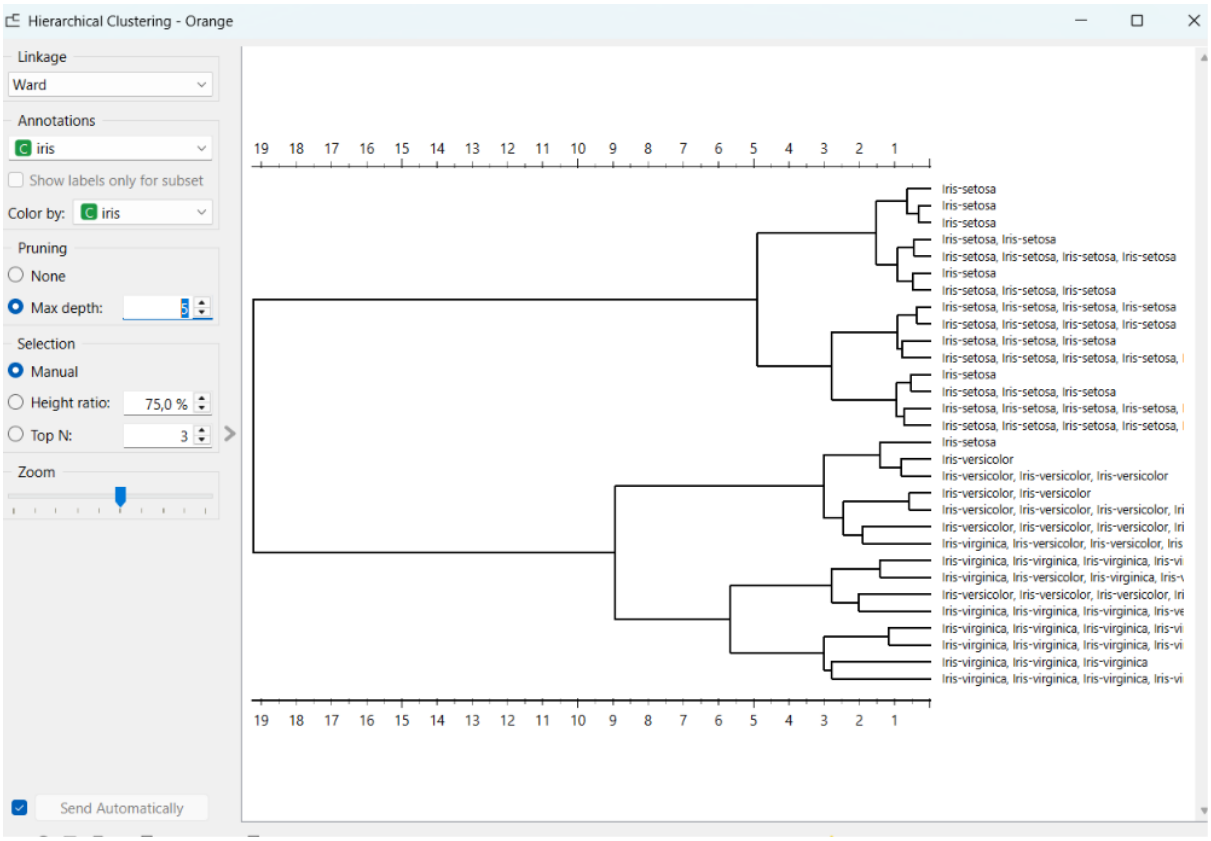
- Observación en Wine: El gráfico muestra tres clases (*class_0*, *class_1* y *class_2*) que se agrupan en regiones separadas en el plano de los dos primeros componentes principales. A pesar de que el PC1 y PC2 en Wine explican cerca del 55% de la varianza total, la proyección es suficiente para aislar visualmente a las tres clases sin usar sus etiquetas.

- Comparación con Iris: En el caso de Iris, la separación visual muestra a *Iris-setosa* completamente aislada, mientras que *Iris-versicolor* e *Iris-virginica* presentan un leve solapamiento en su frontera. Irónicamente, aunque Iris retiene un porcentaje de varianza mucho mayor en 2 componentes (95.8%), sus clases contiguas comparten mayor similitud morfológica que los cultivares de Wine.

- Conclusión: Ambos datasets demuestran el poder del PCA como técnica no supervisada. Sin embargo, se comportan de forma inversa respecto a su varianza y separación: Wine logra separar limpiamente sus tres clases en 2D a pesar de tener una varianza acumulada baja, mientras que Iris concentra casi toda la varianza en dos componentes pero deja un pequeño traslape entre dos de sus especies.

Parte 2)

- **Construir el dendograma con los cuatro criterios de enlace**



El método más balanceado es Ward (varianza mínima), ya que genera particiones simétricas con clústeres de tamaños homogéneos y bien delimitados, evitando el efecto de encadenamiento.

- **Cortar el dendograma en 3 grupos**

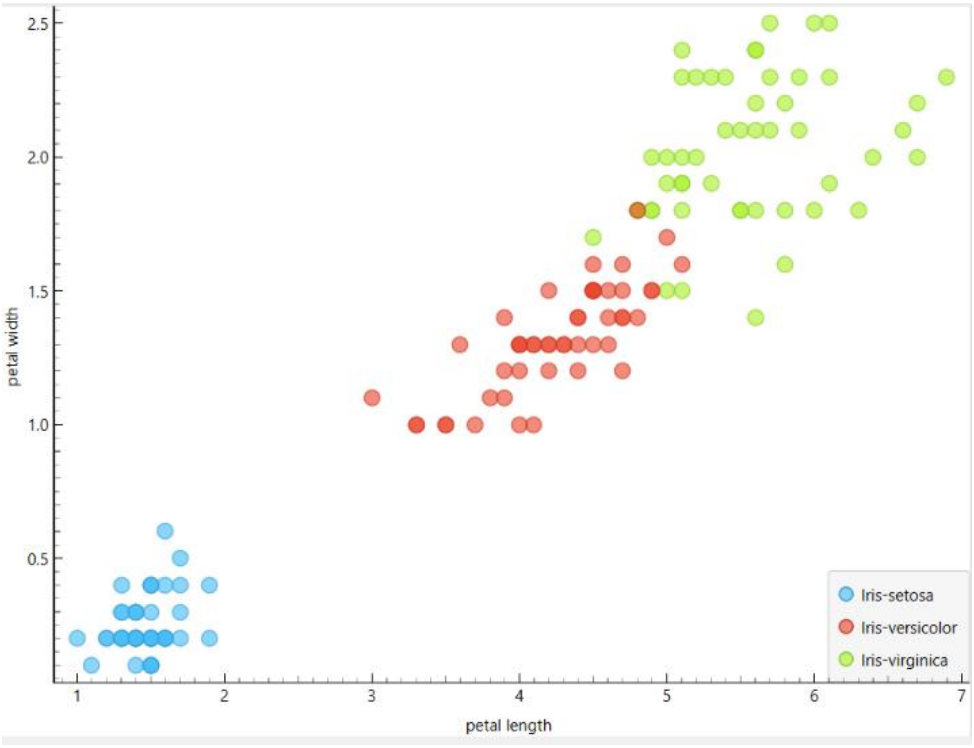


Gráfico de color por Iris.

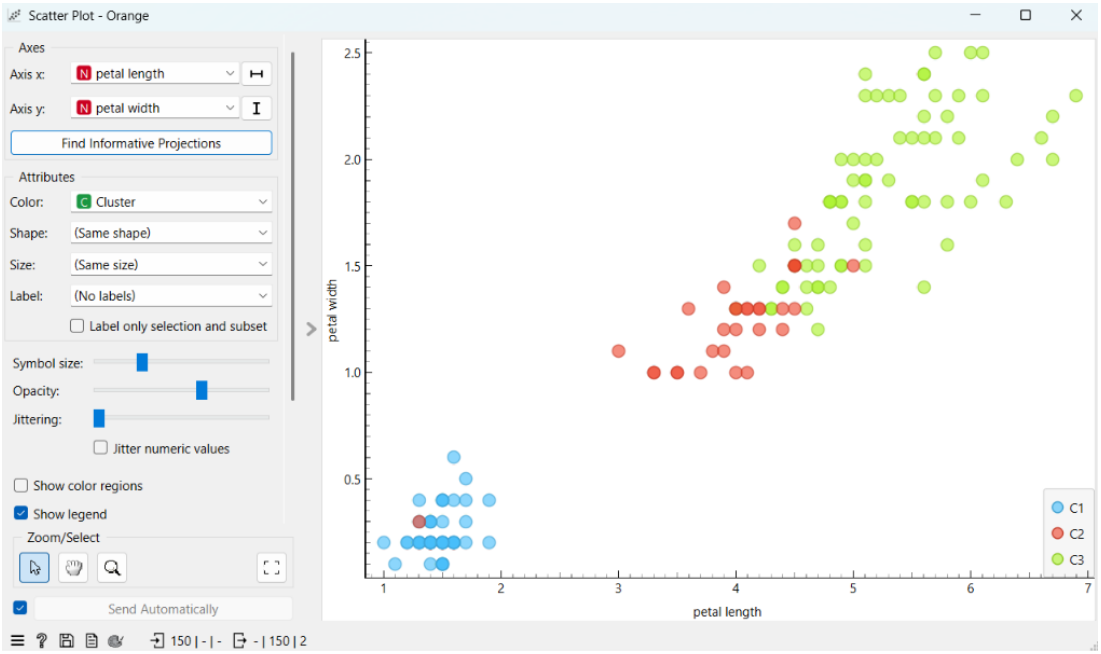


Gráfico de color por cluster.

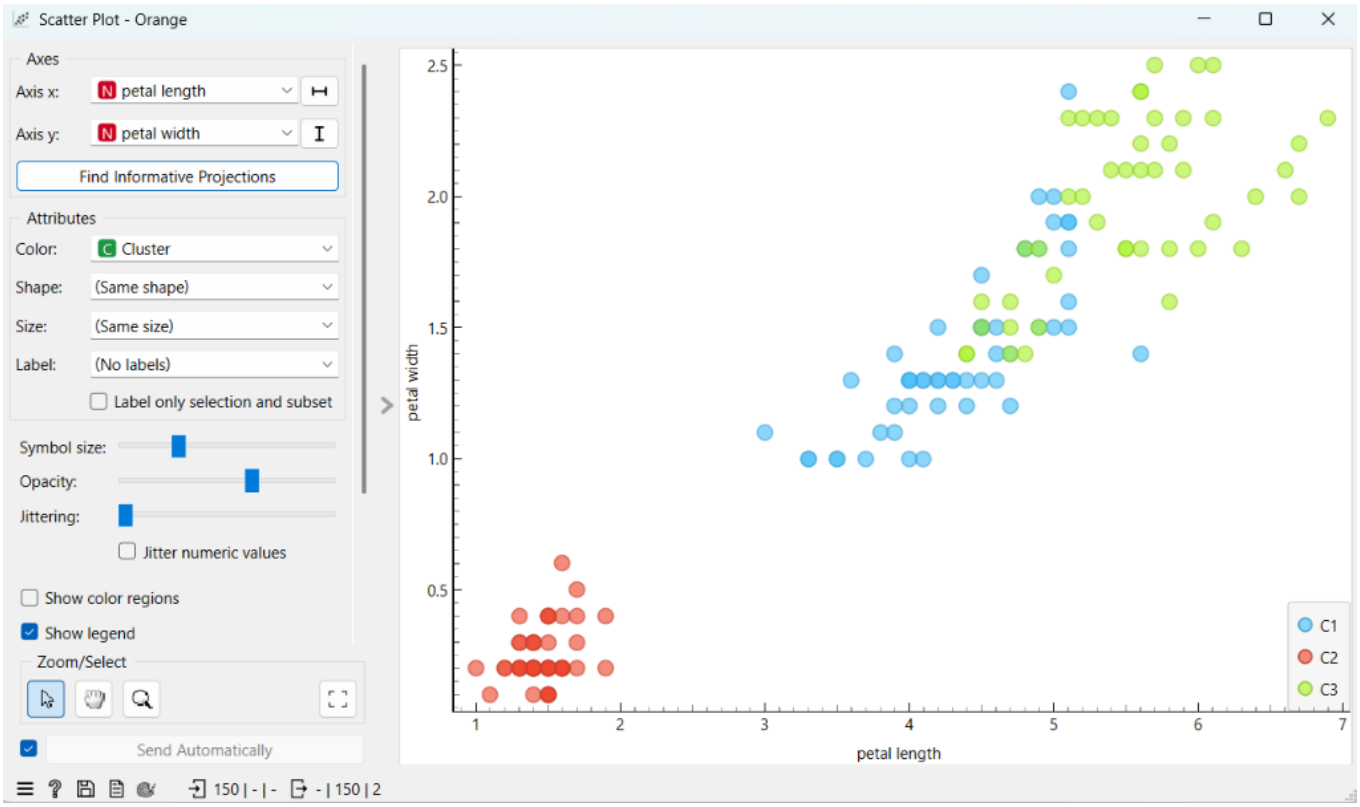
Semejanzas:

- **Grupo Setosa:** La especie *Iris-setosa* se identifica con una precisión perfecta, formando un clúster completamente aislado en la parte inferior izquierda.
- **Estructura General:** El clustering logra capturar correctamente la separación general en 3 regiones principales del espacio de datos según el largo y ancho del pétalo.

Diferencias:

- **Solapamiento Versicolor/Virginica:** El algoritmo comete pequeños errores de clasificación en la frontera donde *versicolor* y *virginica* se superponen. Algunos puntos de *versicolor* son agrupados dentro del clúster de *virginica* (y viceversa) debido a la continuidad de sus medidas.
- **Asignación por Proximidad:** A diferencia de las etiquetas biológicas reales, el criterio de Ward agrupa estrictamente por cercanía geométrica y minimización de varianza, lo que causa disputas en los puntos límites.

Parte 3)



¿Se parecen las dos particiones? Sí, son idénticas en la identificación del grupo inferior (*Iris-setosa*), separándolo a la perfección en ambos algoritmos. No obstante, difieren en la zona de solapamiento (*Versicolor* y *Virginica*): K-means genera fronteras de decisión más geométricas basadas en centroides (lo que mezcla de forma

distinta los puntos azules y verdes en la región superior), mientras que Ward gestiona la varianza y los agrupa de manera más compacta y estructurada según su densidad.