

Bases de datos y datasets

Unidad 1 · Analítica de Datos

¿De dónde vienen los datos que analizamos?

Antes de analizar cualquier información, es fundamental comprender cómo está almacenada, estructurada y disponible. Esta unidad te proporciona las bases para entender el origen y la naturaleza de los datos.



¿Qué es un dataset?

Un **dataset** o **conjunto de datos** es una colección de descriptores relacionados con un mismo fenómeno. No es simplemente "muchos datos", sino información organizada alrededor de algo que queremos estudiar. Por ejemplo, una base de datos sobre calidad del aire puede contener fecha, ubicación, temperatura y concentración de contaminantes: todos describen el mismo fenómeno.



Columnas = Variables

Cada columna es un descriptor o característica del fenómeno estudiado (fecha, temperatura, contaminante).

Filas = Observaciones

Cada fila representa una observación o registro concreto del fenómeno en un momento y lugar determinados.

¿Dónde encontramos datasets?

Existe una gran variedad de repositorios públicos y privados con datos listos para analizar. Conocer estos ecosistemas es el primer paso para cualquier proyecto de analítica.



Kaggle

Datasets para proyectos y competiciones de ciencia de datos.



UCI ML Repository

Datos científicos para aprendizaje automático.



AWS Open Data

Datos masivos en la nube de Amazon.



Google BigQuery

Datasets públicos para análisis a gran escala.



Quandl

Datos financieros y económicos.



Data.world

Repositorio colaborativo de datos abiertos.

Datos abiertos y fuentes gubernamentales

Los gobiernos generan grandes volúmenes de información que pueden consultarse y reutilizarse libremente. La **Alianza para el Gobierno Abierto (AGA/OGP)** promueve la transparencia institucional a nivel global.

En Colombia, el **Ministerio TIC (MINTIC)** gestiona el portal **Datos Abiertos Colombia**, donde ciudadanos, investigadores y empresas pueden acceder a datos reales para proyectos académicos y aplicados.



❏ Estos datos permiten desarrollar ejercicios académicos y proyectos aplicados con información real.

¿Qué encontramos dentro de un dataset?

Aunque los fenómenos estudiados sean completamente distintos, ambos pueden representarse mediante **registros** y **variables**. Dos ejemplos reales ilustran esta idea:

Calidad del aire en Madrid (2001–2018)

Disponible en Kaggle. Mide contaminantes por estación y fecha.

Fecha	Estación	NO ₂
01/01/2018	Plaza Castilla	45 µg/m ³
01/01/2018	Retiro	38 µg/m ³

Suscriptores de TV cerrada — Colombia

Disponible en Datos Abiertos Colombia. Registra suscriptores por municipio.

Municipio	Operador	Suscriptores
Bogotá	Claro	1.2M
Medellín	Tigo	680K

Los datos pueden venir en diferentes formatos

Antes de iniciar cualquier análisis, debemos identificar **en qué formato se encuentran los datos** y cómo acceder a ellos desde nuestra herramienta o lenguaje de programación. No todos los formatos se leen de la misma manera.



Raw Text

Texto plano
sin estructura
definida.



CSV / TSV

Valores separados
por delimitadores.



Spreadsheet

Hojas de cálculo
con fórmulas y
formato.



XML / JSON

Estructuras
jerárquicas con
etiquetas o pares
clave-valor.



SQL

Bases de datos
relacionales con
consultas
estructuradas.

CSV, JSON y XML: mismo dato, distinta estructura

El contenido puede ser idéntico, pero la forma en que se organiza varía según el formato. A continuación se muestra el mismo registro —nombre, ciudad y edad— representado en los tres formatos más comunes.

CSV

Valores separados por comas. Simple y ampliado. Variantes: TSV (tabulador), PSV (pipe).

```
nombre,ciudad,edad  
Ana,Madrid,28
```

JSON

Pares clave/valor. Ideal para comunicación entre aplicaciones web y APIs.

```
{  
  "nombre": "Ana",  
  "ciudad": "Madrid",  
  "edad": 28  
}
```

XML

Etiquetas descriptivas. Legible tanto por máquinas como por personas.

```
<persona>  
  <nombre>Ana</nombre>  
  <ciudad>Madrid</ciudad>  
  <edad>28</edad>  
</persona>
```

Hojas de cálculo y bases de datos

Ambas almacenan información, pero con capacidades muy distintas. Elegir la herramienta adecuada depende del volumen, la complejidad y las relaciones entre los datos.



Hojas de cálculo

Formato muy utilizado en organizaciones. Pueden contener **fórmulas, formato visual y múltiples pestañas**. Adecuadas para volúmenes pequeños o medianos de datos.

- Fáciles de usar y compartir
- Admiten fórmulas y gráficos
- Limitadas en volumen y relaciones



Bases de datos

Solución estructurada y relacional. Permiten **asociar tablas mediante claves** y gestionar grandes volúmenes con integridad y eficiencia.

- Organización relacional robusta
- Consultas complejas con SQL
- Escalables y seguras

Antes de analizar, debemos verificar

Un análisis puede producir resultados deficientes si los datos de entrada contienen errores. Es especialmente crítico cuando la información ha sido ingresada manualmente.

1

¿El dato existe?

Verificar que no haya campos vacíos o nulos.

2

¿Es del tipo correcto?

Un campo de edad no debería contener texto.

3

¿Está dentro del rango válido?

Una edad de 150 años es improbable.


4

¿Cumple el formato esperado?

Un correo electrónico debe incluir "@".

Nombre	Apellido	Correo	Edad
Carlos	García	carlos@mail.com	34
Lucía	—	lucia.sinarroba	—

Datos estructurados y no estructurados



La forma del dato determina cómo debemos extraerlo y procesarlo

Los **datos estructurados** siguen un esquema definido: tablas, campos y relaciones preestablecidas, como en las bases de datos relacionales.

Los **datos no estructurados** no siguen un esquema predefinido y pueden encontrarse en documentos, correos electrónicos, imágenes, vídeos, audios o información de sensores.



Comprender esta distinción es esencial para elegir las herramientas y técnicas de análisis adecuadas.