


PREPROCESAMIENTO DE DATOS

Preparar los datos para un análisis válido


Seleccionar tratamientos de datos faltantes y transformaciones de variables adecuadas al problema. El aprendizaje **supervisado** (clasificación y regresión) incluye una variable objetivo categórica o numérica; el **no supervisado** opera sin ella.



Diagnóstico de datos faltantes

Un dato faltante es información cuyo valor se desconoce: **no equivale a cero ni a «no aplica»**. Su revisión se orienta a cuánto falta, dónde se concentra y por qué pudo producirse.

Observación	Temperatura	Vibración	Presión
1	85.2	3.1	101.3
2	—	2.8	100.9
3	87.1	—	102.0
4	84.6	3.4	—



Las ausencias pueden deberse a fallas de medición u omisiones en el registro. El patrón de ausencia orienta la decisión de tratamiento.



Eliminar o imputar: una decisión justificada

No existen umbrales universales. La decisión depende del contexto, del patrón de ausencia y del propósito del análisis.

Eliminar filas

Útil cuando los faltantes son escasos y aleatorios. Riesgo: pérdida de información y posible sesgo.

Excluir variables

Apropiado si la variable tiene demasiados faltantes o baja relevancia para el modelo.

Imputar valores

Preserva el tamaño muestral. Puede modificar la variabilidad y las relaciones entre variables.

Métodos de imputación y sus límites


Media vs. mediana: efecto de valores extremos

Con los valores conocidos 10, 12 y 80:


- Media = **34** → sensible a valores extremos
- Mediana = **12** → más robusta

Para variables categóricas se usa la **moda**. Los modelos predictivos permiten imputaciones más refinadas, distinguiendo regresión (objetivo numérico) y clasificación (objetivo categórico).

❏ Imputar no recupera el valor verdadero: puede alterar la variabilidad y las relaciones entre variables.



Prevención de la fuga de información



Las medias de imputación, los parámetros de escalado y las categorías aprendidas deben obtenerse **exclusivamente con los datos de entrenamiento** y aplicarse después a prueba. Calcular la media con todo el conjunto introduce información del test en el entrenamiento. En validación cruzada, el preprocesamiento se ajusta **dentro de cada partición**.


Discretización por ancho uniforme

La discretización agrupa valores numéricos en intervalos. El ancho uniforme divide el rango en k intervalos de igual amplitud:

$$w = \frac{\max - \min}{k}$$

Con el vector {0, 4, 12, 16, 16, 18, 24, 26, 28} y $k = 3$: ancho = $28/3 \approx 9,33$. Límites: [0 – 9,33], [9,33 – 18,67], [18,67 – 28].

❑ Agrupar implica perder detalle sobre los valores individuales.




Discretización por frecuencia uniforme

Se forman grupos con **aproximadamente el mismo número de observaciones**, aunque las amplitudes de los intervalos sean distintas.

Con el mismo vector y $k = 3$ (3 observaciones por grupo):

- Grupo 1: {0, 4, 12}
- Grupo 2: {16, 16, 18}
- Grupo 3: {24, 26, 28}

Los valores repetidos pueden impedir una igualdad exacta entre grupos sin separar observaciones idénticas.




Discretización supervisada: entropía y pureza

La discretización supervisada usa la **variable objetivo** para seleccionar cortes que separen mejor las clases. La entropía mide la impureza de un grupo:

$$H(S) = - \sum_i p_i \log_2(p_i)$$

Un grupo **puro** (una sola clase) tiene entropía **cero**. La evaluación del corte considera la entropía ponderada de los grupos resultantes. Los cortes deben aprenderse **únicamente con entrenamiento**.



Codificación de variables categóricas

Ordinal

Asigna enteros respetando el orden natural. Ej.:
Primaria=1, Secundaria=2, Universidad=3.

One-hot

N columnas binarias, una por categoría. Sin
jerarquía artificial. Ej.: Madrid, Barcelona, Sevilla
→ 3 columnas.

Dummy

N-1 columnas con categoría de referencia. Evita
multicolinealidad en modelos lineales.



Distinguir codificación de características de la del
objetivo. Prever categorías nuevas en producción.

	Ciudades		Dummy
0	Pereira	0	10000
1	Cali	1	01000
2	Medellín	2	00100
3	Bogotá	3	00010
4	Barranquilla	4	00001
5	Cartago	5	00000

	Pereira	Cali	Medellín	Bogotá	Barranquilla	Cartago
0	1	0	0	0	0	0
1	0	1	0	0	0	0
2	0	0	1	0	0	0
3	0	0	0	1	0	0
4	0	0	0	0	1	0
5	0	0	0	0	0	1

Actividad integradora: justificar el preprocesamiento

Variable	Tipo	Observaciones
Temperatura	Numérica	Con faltantes
Ciudad	Nominal	Sin orden
Nivel educativo	Ordinal	Ordenado

Propón y justifica el tratamiento de ausencias, la conveniencia de discretizar y el método de codificación siguiendo esta secuencia:

