

De los datos a las preguntas

Antes de construir un modelo, exploramos los datos para interpretar distribuciones, detectar valores atípicos y descubrir relaciones entre variables. En un dataset, las **filas** son observaciones y las **columnas** son variables: **numéricas** (precio, área) o **categorías** (ciudad, tipo).

ID	Precio (€)	Área (m²)	Ciudad	Tipo
001	245.000	85	Madrid	Piso
002	189.000	62	Barcelona	Ático
003	312.000	110	Madrid	Piso
004	156.000	55	Valencia	Estudio

 **Pregunta orientadora:** ¿Qué podemos descubrir en los datos antes de construir un modelo?

Histogramas: reconocer la distribución



¿Qué revela un histograma?

- **Concentración:** los picos indican los intervalos de mayor frecuencia
- **Dispersión:** la amplitud del eje horizontal muestra el rango de valores
- **Colas:** las zonas bajas pueden revelar valores poco comunes

i El número de intervalos (*bins*) modifica la apariencia del gráfico. Probad con distintos valores para captar la forma real de la distribución.



FORMA DE LA DISTRIBUCIÓN

Asimetría: interpretar las colas

Simétrica

Colas equilibradas.
Media $\approx$ Mediana.
Ejemplo: altura de personas adultas.

Asimetría positiva

Cola hacia la derecha. Media $>$ Mediana. Ejemplo: salarios, precios de vivienda.


Asimetría negativa

Cola hacia la izquierda. Media $<$ Mediana. Ejemplo: notas en exámenes fáciles.



Una distribución simétrica no implica normalidad. Interpretad siempre el coeficiente de asimetría junto con el gráfico.

Diagrama de caja: mediana, cuartiles y dispersión



Anatomía del box plot


- La **caja** contiene el 50 % central de las observaciones
- La línea interior marca la **mediana**
- Los **bigotes** llegan hasta los valores más extremos dentro de los límites



$$IQR = Q3 - Q1$$

Límites: $Q1 - 1,5 \times IQR$ y $Q3 + 1,5 \times IQR$

Valores atípicos: detectar e investigar



¿Error o dato válido?

El valor de 800.000 € desplaza la **media** y aumenta la dispersión, pero la **mediana** apenas cambia. La mediana es más robusta frente a valores extremos.

Regla IQR

Valor atípico si está fuera de $Q1 - 1,5 \times IQR$ o $Q3 + 1,5 \times IQR$

Media $\pm 3\sigma$

Requiere distribución aproximadamente normal para ser válida

Estandarización: comparar variables en distintas escalas


Puntuaciones z

$$z = \frac{x - \mu}{\sigma}$$


- x : valor observado
- μ : media de la variable
- σ : desviación estándar

El resultado expresa cuántas desviaciones estándar se aleja un valor de la media. Permite comparar variables con unidades distintas (p. ej., temperatura en °C y longitud de pétalos en mm).

i Estandarizar **no** convierte una distribución en normal ni elimina su asimetría. Es distinto del escalado al intervalo [0, 1].



Variables categóricas: conteos y proporciones




¿Cómo resumir una variable categórica?

- **Tabla de contingencia:** cruza dos variables categóricas con frecuencias absolutas
- **Barras agrupadas:** comparan conteos entre categorías
- **Barras apiladas al 100 %:** muestran proporciones para comparar grupos de tamaños distintos

Los conteos comparan cantidades; las proporciones facilitan la comparación entre grupos de distinto tamaño.

Gráficos de dispersión: explorar relaciones numéricas



¿Qué observar en un scatter plot?

- **Dirección:** positiva (ascendente) o negativa (descendente)
- **Forma:** lineal, curvilínea o sin patrón claro
- **Agrupamientos:** posibles subgrupos o categorías latentes
- **Valores atípicos:** puntos alejados del patrón general



Una asociación visual **no** demuestra causalidad. La relación puede ser lineal o no lineal.


Series temporales y mapas de calor

Series temporales



Las series temporales **deben conservar el orden cronológico**. No reordenar los datos por valor.

Mapa de calor de correlaciones



Escala de -1 a 1. Una correlación cercana a cero **no descarta** otras formas de relación no lineal.

Visualizar y argumentar

Elegid un dataset y responded con evidencia gráfica siguiendo esta estructura:

1

Pregunta

¿Qué queréis investigar?
Formulad una pregunta
clara sobre el dataset.

2

Evidencia

Elegid una visualización
univariada y una
bivariada. Leed ejes y
unidades correctamente.

3

Conclusión

Argumentad con los
gráficos. Identificad
posibles valores atípicos
y distinguid correlación
de causalidad.



Criterios de revisión: selección adecuada del gráfico · lectura de ejes y unidades · interpretación coherente · distinción correlación/causalidad

