

Universidad Nacional de Colombia — Sede Manizales  
Facultad de Ingeniería y Arquitectura  
Departamento de Ingeniería Eléctrica, Electrónica y Computación

---

## Laboratorio de Simulación 2

Implementación en Orange Data Mining

---

**Curso:** Analítica de Datos (Aprendizaje de máquina) — Código 4200729

**Módulo:** 2 — Transformación y visualización de datos

**Docente:** Diego Fabián Collazos Huertas

**Modalidad:** trabajo en parejas

Este laboratorio hace parte de la nota de **Laboratorios de simulación (45 % de la evaluación)**, según el programa de la asignatura (PROGRAMA.md).

## 1 Objetivos

- Reproducir en **Orange Data Mining** — mediante programación visual, sin escribir código — los mismos análisis que se implementaron en Python en los notebooks `2.2_Preprocesamiento_Transformacion_Ejemplos.ipynb` y `2.4_Visualizacion_Datos_Ejemplos.ipynb`.
- Diagnosticar datos faltantes y aplicar el tratamiento adecuado (excluir, imputar) usando los widgets de preprocesamiento de Orange.
- Dividir un dataset en entrenamiento/prueba y aplicar la **misma** transformación aprendida en entrenamiento sobre la prueba, evitando la fuga de información.
- Discretizar una variable numérica de las tres formas vistas en clase (ancho uniforme, frecuencia uniforme, supervisada) y codificar variables categóricas.
- Elegir y construir las visualizaciones adecuadas (histograma, diagrama de caja, barras, dispersión, serie temporal) para responder preguntas sobre un dataset real.

### Nota

Este taller **no reemplaza** los notebooks de Python; los complementa. La idea es que compares, para el mismo problema, qué tan distinto es resolverlo con código (Pandas/scikit-learn/Matplotlib) frente a resolverlo con programación visual (Orange) — ver `1.2_Orange_Data_Mining.md` para instalar la herramienta si aún no lo has hecho.

## 2 Instrucciones generales

1. **Este laboratorio se desarrolla en parejas** (2 estudiantes), asignadas o conformadas según indique el docente.
2. Para cada parte del laboratorio, arma el flujo (*workflow*) solicitado en el lienzo de Orange.
3. Cada vez que veas el ícono ● **Actividad**, documenta la respuesta **directamente sobre el lienzo de Orange**, usando la herramienta de texto (clic derecho sobre un espacio vacío del lienzo → *Text*, o el ícono “T” de la barra de herramientas) para agregar un cuadro de texto junto a los widgets correspondientes. No se entregan respuestas en un documento aparte: el workflow comentado **es** la respuesta.
4. Además, toma una captura de pantalla del resultado de cada actividad (el widget correspondiente ya abierto, mostrando el gráfico o la tabla) para incluirla en el PDF de evidencias.
5. Consulta la sección **Entregables** (al final de este documento) para el detalle de qué debes entregar y cómo.

### Nota

Algunos widgets de este laboratorio (*Group By*, *Line Plot*) son relativamente recientes en Orange. Si no los encuentras en tu barra de widgets, actualiza Orange a la versión más reciente (*Help* → *Check for Updates*, o reinstalando desde <https://orangedatamining.com/download/>).

## 3 Parte 1 — Preprocesamiento y transformación en Orange

Esta parte reproduce en Orange lo desarrollado en el notebook `2.2_Preprocesamiento_Transformacion_Ejemplos.ipynb`, usando el mismo dataset: el **Titanic**.

### 3.1 1.1 Cargar el dataset y diagnosticar datos faltantes

1. Reutiliza el archivo `.csv` del Titanic que ya descargaste con **kagglehub** al ejecutar el notebook 2.2 (queda guardado en la ruta que imprime la celda de descarga), o descárgalo directamente desde <https://www.kaggle.com/datasets/yasserh/titanic-dataset>.
2. Abre Orange y crea un workflow nuevo. Arrastra el widget **File** al lienzo y carga el archivo.
3. En el editor de columnas del widget *File*, marca la columna **Survived** con el rol **target** (clase) — la necesitaremos más adelante para la discretización supervisada.
4. Agrega el widget **Feature Statistics** (categoría *Data*) y conéctalo a *File*. Esta tabla muestra, entre otras cosas, el porcentaje de valores faltantes de cada columna.

#### ● Actividad

Compara la columna de faltantes de *Feature Statistics* con el diagnóstico del notebook (**Cabin**  $\approx 77\%$ , **Age**  $\approx 20\%$ , **Embarked**  $\approx 0.2\%$ ). En un cuadro de texto junto al widget, escribe si los porcentajes coinciden. Incluye en tu PDF de evidencias una captura de *Feature Statistics*.

### 3.2 1.2 Dividir train/test y tratar los datos sin fuga de información

Como en el notebook (sección 3), **dividimos antes de calcular cualquier estadístico de imputación**, para que ningún dato de prueba influya en los valores usados para imputar.

1. Agrega el widget **Select Columns** conectado a *File*, y mueve la columna **Cabin** al grupo *Excluded* (equivalente a `drop(columns=['Cabin'])`).
2. Agrega el widget **Data Sampler**, conéctalo a *Select Columns*. Configúralo con **Fixed proportion of data: 80%** y activa la casilla **Stratify sample**. Esto reparte los datos en dos salidas: *Data Sample* (entrenamiento) y *Remaining Data* (prueba) — equivalente a `train_test_split(..., stratify=titanic['Survived'])`.
3. Agrega un segundo widget **Feature Statistics** y conéctale la salida *Data Sample* (entrenamiento) — para leer la mediana de **Age** calculada **solo** con el entrenamiento (no la del dataset completo que viste en 1.1). Anota ese valor: lo necesitarás en el siguiente paso.
4. Agrega el widget **Impute** (categoría *Data*, distinto del paso “Impute Missing Values” dentro de *Preprocess*) y conéctale también la salida *Data Sample* (entrenamiento). A diferencia de *Preprocess*, *Impute* sí permite elegir un tratamiento distinto **para cada variable**:
  - Selecciona **Age** en la lista de variables y cambia su tratamiento individual a **Value** (valor fijo), escribiendo el valor de la mediana que anotaste en el paso anterior. Como Orange no trae un preset listo de “mediana”, así se logra el mismo efecto: imputar con un valor fijo igual a la mediana del entrenamiento.
  - Selecciona **Embarked** y déjalo (o cámbialo) en **Average/Most frequent** — para una variable categórica, esta opción imputa con la moda.

- El nombre y la ubicación exactos de estas opciones pueden variar un poco según la versión de Orange; si no las encuentras igual, explora el panel del widget o pregúntale al docente.
5. Agrega un widget **Apply Domain** (categoría *Data*). Conéctale la salida *Remaining Data* (prueba) de *Data Sampler* como **Data**, y la salida del *Impute* (entrenamiento) como **Reference Data**. *Apply Domain no vuelve a calcular nada*: reconstruye el conjunto de prueba usando exactamente el mismo dominio que quedó fijado al imputar el entrenamiento (el mismo valor fijo de **Age** y la misma moda de **Embarked**), sin recalcular esos valores con los datos de prueba.

### Nota

*Impute* (entrenamiento) → *Apply Domain* (con la prueba como *Data* y el entrenamiento ya imputado como *Reference Data*) es el equivalente visual exacto de “ajustar (*fit*) en entrenamiento y transformar (*transform*) en prueba con los mismos parámetros”, que en el notebook se resuelve calculando `mediana_age` y `moda_embarked` solo con `train` y aplicándolas también a `test`. Usamos el widget *Impute* en vez del paso “Impute Missing Values” de *Preprocess* porque este último solo ofrece tres opciones **globales** (Average/Most frequent, Replace with random value, Remove rows) — no deja elegir un método distinto por variable, y “Average” calcula la **media**, no la mediana. Tampoco se puede encadenar la salida *Preprocessor* de un *Preprocess* a otro *Preprocess*: ese widget solo acepta *Data* como entrada; para aplicar una transformación ya aprendida a otro conjunto de datos, el widget correcto en Orange es *Apply Domain*.

### ● Actividad

Conecta un widget **Data Table** a la salida del *Impute* (entrenamiento) y a la salida *Data* del *Apply Domain* (prueba), y verifica que ninguna de las dos columnas tratadas (**Age**, **Embarked**) tenga valores faltantes. En un cuadro de texto junto al *Impute*, anota el valor fijo que usaste para **Age** y compáralo con la mediana que calculó el notebook ( $\approx 28.5$  años). Incluye en tu PDF de evidencias una captura del workflow completo de esta sección (*Select Columns* → *Data Sampler* → *Feature Statistics*, *Impute* y *Apply Domain* → las dos *Data Table*).

## 3.3 1.3 Discretización de la edad y codificación de categóricas

1. Agrega el widget **Discretize** (categoría *Data*) conectado a la salida del *Impute* (entrenamiento). Selecciona la variable **Age** y prueba, uno a la vez, los tres métodos de discretización disponibles:
  - **Equal frequency** (frecuencia uniforme) — equivalente a `pd.qcut` en el notebook.
  - **Equal width** (ancho uniforme) — equivalente a `pd.cut` con bordes fijos.
  - **Entropy-MDL** — discretización **supervisada**: usa la variable objetivo (**Survived**, que ya marcaste como *target* en el punto 1.1) para elegir el corte que mejor separa las clases, igual que la búsqueda por entropía del notebook.
2. Agrega un widget **Continuize** (categoría *Data*) conectado también a la salida del entrenamiento. Selecciona **Embarked** y prueba las opciones **One feature per value** (equivalente a *one-hot*) y **One feature per value, ignore the first value** (equivalente a *dummy*, la codificación  $N - 1$ ).

### ● Actividad

En un cuadro de texto junto al widget *Discretize*, anota el corte que encontró el método **Entropy-MDL** para **Age** y compáralo con el umbral que encontró el notebook ( $\approx 5-6.5$  años, el patrón de “mujeres y niños primero”). Junto al widget *Continueize*, anota cuántas columnas nuevas genera cada opción para **Embarked** y compáralas con las columnas **Embarked\_C/Q/S** (one-hot) y **Embarked\_Q/S** (dummy) del notebook. Incluye en tu PDF de evidencias una captura de cada widget con el método/opción que mejor haya reproducido el resultado del notebook.

## 4 Parte 2 — Visualización en Orange

Esta parte reproduce en Orange lo desarrollado en el notebook 2.4\_Visualizacion\_Datos\_Ejemplos.ipynb, usando el mismo dataset: **Video Game Sales**.

### 4.1 2.1 Cargar el dataset y explorar la distribución

1. Reutiliza el archivo `.csv` de Video Game Sales que ya descargaste con **kagglehub** al ejecutar el notebook 2.4, o descárgalo directamente desde <https://www.kaggle.com/datasets/regorut/videogamesales>.
2. Carga el archivo en un nuevo workflow con el widget **File**.
3. Agrega el widget **Distributions**, conéctalo a *File*, y selecciona la variable **Global\_Sales**. Prueba distintos valores del control de número de intervalos (*Bin width* / número de *bins*), igual que en el notebook.
4. Agrega el widget **Feature Statistics** conectado a *File*: muestra directamente la **media**, la **mediana** y la **asimetría** (*skewness*) de **Global\_Sales**.

### ● Actividad

Compara el histograma de *Distributions* con los del notebook (¿también se ve una cola larga hacia la derecha con pocos *bins* y se nota mejor con más *bins*?). En un cuadro de texto junto a *Feature Statistics*, compara los valores de media, mediana y asimetría con los que calculó el notebook (media  $\approx 0,54$ , mediana  $\approx 0,17$ , asimetría muy alta y positiva) y explica en una frase qué significa que la media sea mucho mayor que la mediana. Incluye en tu PDF de evidencias una captura de cada widget.

### 4.2 2.2 Diagrama de caja, valores atípicos y variables categóricas

1. Agrega el widget **Box Plot** conectado a *File*, y selecciona **Global\_Sales**. Orange dibuja la caja, la mediana y marca los valores atípicos según la misma regla del IQR usada en el notebook.
2. Agrega el widget **Bar Plot** conectado a *File*, y selecciona **Genre** para ver el conteo de juegos por género.

### ● Actividad

En un cuadro de texto junto al *Box Plot*, anota cuántos valores atípicos identifica Orange y compáralos con el conteo de la regla del IQR del notebook ( $\approx 11\%$  de los juegos). Junto al *Bar Plot*, indica si el género más frecuente coincide con el del notebook (*Action*). Incluye en tu PDF de evidencias una captura de cada widget.

## 4.3 2.3 Relaciones entre variables y serie temporal

1. Agrega el widget **Scatter Plot** conectado a *File*: en el eje X selecciona **NA\_Sales**, en el eje Y selecciona **EU\_Sales**.
2. Agrega el widget **Correlations** conectado a *File*: ordena automáticamente todos los pares de variables numéricas según su coeficiente de correlación — es el equivalente a leer el mapa de calor de correlaciones del notebook, pero en forma de tabla.
3. Agrega el widget **Group By** (categoría *Transform*) conectado a *File*: agrupa por **Year** y agrega **Global\_Sales** con la función *Sum* — es el equivalente visual de `groupby('Year')['Global_Sales'].sum()` en el notebook.
4. Conecta la salida de *Group By* a un widget **Line Plot** para ver la serie temporal de ventas globales por año.

### ● Actividad

En un cuadro de texto junto al *Scatter Plot*, describe la dirección y forma de la relación entre **NA\_Sales** y **EU\_Sales**, y compárala con la correlación que reporta el widget *Correlations* (el notebook encontró  $\approx 0,77$ ). Junto al *Line Plot*, indica si el año de mayores ventas coincide con el que encontró el notebook (2008). Incluye en tu PDF de evidencias una captura de los cuatro widgets de esta sección.

## 5 Entregables

La pareja debe subir al repositorio del curso (a través de la página de entregas) **dos tipos de archivo**:

1. **Los archivos .ows de los workflows armados en Orange** (uno por cada parte del laboratorio), **comentados con la herramienta de texto de Orange** tal como se indicó en cada actividad. El workflow comentado — no un documento aparte — es donde se responden las preguntas de cada actividad.
2. **Un único PDF con las capturas de pantalla** de los resultados obtenidos en cada una de las 6 actividades (●), claramente identificadas (por ejemplo, “Actividad 1 — Feature Statistics del Titanic”).

Nombra los archivos con los apellidos de ambos integrantes de la pareja, por ejemplo: `apellido1_apellido2_parte1.ows`, `apellido1_apellido2_parte2.ows` y `apellido1_apellido2_evidencias.pdf`. Sube estos archivos desde la página de entregas del curso, seleccionando la categoría **Laboratorio de Simulación 2**.

### ● Reflexión final

Como cuadro de texto de cierre en el workflow de la **Parte 1**, escriban en pareja una breve reflexión (5-8 líneas): ¿qué fue más fácil de entender en Orange que en Python (o viceversa) al dividir train/test y evitar la fuga de información? ¿Y al discretizar y codificar variables?

### Nota

Este laboratorio corresponde a la segunda entrega del componente **Laboratorios de simulación (45 % de la nota)**. Revisa la fecha de entrega vigente en `entregas/README.md`.