





Correlación y causalidad en analítica de datos

El análisis de relaciones entre variables permite reconocer patrones y comprender cómo se comportan los datos antes de construir un modelo de aprendizaje de máquina. En esta presentación aprenderemos a interpretar la dirección e intensidad de una relación lineal, explorar mapas de correlación y distinguir una asociación estadística de una explicación causal.


Machine learning: mapa de decisión



El mapa de decisión organiza las principales tareas del aprendizaje de máquina según el problema que se desea resolver. Antes de elegir un modelo, necesitamos comprender las variables, identificar relaciones y reconocer las características de los datos.


- La exploración mediante correlaciones contribuye a esa comprensión inicial.

¿Qué relación muestran los datos?




Correlación positiva

Cuando una variable aumenta, la otra también tiende a aumentar. Los puntos se alinean de abajo a la izquierda hacia arriba a la derecha.



Correlación negativa

Al aumentar una variable, la otra tiende a disminuir. Los puntos se alinean de arriba a la izquierda hacia abajo a la derecha.




Sin asociación lineal

Los puntos no presentan tendencia lineal clara, aunque pueden existir relaciones curvas u otros patrones no lineales.

El coeficiente de correlación de Pearson

El coeficiente de Pearson mide la **dirección** y la **intensidad** de la asociación lineal entre dos variables. Sus valores se encuentran entre **-1 y +1**:



$$r = +1$$

Relación lineal positiva perfecta

$$r = -1$$


Relación lineal negativa perfecta

$$r \approx 0$$

Poca asociación lineal

- Un valor de $-0,9$ expresa una asociación más intensa que $+0,4$, aunque su dirección sea negativa. La magnitud importa tanto como el signo.

Un coeficiente necesita un gráfico



El coeficiente de correlación **resume una característica** de la relación, pero no describe toda la estructura de los datos. Los diagramas de dispersión permiten reconocer:

→ Curvaturas

Relaciones no lineales que el coeficiente no captura.


→ Agrupaciones

Subgrupos dentro de los datos que merecen análisis separado.

→ Observaciones alejadas

Valores atípicos que pueden distorsionar el coeficiente.

Transformaciones que revelan relaciones



En algunos conjuntos de datos, las relaciones no resultan evidentes en su escala original. Aplicar **logaritmos a ambas variables** puede permitir observar con mayor claridad una tendencia positiva oculta.

⚠ Valores positivos

El logaritmo requiere valores estrictamente positivos.

📐 Nueva escala

La transformación modifica la interpretación de los resultados.

🔍 Sin causalidad

Encontrar una relación más clara no demuestra causalidad.

Mapas de correlación

	longitude	latitude	housing_median_age	total_rooms	total_bedrooms	population	households	median_income	median_house_value
longitude	1.000000	-0.924478	-0.105823	0.048909	0.076686	0.108071	0.063146	-0.019615	-0.047466
latitude	-0.924478	1.000000	0.005737	-0.039245	-0.072550	-0.115290	-0.077765	-0.075146	-0.142673
housing_median_age	-0.105823	0.005737	1.000000	-0.364535	-0.325101	-0.298737	-0.306473	-0.111315	0.114146
total_rooms	0.048909	-0.039245	-0.364535	1.000000	0.929391	0.855103	0.918396	0.200133	0.135140
total_bedrooms	0.076686	-0.072550	-0.325101	0.929391	1.000000	0.876324	0.980167	-0.009643	0.047781
population	0.108071	-0.115290	-0.298737	0.855103	0.876324	1.000000	0.904639	0.002421	-0.026882
households	0.063146	-0.077765	-0.306473	0.918396	0.980167	0.904639	1.000000	0.010869	0.064590
median_income	-0.019615	-0.075146	-0.111315	0.200133	-0.009643	0.002421	0.010869	1.000000	0.687151
median_house_value	-0.047466	-0.142673	0.114146	0.135140	0.047781	-0.026882	0.064590	0.687151	1.000000

Un mapa de correlación representa las asociaciones entre varios pares de variables mediante una **matriz de colores**. Cada celda corresponde a un par y su color indica el signo e intensidad del coeficiente.

Identificar variables

Consultar filas y columnas para saber qué par se analiza.

Detectar redundancias

Correlaciones muy elevadas pueden señalar características superpuestas.

Contexto de tarea

Una correlación alta no basta para eliminar una variable: depende del objetivo del modelo.

CONCEPTO CLAVE

Correlación $\neq$ Causalidad

Correlación


Describe una **asociación estadística** entre variables. Indica que dos fenómenos varían de forma conjunta, sin afirmar que uno cause el otro.

Causalidad

Plantea que un fenómeno **produce cambios** en otro. Requiere justificación teórica, diseño experimental o análisis que controle variables externas.

Variable de confusión

Una **tercera variable** puede influir sobre ambas, generando una asociación aparente sin relación causal directa entre ellas.



Helados y ahogamientos




Si durante determinados periodos aumentan tanto el **consumo de helados** como los **ahogamientos**, podríamos observar una asociación estadística entre ambos fenómenos.

¿Comer helados provoca ahogamientos?
Evidentemente, no.

Los **días cálidos** ofrecen una explicación común: favorecen el consumo de helados y aumentan la participación en actividades acuáticas. La temperatura es la **variable de confusión** que explica la asociación aparente.

Aplicación y conclusiones



La correlación ayuda a **explorar y describir** los datos, pero sus resultados deben interpretarse siempre dentro del contexto del problema. Antes de extraer conclusiones, combina la información gráfica con el coeficiente y reflexiona sobre las posibles explicaciones causales.



Gráfico primero

Inspecciona siempre la distribución de los datos antes de confiar en un número.



Asociación $\neq$ Causa

Una correlación elevada no implica relación causal directa.



Busca la tercera variable

Considera siempre si un factor externo puede explicar la asociación observada.