



Selección y Extracción de Características

No toda la información disponible es útil. Algunas características son redundantes, poco variables o introducen ruido. Aprenderemos a conservar atributos, construir nuevas representaciones y evaluar qué se gana y qué se pierde al reducir la dimensionalidad, usando los conjuntos **Iris**, **MNIST** y **Swiss roll**.



¿Dónde encaja en el aprendizaje automático?



Dos decisiones independientes

Seleccionar características define qué información se usa para representar las observaciones. **Elegir un algoritmo** define cómo se aprenderá de esa información.

- La disponibilidad de etiquetas orienta el tipo de problema
- Ambas decisiones deben validarse mediante evaluación adecuada
- La utilidad de una característica depende de la tarea concreta

Seleccionar atributos o extraer características

Selección

Conserva un **subconjunto** de los atributos originales. En Iris, elegir solo medidas del pétalo es selección.

Extracción

Construye **nuevas características** a partir de las existentes mediante transformaciones. Genera atributos que no existían antes.



Supervisado: usa la variable objetivo para orientar el proceso.




No supervisado: trabaja sin etiquetas, basándose en propiedades intrínsecas de los datos.

Criterios de selección supervisada




Gini y Entropía

Miden impureza de clases e incertidumbre en árboles de decisión. La **ganancia de información** expresa cuánto se reduce la incertidumbre tras una división.



ANOVA


Contrasta las medias de una característica numérica entre clases. Detecta si los grupos difieren significativamente en ese atributo.



Chi-cuadrado

Evalúa asociaciones entre variables categóricas comparando recuentos observados y esperados. Su aplicación depende del tipo de datos.

What Is a Chi-Square Test?



Relief y eliminación recursiva (RFE)

ReliefF con un ejemplo de frutas

¿Qué distingue mejor una fruta madura de una verde: la dulzura o el tamaño?

Datos ficticios normalizados de 0 a 1 · k = 2 · Una iteración ilustrativa

1. Datos del ejemplo

Fruta	Clase	Dulzura	Tamaño
R	Madura	0,8	0,5
H1	Madura	0,7	0,4
H2	Madura	0,9	0,6
M1	Verde	0,2	0,5
M2	Verde	0,3	0,6

2. Elegir referencia y vecinos

Referencia: R, fruta madura.
Hits: H1 y H2, misma clase.
Misses: M1 y M2, otra clase.

Se excluye R de sus propios vecinos.
Solo hay dos vecinos elegibles en cada clase en este ejemplo.

3. Comparar la dulzura

Diferencias absolutas con R:

Hits: 0,1 y 0,1 → promedio 0,10

Misses: 0,6 y 0,5 → promedio 0,55

Dulzura

4. Comparar el tamaño

Diferencias absolutas con R:

Hits: 0,1 y 0,1 → promedio 0,10

Misses: 0,0 y 0,1 → promedio 0,05

Tamaño

5. Actualizar los pesos

Pesos iniciales: 0
Ejemplo binario con una iteración:

Peso = promedio misses – promedio hits

Dulzura: 0,55 – 0,10 = **+0,45**

Tamaño: 0,05 – 0,10 = **-0,05**

6. Interpretar y repetir

En esta iteración, la dulzura distingue mejor las clases.
Su diferencia es pequeña entre maduras y grande frente a las verdes.
Repetir con otras referencias y promediar los aportes antes de seleccionar características.

1 Dulzura: +0,45

2 Tamaño: -0,05

ReliefF favorece atributos que cambian poco dentro de una clase y mucho entre clases vecinas.

Este cálculo usa m = 1 para enseñar el mecanismo; no es una evaluación completa.

Relief

Compara ejemplos cercanos de la misma clase y de clases distintas. Favorece atributos con valores similares entre vecinos de la misma clase y diferencias entre clases distintas, ajustando pesos iterativamente.

Eliminación Recursiva (RFE)

Entrena un estimador, retira los atributos menos importantes y repite el proceso con conjuntos menores. La validación cruzada ayuda a determinar cuántos atributos conservar.

Extracción de características

Reducción de dimensión

El enfoque de la extracción de características, como su nombre lo indica, es la extracción de "nuevos" atributos a partir de los ya existentes.

Reducir el número de atributos


Con esto se reduce el efecto de la maldición de la dimensionalidad.

Mejor representación de la base

Permite condensar la información en una forma más útil para el análisis.

No supervisadas

Supervisadas




Dimensionalidad y el ejemplo MNIST

La maldición de la dimensionalidad



Al aumentar las características, los datos se dispersan en el espacio y se requieren más observaciones y recursos. Reducir atributos facilita el análisis, pero conlleva riesgo de pérdida informativa.

MNIST en la práctica

Los píxeles de fondo varían poco y son poco informativos para distinguir dígitos. **Eliminarlos** es selección; **transformarlos** en nuevos atributos es extracción. En ambos casos, hay que verificar qué se conserva.



Proyección a un espacio de menor dimensión



Subespacios de representación

Las observaciones no siempre ocupan todas las dimensiones disponibles. A menudo se concentran cerca de un **subespacio de menor dimensión**.

Proyección sobre el plano

Al proyectar puntos 3D sobre un plano, obtenemos una representación bidimensional con nuevos ejes z_1 y z_2 . Facilita la visualización, pero puede perder información. Su pertinencia depende de que el subespacio represente adecuadamente la estructura de interés.

Variedades y el ejemplo Swiss roll

Estructura enrollada




Swiss roll es una superficie **bidimensional** enrollada en un espacio tridimensional. Proyectarla directamente sobre un plano puede superponer capas que estaban separadas.

Desenrollar la variedad

El **aprendizaje de variedades** busca representar la estructura en menos dimensiones respetando sus relaciones internas. La dimensión local puede ser menor que la del espacio de representación.

Complejidad de la frontera

Reducir la dimensión no siempre simplifica la tarea: una frontera de clasificación puede volverse más sencilla o más compleja según la representación elegida.



Decisión aplicada y cierre



Iris

¿Qué medidas conservaría?
Justifique según la tarea de
clasificación.



MNIST

¿Qué píxeles revisaría por su
escasa variación? ¿Qué
información se perdería?



Swiss roll

¿Qué estructura debe preservarse
al cambiar la representación?

 **Recuerde:** En tareas predictivas, ajuste la selección con los datos de entrenamiento y reserve los de prueba para la evaluación final. Una representación más compacta puede facilitar el trabajo, pero su utilidad debe comprobarse empíricamente.