


¿Qué es Principal Component Analysis (PCA)?




PCA (Principal Component Analysis) o **Análisis de Componentes Principales** es un método de reducción de dimensionalidad que transforma las variables originales en nuevas variables denominadas **componentes principales**.

Identifica un hiperplano cercano a los datos y proyecta las observaciones sobre dicho subespacio, **conservando la mayor cantidad posible de variabilidad**.

- ❏ PCA busca una nueva representación de los datos que concentre la mayor cantidad posible de información en pocas dimensiones.

PCA como un problema de proyección




Imaginemos datos distribuidos en un espacio bidimensional. Existen **diferentes direcciones posibles** sobre las cuales proyectarlos, pero no todas conservan la misma cantidad de información.

- Algunas proyecciones preservan bien la estructura original de los datos
- Otras comprimen los puntos y pierden información
- PCA busca la dirección que **maximiza la variabilidad conservada**

❏ No todas las direcciones contienen la misma cantidad de información.

¿Cómo selecciona PCA la mejor dirección?




PCA selecciona el eje sobre el cual la proyección de los datos conserva la **máxima varianza**. Una proyección con alta dispersión mantiene mayor información; una proyección donde los puntos quedan muy próximos pierde estructura.

El mejor eje también minimiza la distancia cuadrática entre los datos originales y su proyección.

❏ **Máxima varianza = mayor cantidad de información conservada.**

PC1, PC2, PC3... ¿qué representan?



PC1 — Primer componente principal

Dirección con **mayor variabilidad** en los datos. Corresponde a un vector unitario.

PC2 — Segundo componente principal

Captura la mayor varianza **restante**. Es ortogonal a PC1.


PC3, PC4, ...

Cada componente captura la varianza restante, siempre ortogonal a los anteriores. Con n variables, hasta n componentes.

De los datos originales a los componentes principales

Una técnica estándar para obtener los componentes principales es la **Descomposición en Valores Singulares (SVD)**:

$$X = U\Sigma V^T$$



01

Organizar datos en matriz X

02

Centrar respecto a la media

03

Aplicar SVD: $X = U\Sigma V^T$

04


Ordenar componentes por varianza

05

Conservar los primeros componentes

La matriz V contiene las direcciones de los componentes principales.

Reduciendo de n dimensiones a d dimensiones




Tras identificar los componentes principales, se seleccionan los primeros d y se proyectan las observaciones sobre el nuevo subespacio:

$$X_{d\text{-proj}} = XW_d$$

- X : matriz original de datos
- W_d : primeros d componentes principales
- $X_{d\text{-proj}}$: datos en el espacio reducido

Las nuevas variables son **combinaciones lineales** de las originales.

¿Cuánta información conserva cada componente?




El **Explained Variance Ratio** mide la proporción de varianza total explicada por cada componente principal.

- PC1 normalmente explica la mayor proporción
- PC2 explica una proporción adicional
- Los componentes posteriores aportan cantidades cada vez menores

❏ Los porcentajes son ilustrativos. En la práctica, dependen de cada conjunto de datos.

¿Cuántos componentes conservar?



Una estrategia habitual consiste en escoger el menor número de componentes cuya **varianza explicada acumulada** alcance un umbral suficientemente alto.


Reducción de dimensionalidad

Varianza acumulada $\geq 95\%$

Visualización

Normalmente 2 o 3 componentes

Cuando una proyección lineal no es suficiente



PCA encuentra subespacios **lineales**. Funciona bien cuando la estructura de los datos puede aproximarse mediante un plano o hiperplano, pero algunos conjuntos presentan estructuras **curvas** o **no lineales**.

❏ ¿Cómo aplicar la idea de PCA cuando la geometría de los datos es no lineal?

El Swiss Roll

Estructura 2D doblada en 3D. Una proyección lineal directa **superpone capas** distintas y pierde la estructura intrínseca.


El objetivo real

«Desenrollar» la estructura preservando las distancias locales, no proyectar linealmente.

Kernel PCA: reducción dimensional no lineal

Kernel PCA extiende PCA a estructuras no lineales mediante el **kernel trick**: las observaciones se mapean implícitamente mediante $\phi(x)$ en un espacio de alta dimensión donde se aplica PCA lineal.

$$X \rightarrow \phi(X) \rightarrow \text{Feature Space} \rightarrow \text{PCA} \rightarrow Z$$



PCA	Kernel PCA
Transformación lineal	Transformación no lineal
Maximiza varianza	Captura estructuras no lineales
Más simple	Más flexible
Proyección directa	Reconstrucción más compleja

Kernels habituales: **RBF/Gaussiano, Polinómico y Sigmoid**. La selección del kernel y sus hiperparámetros afecta significativamente la representación obtenida.