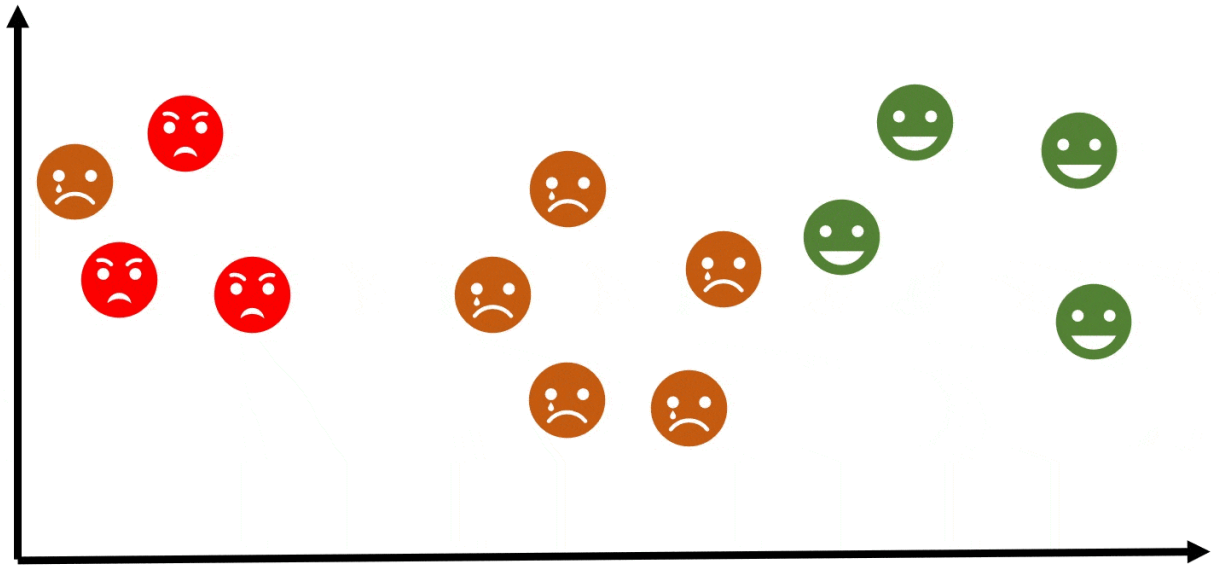
Principios básicos del clustering

Cómo descubrir grupos en datos sin etiquetas

Pregunta guía: ¿Cómo identificar perfiles de clientes sin categorías previas?

Objetivo resumido: Comprender qué es el agrupamiento (clúster), la noción de similitud y las medidas de distancia.



Made with GAMMA

Aprendizaje supervisado vs no supervisado

Clasificación (supervisado)	Clustering (no supervisado)
Entrena con ejemplos etiquetados; objetivo: asignar etiquetas conocidas.	Trabaja sin etiquetas; objetivo: explorar estructuras y proponer identificadores de grupo.
Salida: categoría validada (p.ej. “alto/medio/bajo”).	Salida: identificador de clúster (números de grupo). No es una categoría validada.

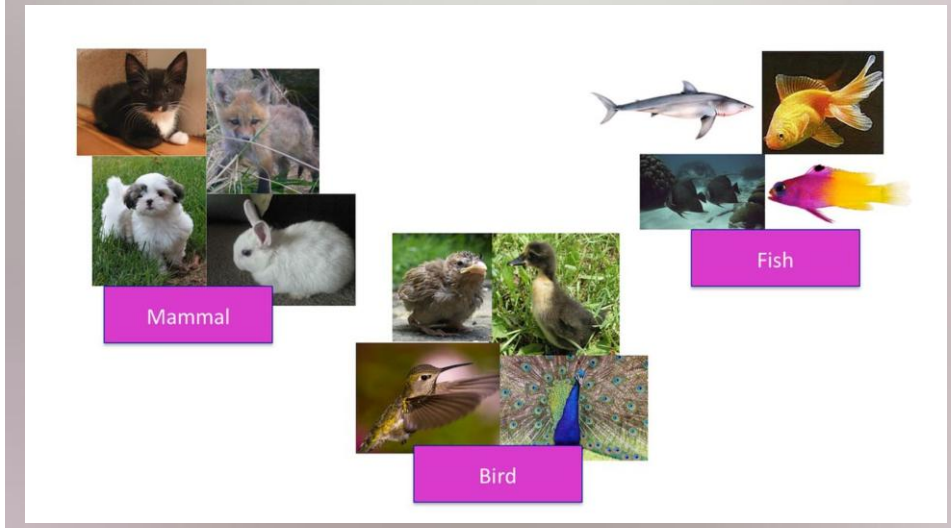
Nota visible: una salida numérica es un identificador, la interpretación la aporta el analista.

Made with GAMMA

Qué caracteriza a un clúster

Un grupo (clúster) muestra coherencia interna y separación respecto a otros grupos según el criterio elegido. No existe un método universal: la representación y la elección de variables condicionan la percepción de grupos.

¿Qué información necesitaría para explicar estos grupos?



Observaciones, variables y preparación

ID	Compras/mes	Gasto mensual (COP)
A (ident.)	2	80000
B (ident.)	3	100000
C (ident.)	10	700000

Decisiones previas: manejar valores faltantes, elegir variables relevantes, detectar atípicos y tratar identificadores (ID) como etiquetas, no como variable de similitud.

Advertencia: sin reescalar, magnitudes monetarias pueden dominar distancias si se mezclan con conteos.

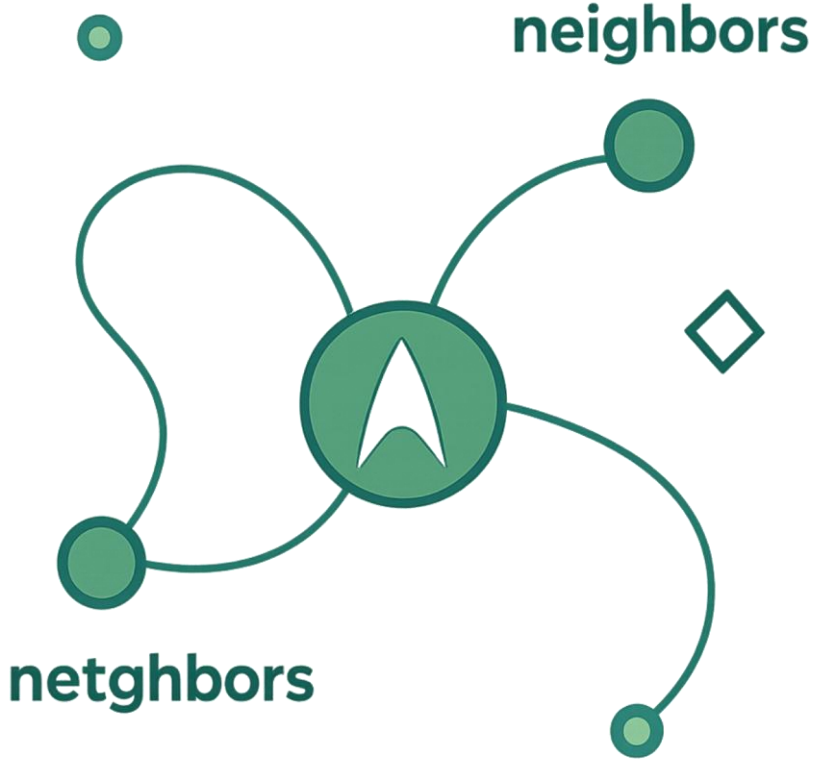
Preparar datos define qué significa “parecerse”.

Made with GAMMA

Similitud, distancia y vecinos

Similitud alta → mayor parecido. Distancia baja → cercanía según la medida. Un vecino es la observación más cercana según la medida elegida; cambiar la medida cambia la vecindad.

Transformación típica: distancia = 1 − similitud (para ciertas medidas). La elección depende del tipo de variables y la pregunta analítica.

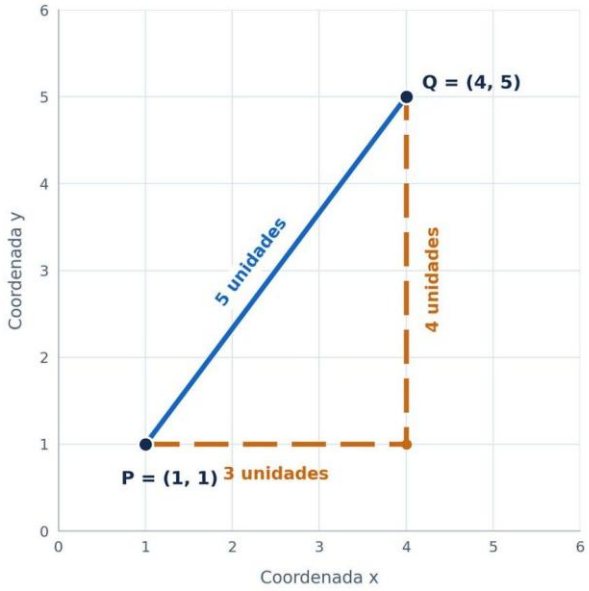


Made with GAMMA

Distancia euclídea y Manhattan (ejemplo)

Dos formas de medir la distancia

Entre P = (1, 1) y Q = (4, 5)



DISTANCIA EUCLÍDEA

Recorrido en línea recta

$$d_E = \sqrt{(4-1)^2 + (5-1)^2}$$

$$= \sqrt{9+16} = \mathbf{5}$$

DISTANCIA MANHATTAN

Suma de desplazamientos por coordenadas

$$d_M = |4-1| + |5-1|$$

$$= 3 + 4 = \mathbf{7}$$

Analogía: recorrer manzanas de una ciudad.

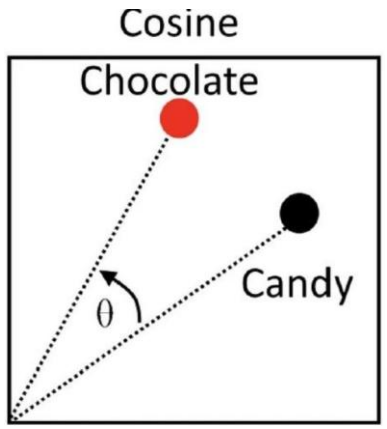
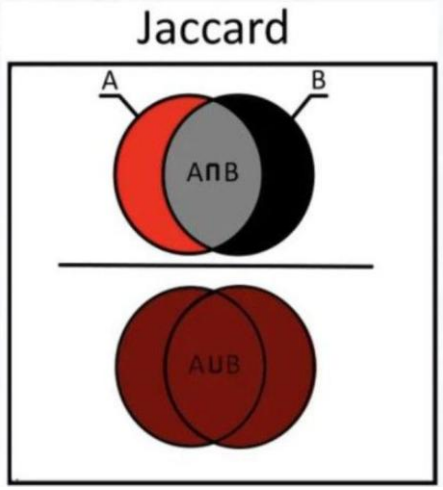
Euclídea: distancia en línea recta.

Manhattan: suma de desplazamientos por coordenadas (analogía: manzanas).

La elección depende de la interpretación de diferencias entre atributos; no afirmar que una sea siempre mejor.

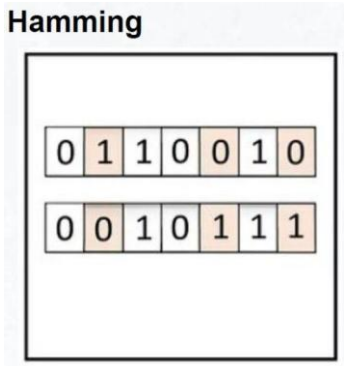
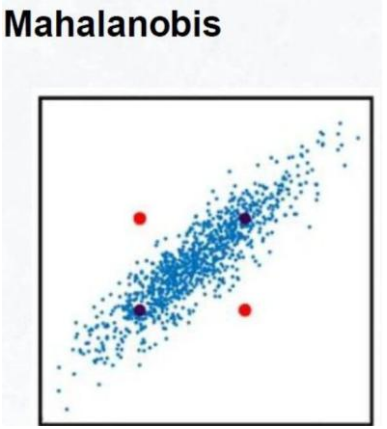
Made with GAMMA

Medidas para distintos tipos de datos

Medida	Qué compara	Ejemplo	Ilustración
Coseno	Orientación de vectores	Documentos (TF)	
Jaccard	Intersección/Unión de conjuntos	Productos comprados	

Made with GAMMA

Medidas para distintos tipos de datos

Medida	Qué compara	Ejemplo	Ilustración
Hamming	Posiciones distintas en secuencias	Códigos binarios	
Mahalanobis	Distancia considerando covarianza	Variables numéricas correlacionadas	

Made with GAMMA

Distancias para variables categóricas

Medidas para datos dicotómicos

$X_i \setminus X_j$	1	0	Totales
1	a	b	a + b
0	c	d	c + d
Totales	a + c	b + d	m = a + b + c + d

Medida de Ochiai → $\frac{a}{\sqrt{(a+b)(a+c)}}$

Medida Φ → $\frac{ad-bc}{\sqrt{(a+b)(c+d)(a+c)(b+d)}}$

Medida de Russell y Rao → $\frac{a}{a+b+c+d}=\frac{a}{m}$

Medida de Parejas simples → $\frac{a+d}{a+b+c+d}=\frac{a+d}{m}$

Medida de Jaccard → $\frac{a}{a+b+c}$

Medida de Dice → $\frac{2a}{2a+b+c}$

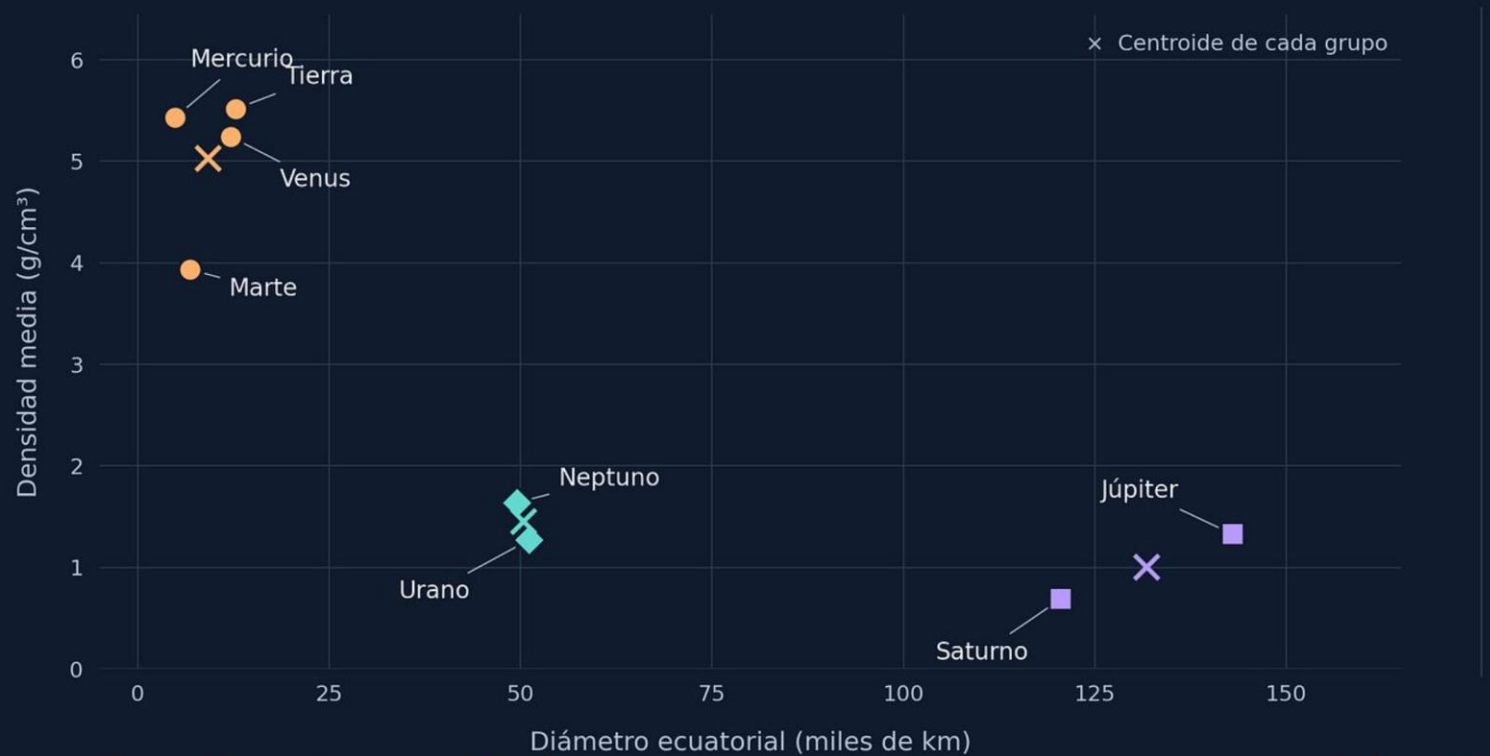
Medida de Rogers-Tanimoto → $\frac{a+d}{a+d+2(b+c)}$

Made with GAMMA

CLUSTERING CON DATOS REALES

¿Qué planetas se parecen entre sí?

K-means agrupa 8 planetas usando solo su diámetro y su densidad.



Para discutir: ¿cambiarían los grupos si usáramos otras características?

Método: K = 3 elegido para el ejercicio; ambas variables estandarizadas antes del ajuste. Ejes en unidades originales.
Los nombres identifican los puntos, pero no intervienen en el cálculo. Los símbolos no representan el tamaño real.

Fuente: NASA / NSSDCA, Planetary Fact Sheet – Metric · nssdc.gsfc.nasa.gov/planetary/factsheet/ · Agrupamiento calculado para esta clase.

GRUPO 1

Pequeños y densos

Mercurio, Venus, Tierra y Marte

GRUPO 2

Diámetro intermedio

Urano y Neptuno

GRUPO 3

Los mayores diámetros

Júpiter y Saturno

UN DATO CURIOSO

La Tierra es unas 8 veces más densa que Saturno.

Made with GAMMA