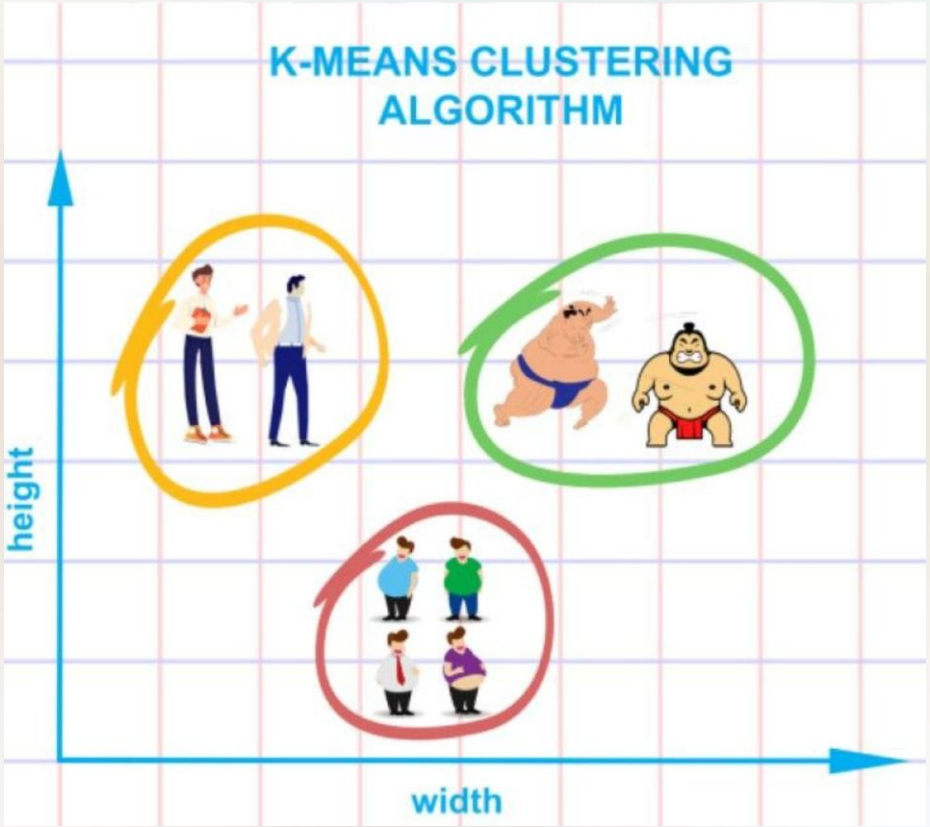
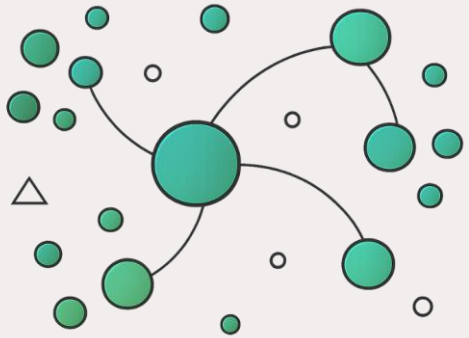


K-means: agrupamiento basado en centroides

Asignar observaciones, actualizar medias y evaluar grupos

Objetivo: ejecutar una iteración sencilla de K-means, justificar la elección de K y la inicialización, e interpretar inercia y silhouette para comparar agrupamientos.

Made with GAMMA



Definición

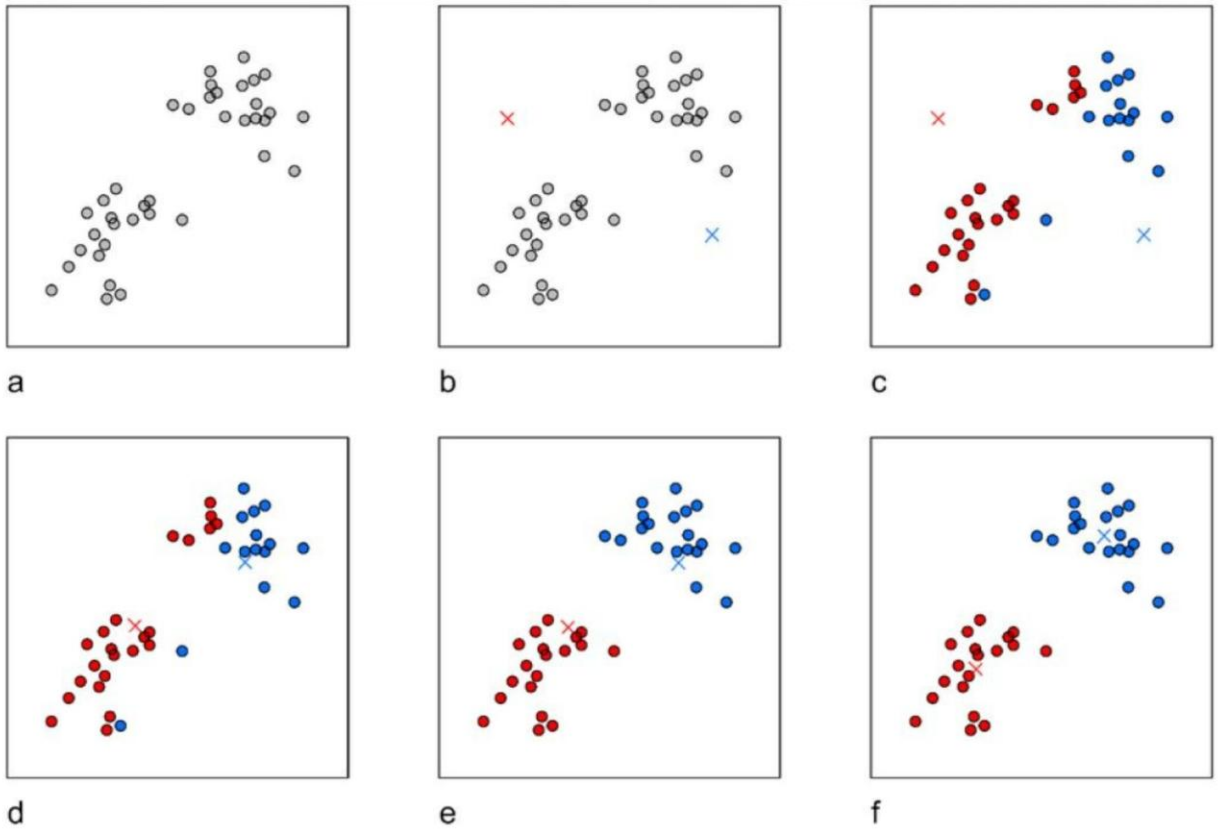
El algoritmo K-Meanses un algoritmo simple capaz de agruparesteste tipo de conjunto de datos de manera muy rápida y eficiente, a menudo en solo unas pocas iteraciones.

Fue propuesto por Stuart Lloyden los Laboratorios Bell en 1957 como una técnica para la modulación de código de pulso, pero solo se publicó fuera de la compañía en 1982, en un artículo titulado “Cuantización de mínimos cuadrados en PCM”.

En 1965, Edward W. Forgy había publicado prácticamente el mismo algoritmo, por lo que K-Means a veces se conoce como Lloyd-Forgy.

Made with GAMMA

El ciclo de K-means (visión general)

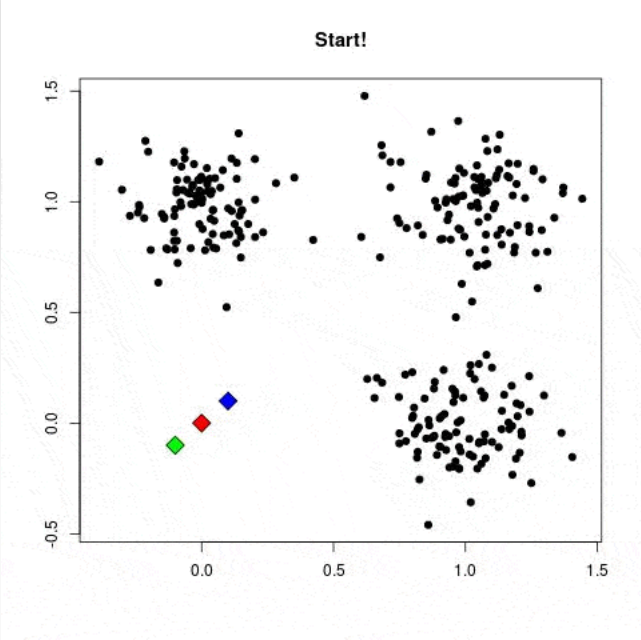


1. Inicialice **k** centroides al azar: se seleccionan al azar k instancias distintas del conjunto de datos y los centroides se colocan en sus ubicaciones.
2. Asigne cada instancia al centroide más cercano.
3. Actualice los centroidespara que sean la media de las instancias que se les asignan.

Repita hasta la convergencia(es decir, hasta que los centroides dejen de moverse)

La elección de **K** se sitúa fuera del bucle. Criterios de parada habituales: asignaciones estables, cambio pequeño en centroides o límite de iteraciones. Distancia usada: euclídea al cuadrado (optimiza suma de cuadrados).

Made with GAMMA



Actualización de centroides y convergencia

No nos danlas etiquetas ni los centroides.

- Comience colocando los centroides al azar(por ejemplo, eligiendo **k** instancias al azar y usando sus ubicaciones como centroides).
- Luego etiquete las instancias, actualice los centroides, etiquete las instancias, actualice los centroides, etc., hasta que los centroides dejen de moverse.

> Se garantiza que el algoritmo converge en un número finito de pasos (generalmente bastante pequeño).

Made with GAMMA

Inicialización y alternativas

Reinicios (random restarts)

Comparar varias inicializaciones para elegir la solución con menor inercia final.

K-means++

Inicializa centroides favoreciendo separación entre ellos; mejora probabilidad de soluciones buenas.

Elkan (acelerado)

Reduce cálculos de distancia mediante cotas, a costa de más memoria.

Mini-batch

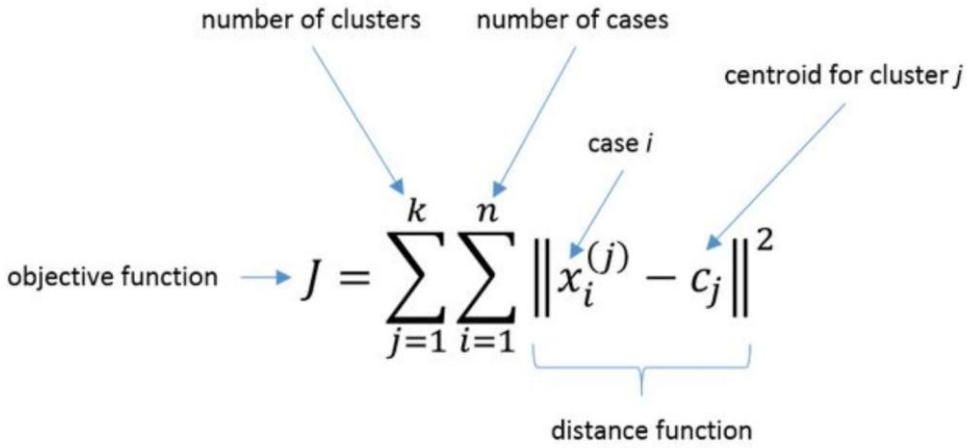
Actualiza con lotes pequeños; eficiente en tiempo pero aproximado.

Ninguna alternativa garantiza el mínimo global por sí sola; comparar reinicios manteniendo datos, escalado y K.

Made with GAMMA

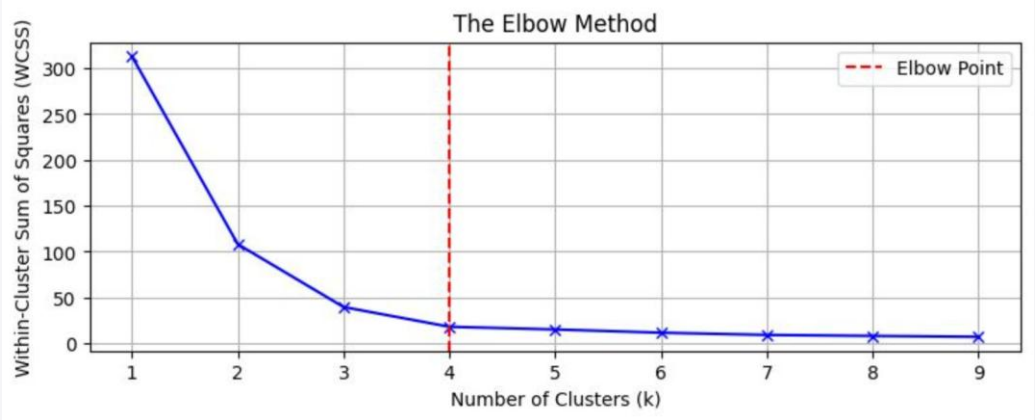
Inercia y método del codo

Definición:



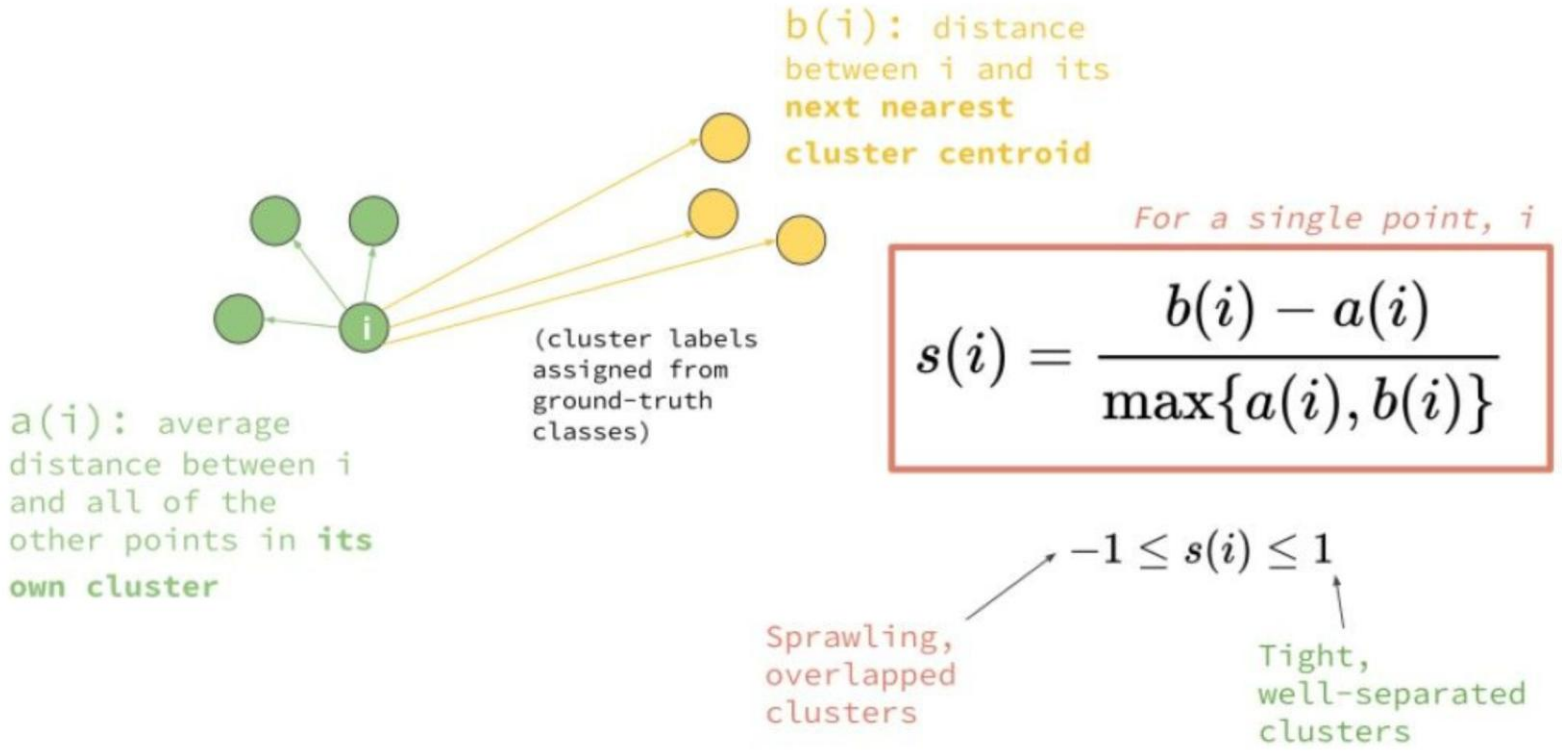
(suma de cuadrados dentro de grupos). Al aumentar K, J no aumenta.

El codo identifica dónde aumentar K reduce poco la inercia. Es ilustrativo y puede ser ambiguo; no determinar K únicamente con esta regla.



Coeficiente silhouette

Definición por punto: s = (b − a) / max(a, b), donde a = distancia media al propio grupo y b = menor distancia media a otro grupo.
Interpretación: **cerca de 1 buena separación**; **≈0 en frontera**; **negativo mala asignación.**



Aclaración: b es la menor distancia media a los puntos de otro grupo (no necesariamente la distancia a un centroide).

Made with GAMMA

Alcance y limitaciones de K-means

Útil para grupos compactos y similares en dispersión. Problemas típicos: formas no convexas, densidades distintas, valores atípicos y variables mal escaladas. Requiere elegir K y revisar la preparación de datos.



Grupos compactos

Buen rendimiento cuando la estructura es aproximadamente esférica.



Grupos curvos

Falla con formas no lineales: considerar alternativas (DBSCAN, spectral).

Las medias son sensibles a outliers; codificar categorías con números no garantiza interpretación válida.

Made with GAMMA

Actividad: cálculo y elección de K

ACTIVIDAD PARA ENTREGAR · 15 MINUTOS

K-means: cálculo y selección de K

Resuelva en una hoja. Escriba su nombre y grupo. Muestre el procedimiento.

Datos ficticios: horas de estudio por semana

A = 1 B = 2 C = 8 D = 9

Inicio: K = 2; centroides $C_1 = 1$ y $C_2 = 9$.

1. Asigne cada observación al centroide más cercano

Use la distancia absoluta: $d(x, C) = |x - C|$.

Dato	x	$\|x - C_1\|$	$\|x - C_2\|$	Grupo
A	1			
B	2			
C	8			
D	9			

2. Calcule los nuevos centroides

C_1 = _____ C_2 = _____

Recuerde: centroide = promedio de los valores del grupo.

3. Calcule la inercia para K = 2

Use los nuevos centroides y sume las distancias al cuadrado de los cuatro datos.

$$J_2 = (1 - ___)^2 + (2 - ___)^2 + (8 - ___)^2 + (9 - ___)^2$$

J_2 = _____

4. Seleccione K y justifique

Complete J_2. Los demás valores ya están calculados.

K	1	2	3	4
Inercia	50	____	0,5	0

¿Qué K elegiría según el método del codo?

¿Por qué no basta buscar una inercia igual a cero?

Entregue: tabla de asignación, dos centroides, cálculo de inercia y una justificación breve de K.

Made with GAMMA