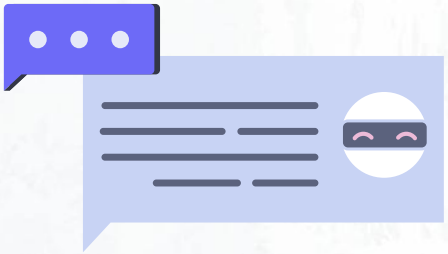
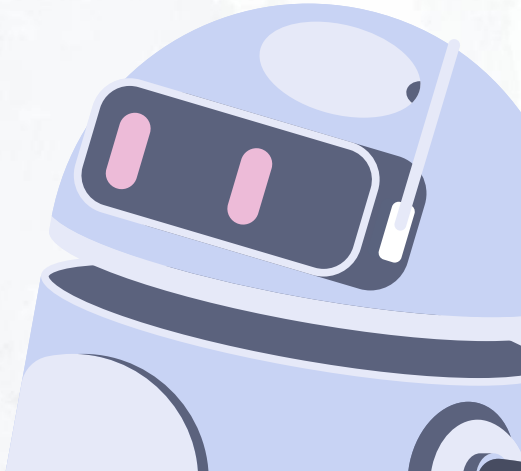
Analítica de Datos (Aprendizaje de máquina)





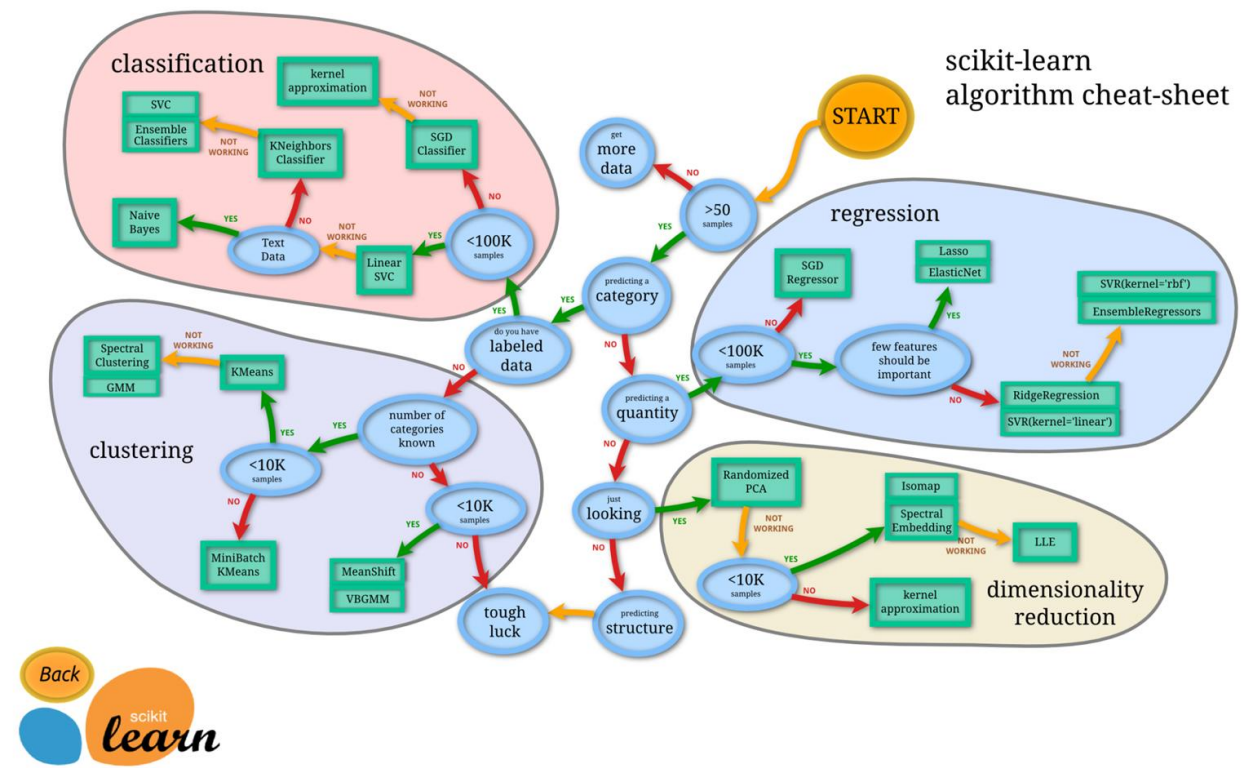


UNAL

Departamento de Eléctrica, Electrónica y Computación
Facultad de Ingeniería y Arquitectura
Sede Manizales

UNIVERSIDAD NACIONAL DE COLOMBIA

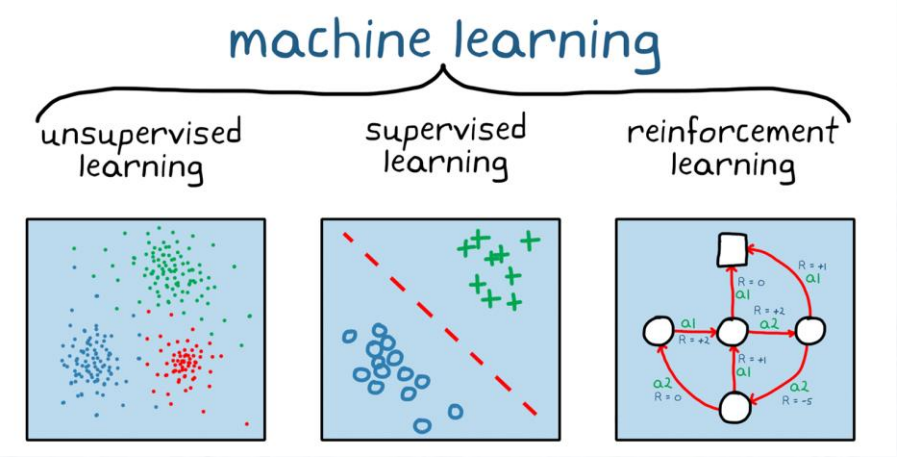
Machine learning - Guideline



Aprendizaje supervisado

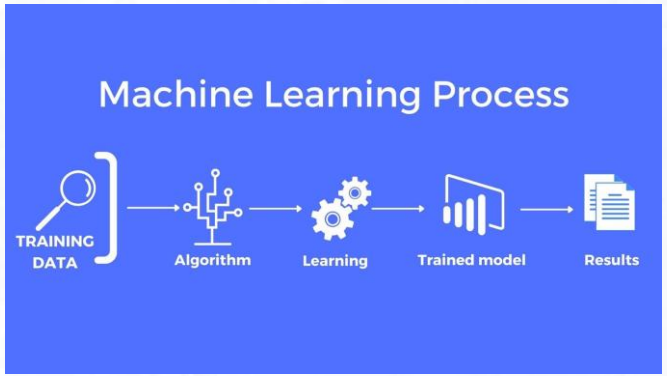
Definición

- ✓ Aprendizaje supervisado consiste en darle la capacidad a las máquinas de **aprender** a partir de ejemplos.
- ✓ Esta forma de analizar datos, aprender de ellos y permitir que las máquinas **tomen decisiones** es lo que llamamos aprendizaje de máquina o MACHINE LEARNING



Aprendizaje supervisado

Machine learning



Entrenamiento / Test: Pensemos en la preparación y presentación de un examen. Esto tiene dos momentos:

1. En un primer momento estudiamos (a partir de nuestros apuntes, leemos libros, buscamos información) ... en definitiva, aprendemos, nos entrenamos.

1. En un segundo momento, nos evalúan, nos sometemos a un test.

Lo mismo ocurre en una estrategia de aprendizaje supervisado.

Primero, entrenamos la máquina a partir de nuestros datos. Luego, la sometemos a un test para evaluar su rendimiento.

Aprendizaje supervisado

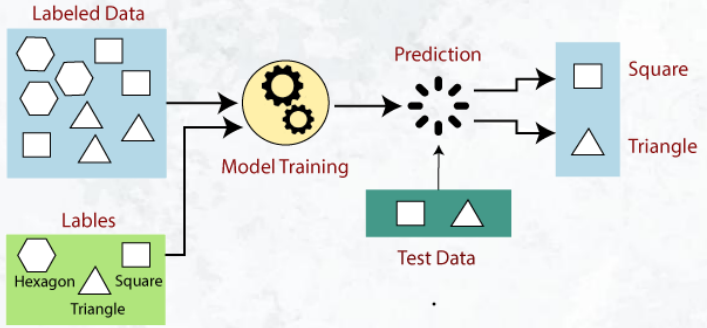
Objetivo

El aprendizaje supervisado de datos lo hacemos cuando conocemos las etiquetas (clases o target) de las instancias (o sujetos).

Aquí lo que buscamos es entrenar un modelo que sea capaz de reconocer instancias de cada una de las clases.

Este tipo de aprendizaje o análisis también se conoce como **aprendizaje por ejemplos**.

El aprendizaje supervisado utiliza un conjunto de datos de entrenamiento para enseñar a los modelos a obtener los resultados deseados. Este conjunto de datos de entrenamiento incluye entradas y salidas correctas, que permiten al modelo aprender.

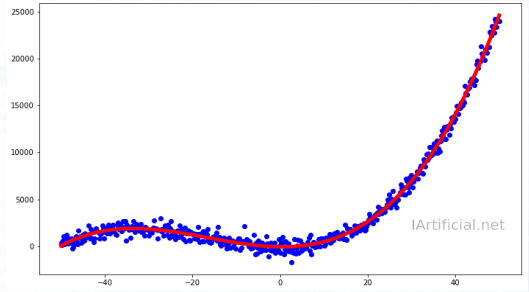


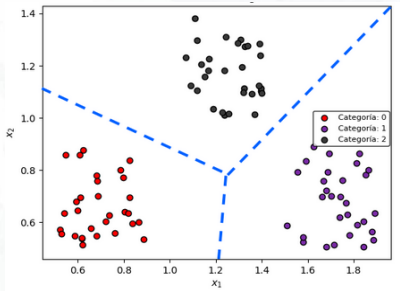
UNAL
Departamento de Eléctrica, Electrónica y Computación
Facultad de Ingeniería y Arquitectura
Sede Manizales
UNIVERSIDAD NACIONAL DE COLOMBIA

Aprendizaje supervisado

Enfoques

Regresión





Clasificación

A diferencia del aprendizaje no- supervisado, aquí tenemos una **variable objetivo.**

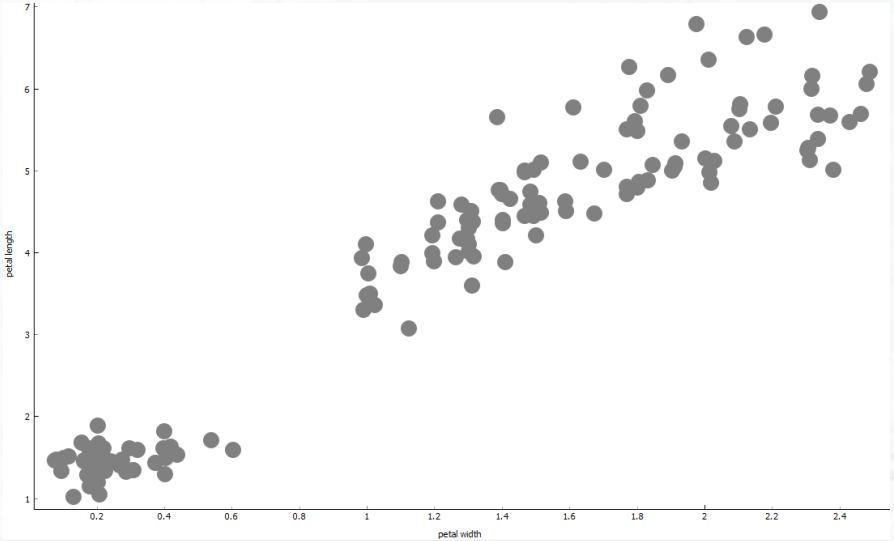
Dentro del aprendizaje supervisado tenemos dos tarea principales:

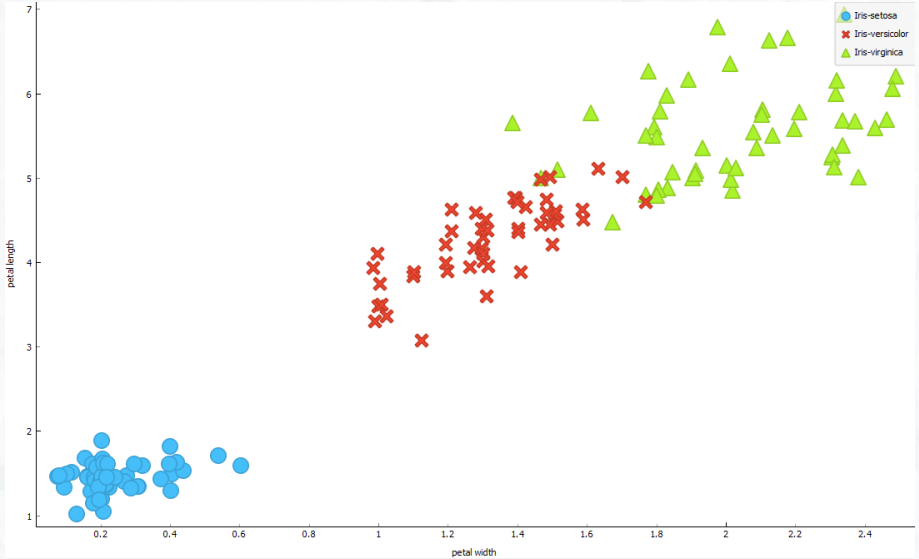
Regresión/Interpolación: En esta tarea la variable objetivo tiene una naturaleza numérica, se busca encontrar el valor de la variable objetivo para pares de valores de atributo donde esta no es conocida.

Clasificación: En esta tarea la variable objetivo tiene una naturaleza categórica, se busca determinar para una muestra, a qué categoría pertenece.

Aprendizaje supervisado

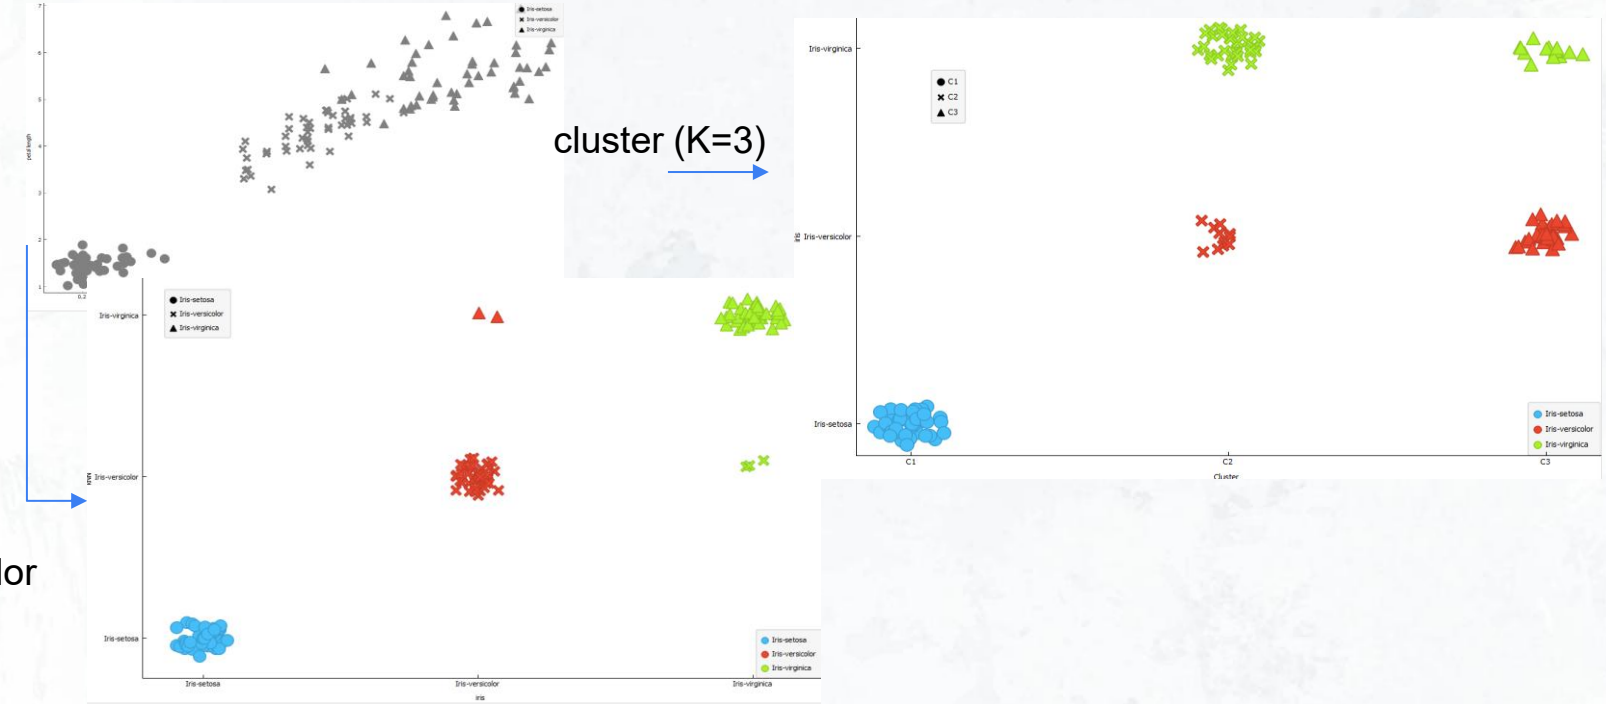
Vs. Aprendizaje no-supervisado





Aprendizaje supervisado

Vs. Aprendizaje no-supervisado



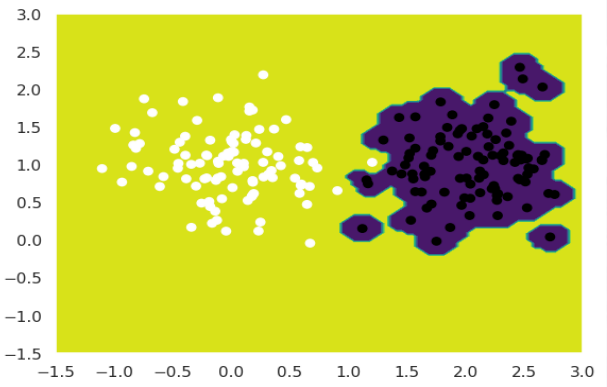
Clasificador

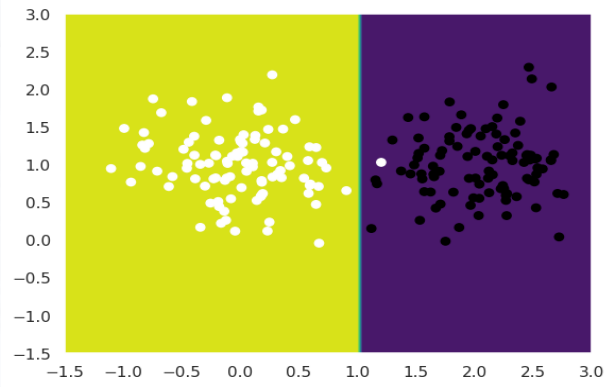
Aprendizaje supervisado

Clasificadores

Entrenar un modelo de análisis de datos **supervisado** implica aprender a separar los datos entre las clases.

Lo anterior significa, en el contexto de clasificación, que el **sistema entrenado** sea capaz de tomar una nueva muestra (una que no se tuvo en cuenta en el entrenamiento del modelo), y ubicarla en la clase correcta.





Aprendizaje supervisado

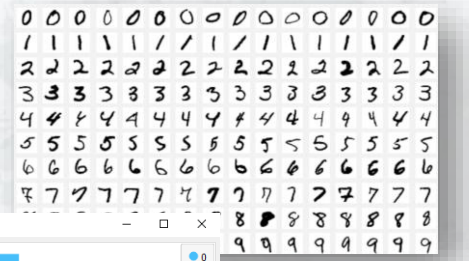
Clasificadores - Ejemplos

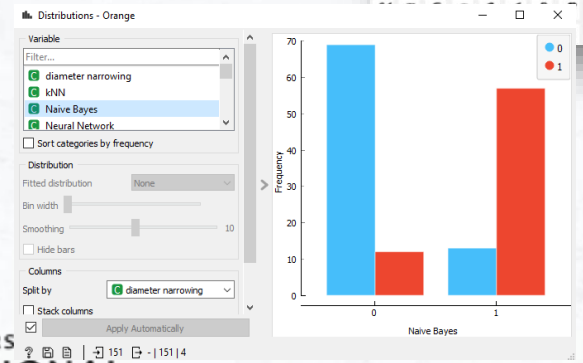
Aplicaciones en donde el **aprendizaje supervisado** puede ayudar a analizar datos.

En el análisis de riesgo crediticio

Riesgo	Nombre	Edad	Reportado antes	Deudas actuales	Casado	Hijos
ALTO	Juan Pérez	34	0	0	0	0
ALTO	Federico González	45	1	2500000	1	1
BAJO	Andrés Correa	42	0	1500000	1	0
ALTO	Manuela Gómez	59	0	0	0	2
BAJO	Pamela Ortiz	38	1	300000	0	1
ALTO	Juliana Gallego	26	1	0	1	0
BAJO	Angelo Medina	42	0	2530000	1	1
BAJO	Pedro Navajas	62	1	0	0	2
¿?	Julian Echeverry	41	0	1800000	1	0

En el reconocimiento de caracteres





En la identificación de sujetos con riesgo de enfermedad

UNAL

Departamento de Eléctrica, Electrónica y Computación
Facultad de Ingeniería y Arquitectura
Sede Manizales

UNIVERSIDAD NACIONAL DE COLOMBIA

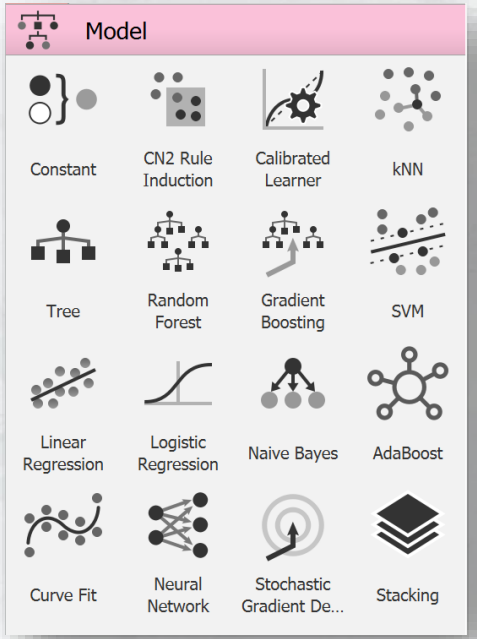
Aprendizaje supervisado

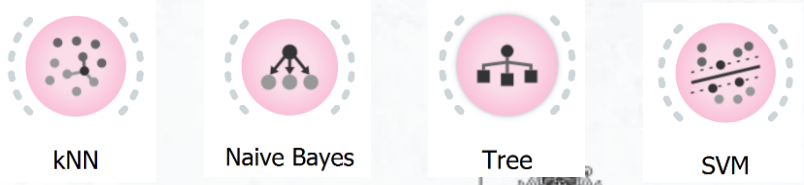
Clasificadores - Entrenamiento

Y ahora bien, ¿cómo se entrena un modelo?

Como hemos dicho, **entrenar** un modelo de análisis de datos supervisado implica aprender a separar los datos entre las clases.

Este aprendizaje se puede realizar mediante distintas funciones. En Orange tenemos varias como el KNN, el Naive Bayes, un árbol o un SVM.





¿Pero qué modelo usar? ¿cómo sé si funciona?

UNAL
Departamento de Eléctrica, Electrónica y Computación
Facultad de Ingeniería y Arquitectura
Sede Manizales
UNIVERSIDAD NACIONAL DE COLOMBIA

Aprendizaje supervisado

Clasificadores - Evaluación

Es decir, ¿cómo sabemos que nuestro **modelo** sí aprendió bien?.

Respuesta: Midiendo su rendimiento.

Cuando los datos son suficientes (pero en realidad **MUY** suficientes) no hay ningún problema.

Se entrena un modelo con un subconjunto de entrenamiento lo suficientemente grande y se evalúa en otro subconjunto de test lo suficientemente grande también.

Pero la realidad es que aunque en el mundo se hable de **big data**, y en este curso hablemos de grandes volúmenes de datos, los datos de "buena calidad", además etiquetados, **escasean** ya que la relación entre las clases (o categorías) suele ser **MUY** desproporcionada.

Ejemplos ¿?

Aprendizaje supervisado

Clasificadores - Rendimiento

En problemas de clasificación es natural **medir el rendimiento** del clasificador en términos de la tasa de error. El clasificador predice cada instancia: si lo hace bien, es un acierto; si lo hace mal, es un fallo.

La **tasa de error** no es más que la proporción de errores en un conjunto total de instancias.
La tasa de acierto se mide como (1 - tasa de error).

Ahora bien, a nosotros nos interesa medir el rendimiento del sistema en datos nuevos y no el rendimiento que tuvo empleando datos ya conocidos.

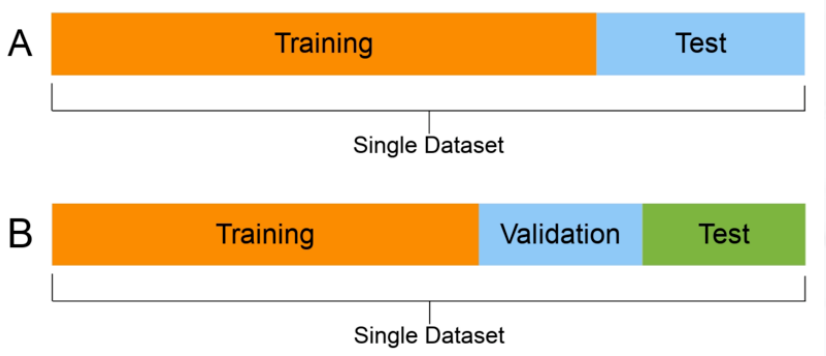
Ya conocemos la clase a la que pertenece cada instancia del conjunto de entrenamiento, de hecho, esa es la razón por la cual las usamos para entrenar el sistema. Por tanto, el rendimiento medido sobre los datos de entrenamiento no es un buen indicador de la tasa de error en datos nuevos.

Aprendizaje supervisado

Clasificadores - Rendimiento

Para evaluar el **error** se hace necesario entonces tener un conjunto independiente que no haya formado parte del entrenamiento del clasificador → conjunto de test.

Asumimos que ambos conjuntos (training y test) son conjuntos representativos del problema bajo estudio.



Existen casos donde existe un tercer conjunto llamado de Validation (validación) el cual se usa en el proceso de entrenamiento para sintonizar/encontrar los mejores parámetros del modelo que estemos usando.

Aprendizaje supervisado

Clasificadores - Rendimiento

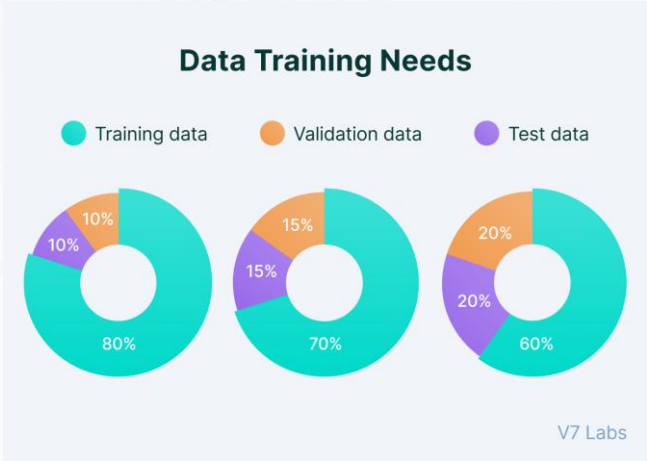
Dos premisas evidentes:

Entre más grande sea el conjunto de training, mejor entrenado quedará el clasificador (aunque la precisión podría empezar a decrecer cuando se sobrepasa cierto volumen de datos de entrenamiento).

Entre más grande sea el conjunto de test, la estimación del error será más precisa.

El problema aparece cuando no hay datos suficientes.

¿Cómo los repartimos entonces?



UNAL
Departamento de Eléctrica, Electrónica y Computación
Facultad de Ingeniería y Arquitectura
Sede Manizales
UNIVERSIDAD NACIONAL DE COLOMBIA

Aprendizaje supervisado

Clasificadores - Validación

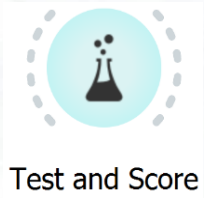
Orange nos ofrece distintas alternativas. Veamos en qué consiste cada una de ellas.

Muestreo aleatorio

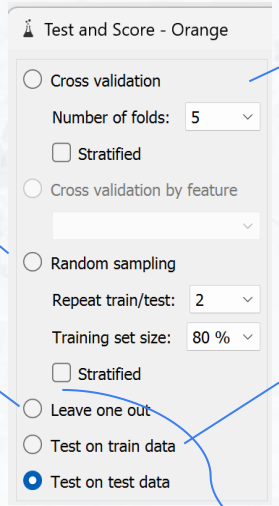
Validación cruzada

Leave one out (dejar uno afuera)

Probar en datos de entrenamiento (sirve para evaluar sobreajustes)



Test and Score



¿Qué significa hacer validación estratificada?

UNAL

Departamento de Eléctrica, Electrónica y Computación
Facultad de Ingeniería y Arquitectura
Sede Manizales

UNIVERSIDAD NACIONAL DE COLOMBIA

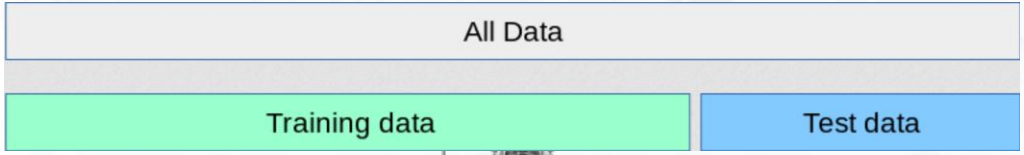
Aprendizaje supervisado

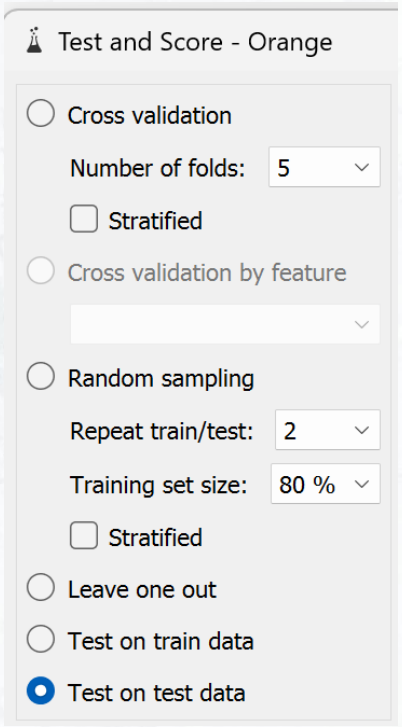
Clasificadores - Muestreo aleatorio

Este escoge un porcentaje de los **datos para entrenamiento** y el resto para test. Comúnmente se usa una proporción de 70% entrenamiento, 30% test.

Existe la opción de stratified. La cual garantiza que en esa selección aleatoria de los conjuntos de entrenamiento y prueba, se mantengan las mismas proporciones de muestras de cada clase, que las que encontrábamos en el dataset original. Es decir, si en general tenemos 100 muestras de una clase y 50 de otra, en el conjunto de entrenamiento habrá el doble de muestras de la clase 1 que la clase 2

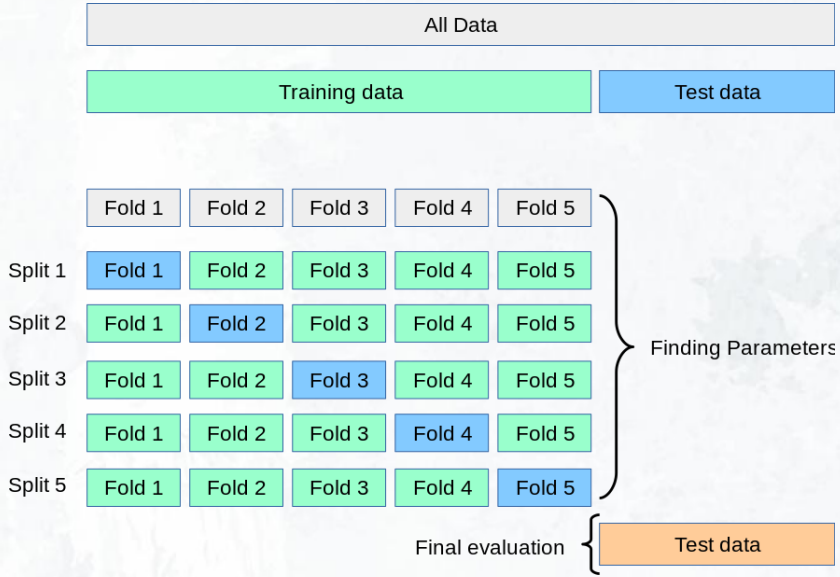
Se puede establecer un número de repeticiones del proceso de validación.





Aprendizaje supervisado

Clasificadores - K-folds



Esta es una metodología que busca fragmentar la base de datos en k conjuntos mutuamente excluyentes (no comparten muestras). K-1 de los conjuntos se utilizan para **Training** (entrenamiento) y se reserva uno para **Test** (prueba). Con los primeros se hace el entrenamiento del modelo, y con el segundo se hace cálculo de una tasa de error o de una medida de **rendimiento**.

Stratified k-folds: Este escoge k conjuntos diferentes mutuamente excluyentes.

Garantiza que en cada uno de los conjuntos (folds) se encuentre la misma proporción de las clases.

Aprendizaje supervisado

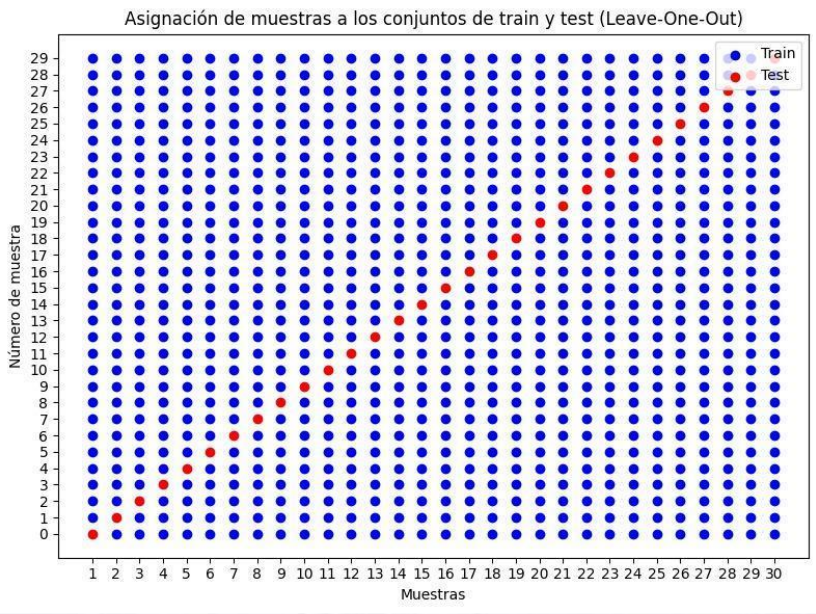
Clasificadores - Leave One-Out

Este se usa en especial cuando se tienen muy pocos datos.

Este **separa una muestra** de la base de datos y se procede a entrenar con el resto. Observe que el conjunto de test siempre tiene una muestra. Luego se evalúa el modelo en la muestra de test.

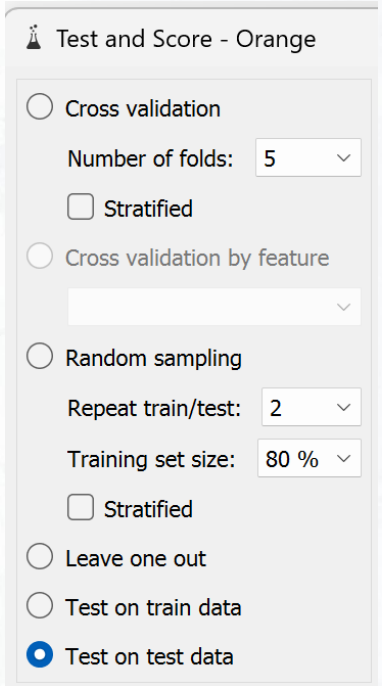
Tendremos tantos valores de evaluación/testeo como muestras en nuestra base.

Es el caso extremo del K-folds. Donde K es el mismo número de muestras.



Aprendizaje supervisado

Clasificadores - Test en Train/Test data



Cuando tenemos suficientes datos se puede definir un set de test fijo y realizar la evaluación sobre este.

También puede ser interesante efectuar la evaluación sobre el set de entrenamiento.

Detectar underfitting. El sistema tiene un rendimiento muy pobre directamente con el set de entrenamiento. Generalmente decimos que el rendimiento es pobre y seguimos buscando alternativas.

Detectar overfitting. El sistema tiene un rendimiento muy bueno con el set de entrenamiento, pero muy bajo con el de test. Es posible que haya " memorizado" sus datos y que ya no sepa generalizar. Este es un problema real que puede llevar a engaño

Aprendizaje supervisado

Clasificación - Evaluando rendimiento

Evaluar el conjunto de test requiere definir la **función de costo** a utilizar.

Algunas opciones comunes:

- Accuracy
- Precision y recall
- F1 score
- AUC

Al final se trata de estimar cuánto acierta o falla el modelo. Y para ello hay que tener en cuenta todo lo que implique acertar y todo lo que implique fallar.

Acertar: Afirmar que se pertenece a una clase y que sea cierto (True Positive)
Acertar: Afirmar que NO se pertenece a una clase y que sea cierto (True Negative)
Fallar: Afirmar que se pertenece a una clase y que NO sea cierto (False Positive)
Fallar: Afirmar que NO se pertenece a una clase y que NO sea cierto (False Negative)

Aprendizaje supervisado

Clasificadores - Costos en evaluación

La clasificación entre diversas clases **no siempre arroja el mismo costo**, y no todos los fallos tienen que ser igual de graves.

Cuando se evalúa si dar un préstamo o no: es mayor el costo de darlo a quien no lo puede pagar, que negarlo a quien sí lo puede pagar.

En diagnóstico médico: es mayor el costo de dar un buen diagnóstico a quien está enfermo (falso negativo) que dar un mal diagnóstico a quien está sano (falso positivo).

		Predicted Class	
		yes	*no*
Actual Class	*yes*	true positive	false negative
	no	false positive	true negative



Matriz de confusión

Aprendizaje supervisado

Clasificadores - Accuracy, Precisión y Recall

		Predicted Class	
		yes	*no*
Actual Class	*yes*	true positive	false negative
	no	false positive	true negative

Accuracy o exactitud: Se centra en las predicciones correctas.

El rendimiento del clasificador se mide como

$$accuracy = \frac{TP + TN}{TP + TN + FP + FN}$$

y el error es igual a 1 – accuracy .

Precisión: proporción correcta del total que se estimaron como pertenecientes a la clase

Recall o exhaustividad: proporción correcta estimada del total real de eventos de la clase.

Cuando se analizan los resultados de esta forma, puede ser necesario calcular la precisión y la exhaustividad (recall).

$$Precision = \frac{TP}{TP+FP} \qquad Recall = \frac{TP}{TP+FN}$$

Aprendizaje supervisado

Clasificadores - F-score

Valor F-score

- Esta es una métrica que mide la precisión que tiene un test.
- Básicamente, es una medida ponderada (i.e. media armónica) de la precision y el recall.
- De manera general, es igual a:

$$F_\beta = (1+\beta^2)\frac{Precision \cdot Recall}{(\beta^2 \cdot Precision) + Recall} = \frac{(1+\beta^2)\cdot TP}{(1+\beta^2)\cdot TP + \beta^2 \cdot FN + FP}$$

Para el caso en que se quiere dar igual peso a ambas medidas, se hace $\beta = 1$, obteniendo la medida F_1 score

$$F_1 = 2 \cdot \frac{Precision \cdot Recall}{Precision + Recall} = \frac{2 \cdot TP}{2 \cdot TP + FN + FP}$$

Aprendizaje supervisado

Clasificadores - Paradoja del accuracy

Pongamos como **ejemplo** un sistema de análisis de datos encargado de reconocer correos electrónicos de **spam**.

Una versión de este sistema entrega los siguientes resultados:

		Clasificados	
		SPAM	**No SPAM**
Etiquetas reales	**SPAM**	10 (TP)	15 (FN)
	No SPAM	25 (FP)	100 (TN)

El accuracy de este sistema sería (10 + 100)/(150) = 73.3%. A simple vista, parece un sistema decente.

Imaginemos que montamos un sistema DUMMY que va a **clasificar todo** como si fuera NO SPAM y estos fueran sus resultados:

		Clasificados	
		SPAM	**No SPAM**
Etiquetas reales	**SPAM**	0 (TP)	25 (FN)
	No SPAM	0 (FP)	125 (TN)

El accuracy de este sistema sería (0 + 125)/150 = 83.3%

Accuracy paradox : El accuracy en muchos casos no refleja la bondad de los sistemas.

Aprendizaje supervisado

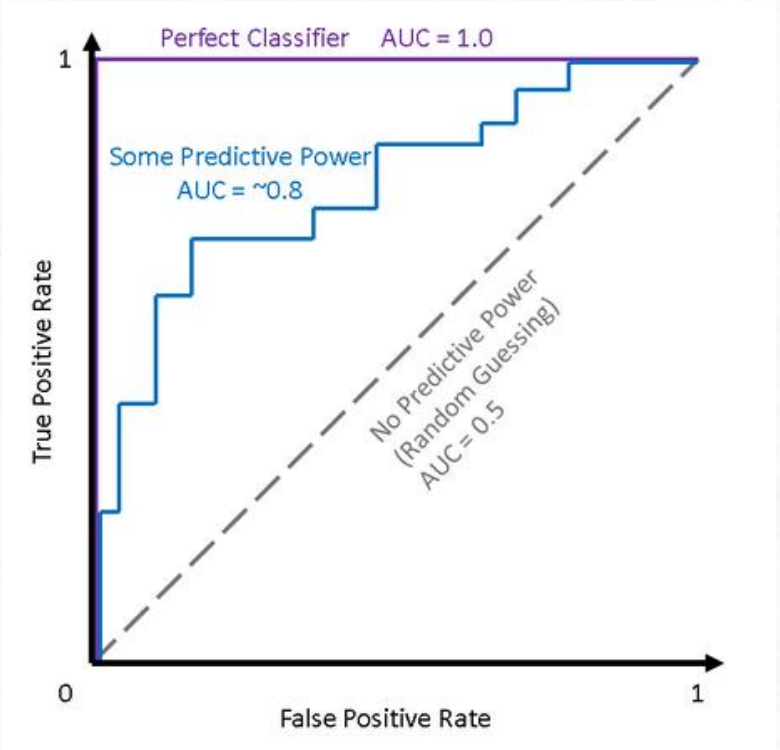
Clasificadores - ROC y AUC

Se utiliza en algoritmos de clasificación binaria, es decir, con dos clases.

Se trata de ***maximizar*** el área bajo la curva de la relación entre ***tasa de verdaderos positivos (TPR)*** o sensibilidad (que se equivale al recall) contra ***la tasa de falsos positivos (FPR)***

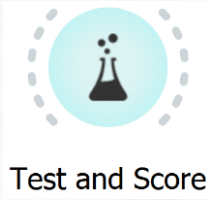
$$FPR = \frac{FP}{FP + TN} \qquad TPR = \frac{TP}{TP + FN}$$

Nos sirve como comparativa en distintos clasificadores. Un área bajo la curva (AUC) mayor representará un clasificador más exacto (con un ratio pequeño de falsos positivos y uno alto de verdaderos positivos)



Aprendizaje supervisado

Clasificadores - Testeando modelos



Test and Score - Orange

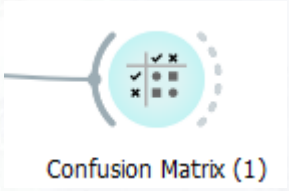
- Cross validation
  - Number of folds: 5
  - Stratified
- Cross validation by feature
- Random sampling
  - Repeat train/test: 2
  - Training set size: 66 %
  - Stratified
- Leave one out

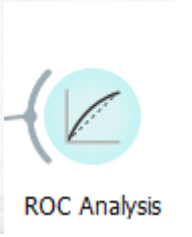
Evaluation results for target: (None, show average over classes)

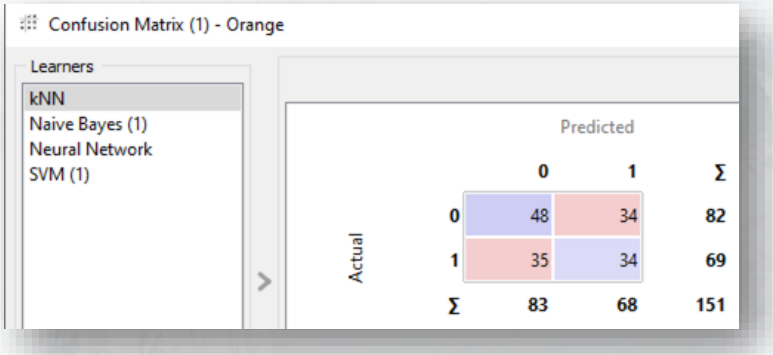
Model	AUC	CA	F1	Precision	Recall
kNN	0.574	0.543	0.543	0.543	0.543
SVM	0.879	0.828	0.828	0.828	0.828
Neural Network	0.860	0.762	0.761	0.761	0.762
Naive Bayes	0.887	0.834	0.835	0.835	0.834

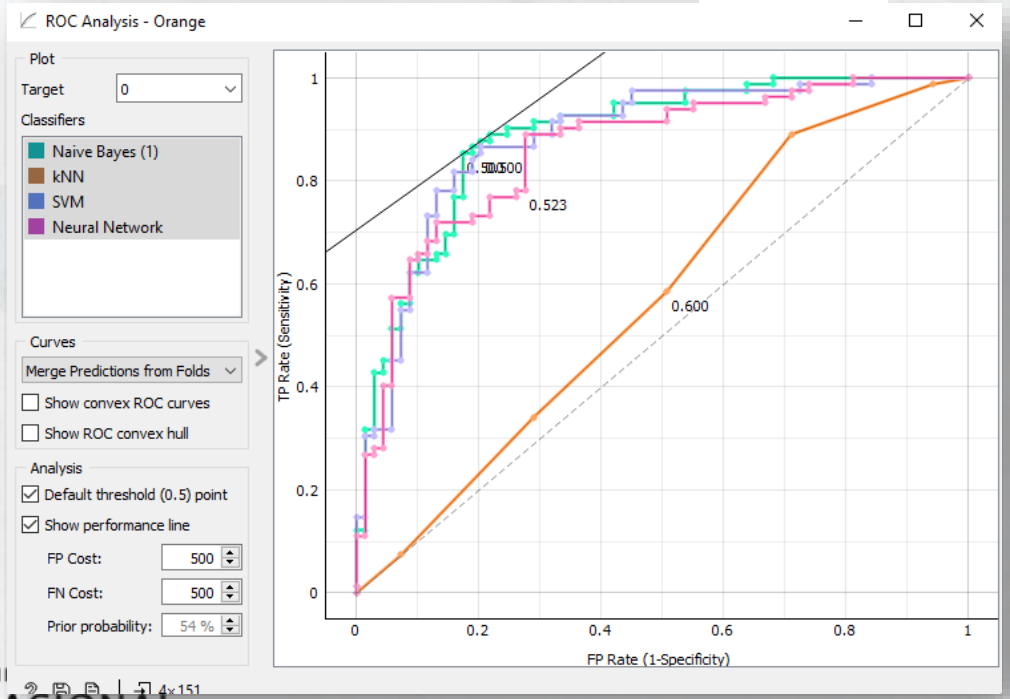
Aprendizaje supervisado

Clasificadores - Testeando modelos





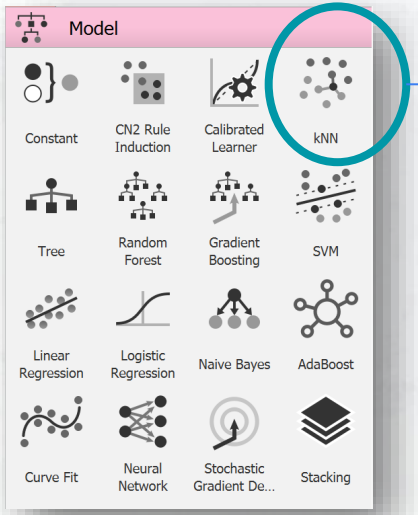


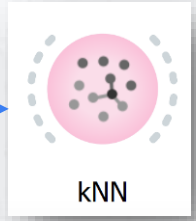


Aprendizaje supervisado

Clasificadores - Algoritmos clásicos

Y ahora que sabemos cómo medir si el algoritmo funciona veamos alguno





kNN

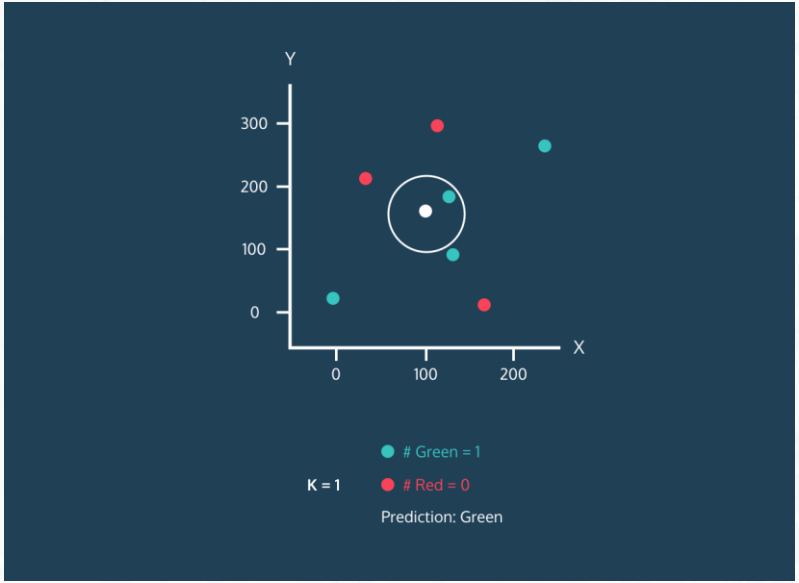
Predict according to the nearest training instances.

The **kNN** widget uses the kNN algorithm that searches for k closest training examples in feature space and uses their average as prediction.

Aprendizaje supervisado

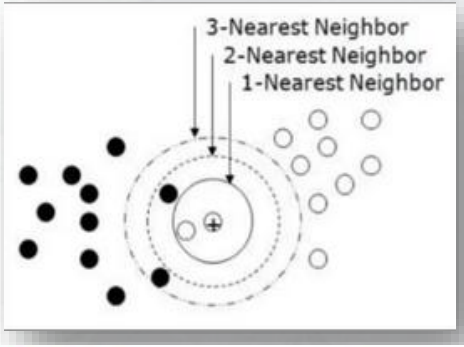
Clasificadores - K-nn

- K- Nearest Neighbours (K vecinos más cercanos)
- Uno de los más simples.
- Requiere de una **noción de distancia** para trabajar.
- Se basa en asumir que dos muestras a corta distancia son similares.
- No “aprende” la estructura subyacente en etapa de entrenamiento sino que decide en la etapa de test con un criterio de mayoría.



K-NN

Algoritmo



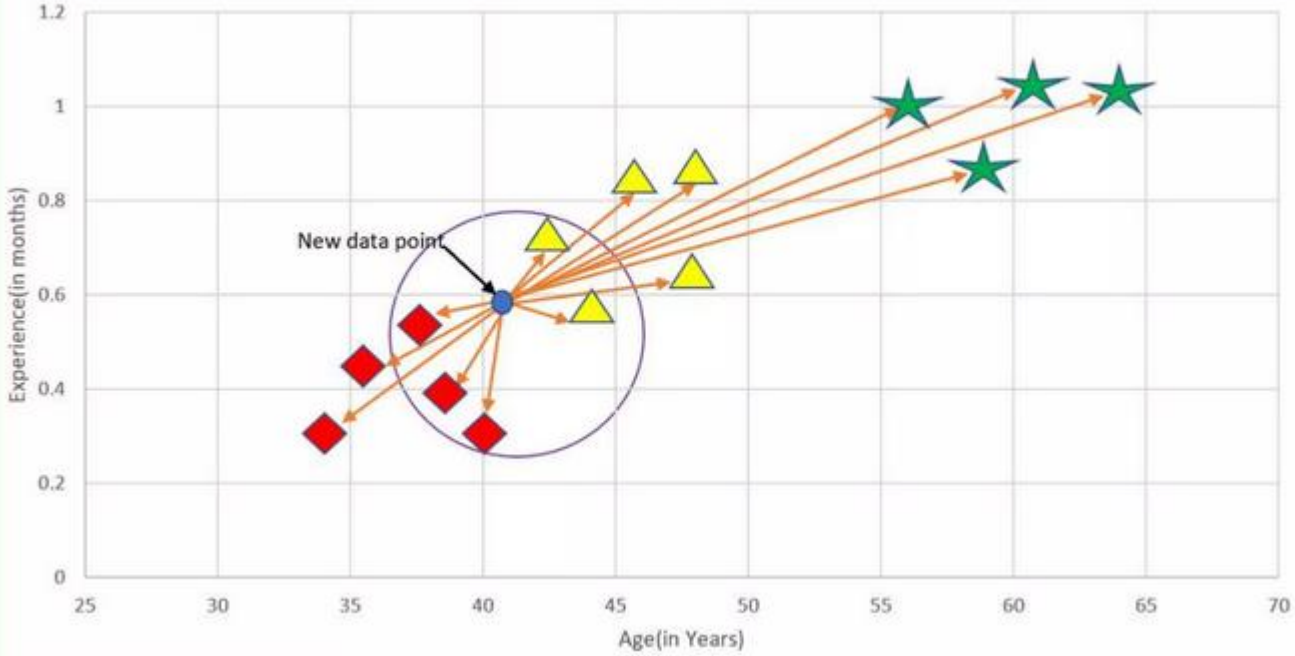


1. Calcula la distancia entre el ítem a clasificar y el resto de ítems del dataset.
2. Selecciona los K elementos más cercanos según el criterio de distancia establecido (K debe establecerse previamente)
3. Busca la categoría mayoritaria entre los K vecinos y se asigna el nuevo item a ese mismo grupo.

A tener en cuenta: El valor de **K** es importante para definir el valor de un punto nuevo, sobre todo si este se sitúa en las fronteras entre clases.

K-NN

Algoritmo



Con ***cinco vecinos*** la clase para el nuevo dato será la ***roja***

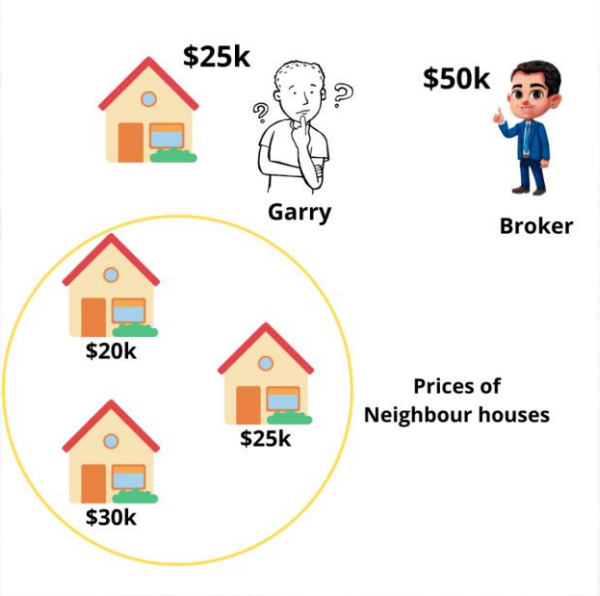
¿Y si cambio el número de vecinos?

K-NN

Aplicaciones

Motores de recomendación al asignar a un nuevo usuario a un perfil conocido.
Predicción en el mercado financiero (riesgos crediticios, previsiones de mercado, lavado de activos...)
Cuidado de la salud al clasificar por ejemplo riesgos clínicos
Reconocimiento de patrones en datos de texto o imágenes
Preprocesamiento de datos (imputación de datos faltantes)

...Entre otros...



K-NN

Ventajas y desventajas

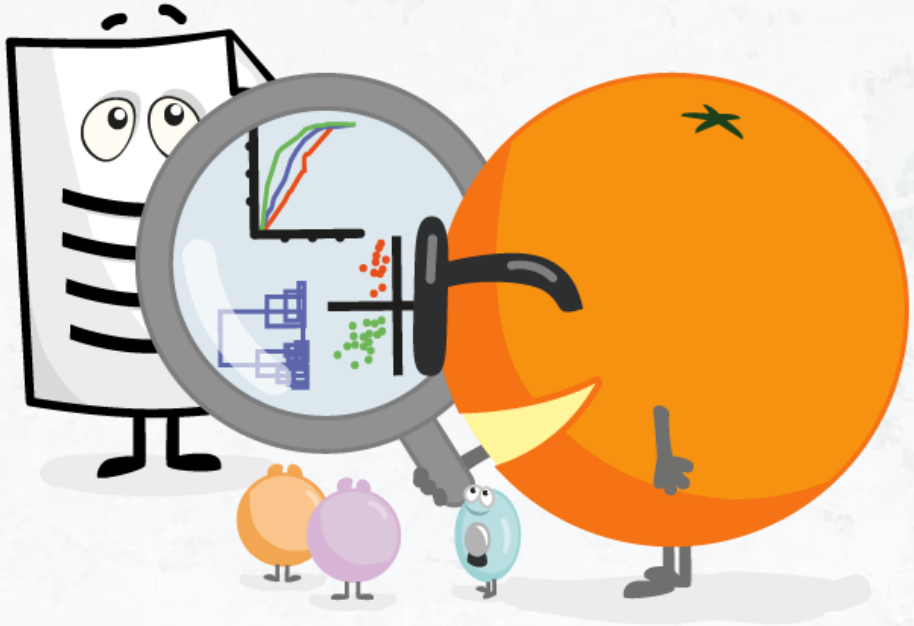


- Es sencillo de entender y de implementar, por lo que se vuelve uno de los primeros a aprender y utilizar.
- Se adapta fácilmente: A medida que se agregan nuevas muestras de entrenamiento, el algoritmo se ajusta para tener en cuenta cualquier dato nuevo, ya que todos los datos de entrenamiento se almacenan en la memoria.
- Pocos hiperparámetros: KNN solo requiere un valor k y una métrica de distancia.



- Algoritmo perezoso (lazy): Todo el proceso se realiza en test por lo que debe pasar por el cálculo de la distancia con todas las muestras => Ineficiencia, más memoria.
- Maldición de la dimensionalidad: El proceso depende tanto de la distancia que una alta dimensionalidad en los datos lo puede afectar => Reducción de dimensionalidad.
- Propenso al sobreajuste/suavizado: La predicción solo depende de un puñado de vecinos cercanos. Demasiados vecinos pueden suavizar la predicción tanto que afecte al rendimiento. Demasiados pocos pueden derivar en sobreajuste.

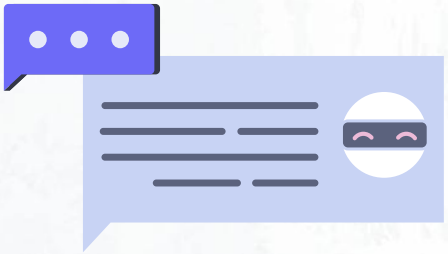
Ejercicios prácticos



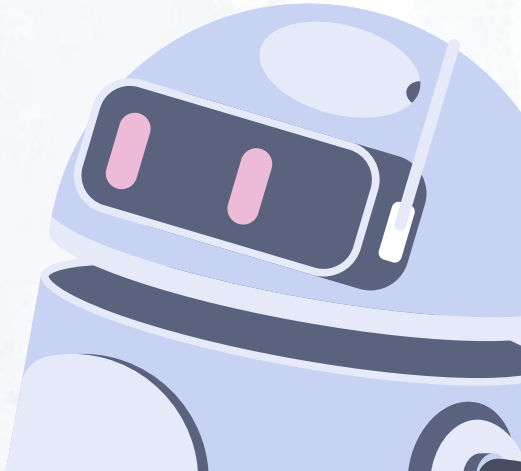
UNAL
Departamento de Eléctrica, Electrónica y Computación
Facultad de Ingeniería y Arquitectura
Sede Manizales
UNIVERSIDAD NACIONAL DE COLOMBIA

Gracias !

dfcollazosh@unal.edu.co







UNAL

Departamento de Eléctrica, Electrónica y Computación
Facultad de Ingeniería y Arquitectura
Sede Manizales

UNIVERSIDAD
NACIONAL
DE COLOMBIA