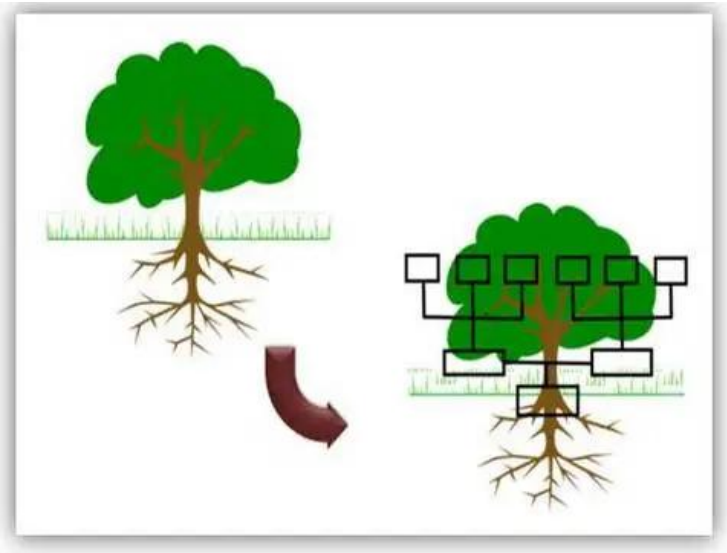
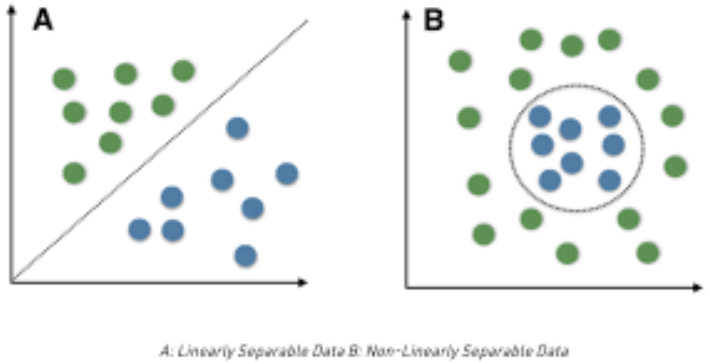
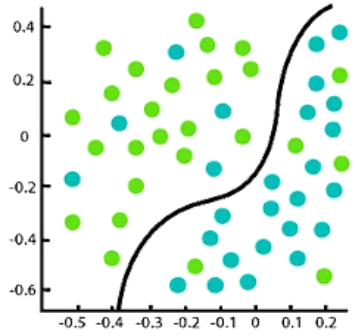
Árbol de decisión - Motivación

- Algoritmo basado en árboles.
- Potencian los modelos predictivos con alta precisión, estabilidad y **facilidad de interpretación**.
- Mapean bastante bien las relaciones no lineales.
- Son adaptables para resolver cualquier tipo de problema (clasificación o regresión).

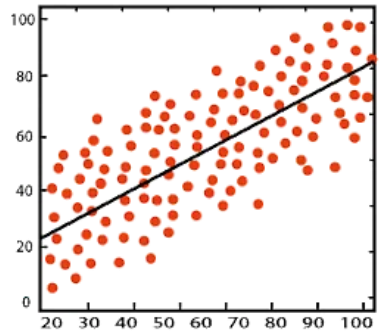




A: Linearly Separable Data B: Non-Linearly Separable Data

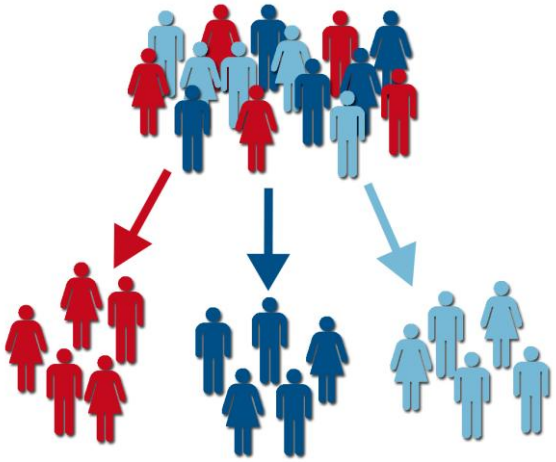


Classification



Regression

Árbol de decisión - Introducción



SEGMENTACIÓN DE CLIENTES



PREDICCIÓN PRECIOS DE VIVIENDAS

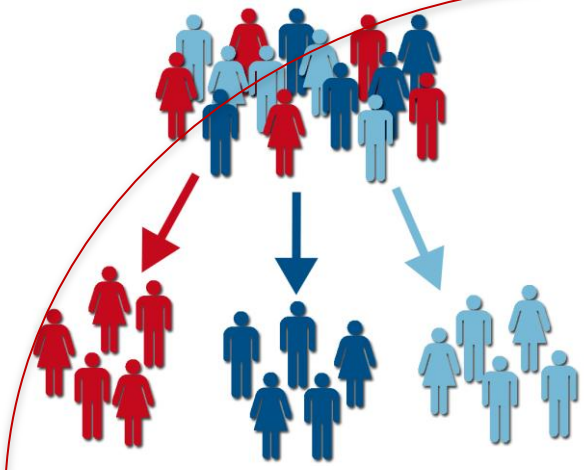


IDENTIFICACIÓN DE SEGUROS RIESGOSOS



PREDICCIÓN DE CLIMA

Árbol de decisión - Introducción



SEGMENTACIÓN DE CLIENTES



PREDICCIÓN PRECIOS DE VIVIENDAS

Problemas de clasificación

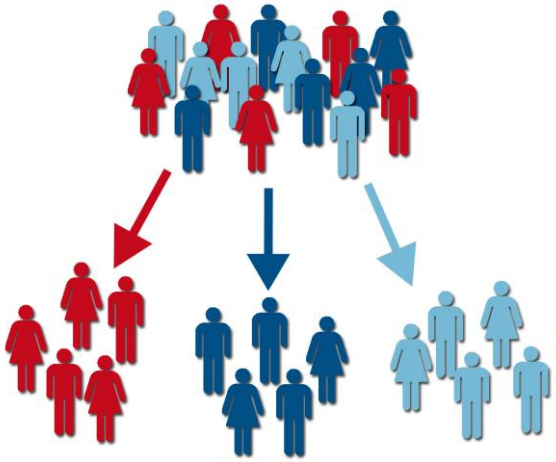


IDENTIFICACIÓN DE SEGUROS RIESGOSOS



PREDICCIÓN DE CLIMA

Árbol de decisión - Introducción



SEGMENTACIÓN DE CLIENTES



PREDICCIÓN PRECIOS DE VIVIENDAS



IDENTIFICACIÓN DE SEGUROS RIESGOSOS

Problemas de regresión

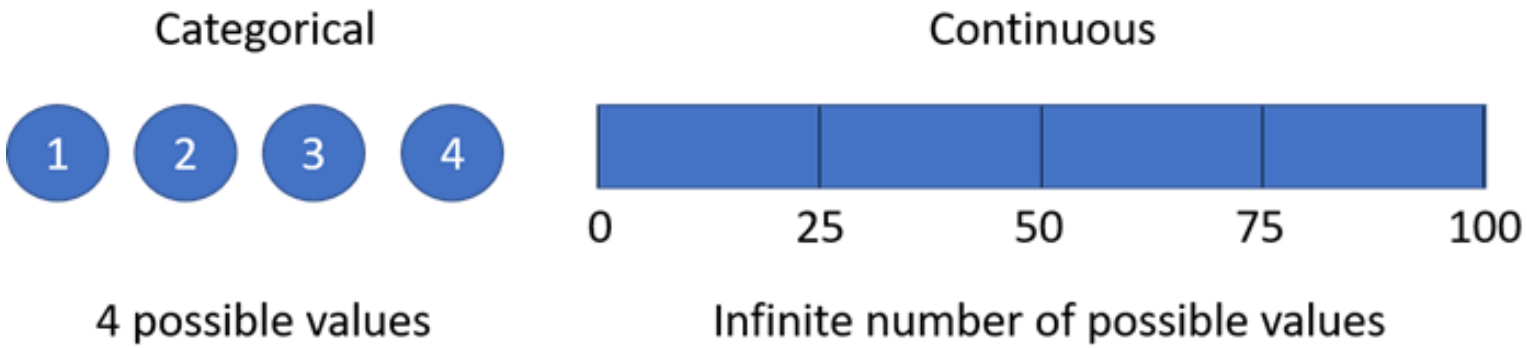


PREDICCIÓN DE CLIMA

Árbol de decisión - Introducción

- Regresión: predecir los valores de una variable continua a partir de una o más variables predictoras categóricas .

- Clasificación: predecir los valores de una variable dependiente categórica (clase, pertenencia a grupos, etc.) a partir de una o más variables predictoras continuas y / o categóricas.



Forma de variables dependientes para el árbol de decisión categórico y continuo.

Árbol de decisión en ML

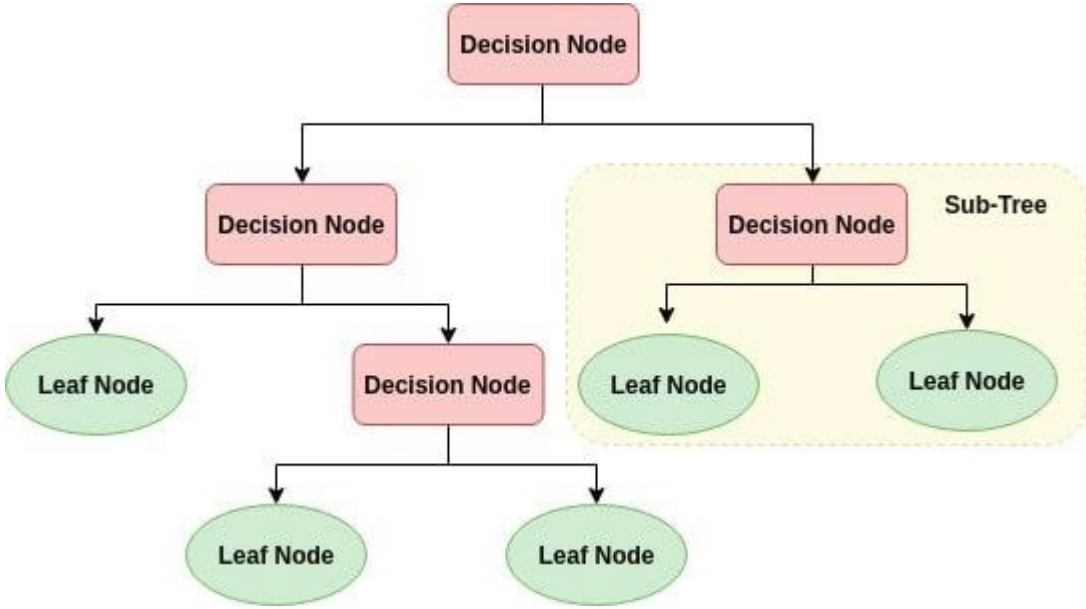
- Diagrama de flujo donde un **nodo interno** representa una característica (o atributo), **la rama** representa una regla de decisión y cada **nodo hoja** representa el resultado.

- Nodo superior => Nodo raíz.

- Clasifican las muestras con **enfoque de arriba hacia abajo.**

- Cada nodo en el árbol actúa como un caso de prueba para algún atributo, y cada borde que desciende de ese nodo corresponde a una de las posibles respuestas al caso de prueba.

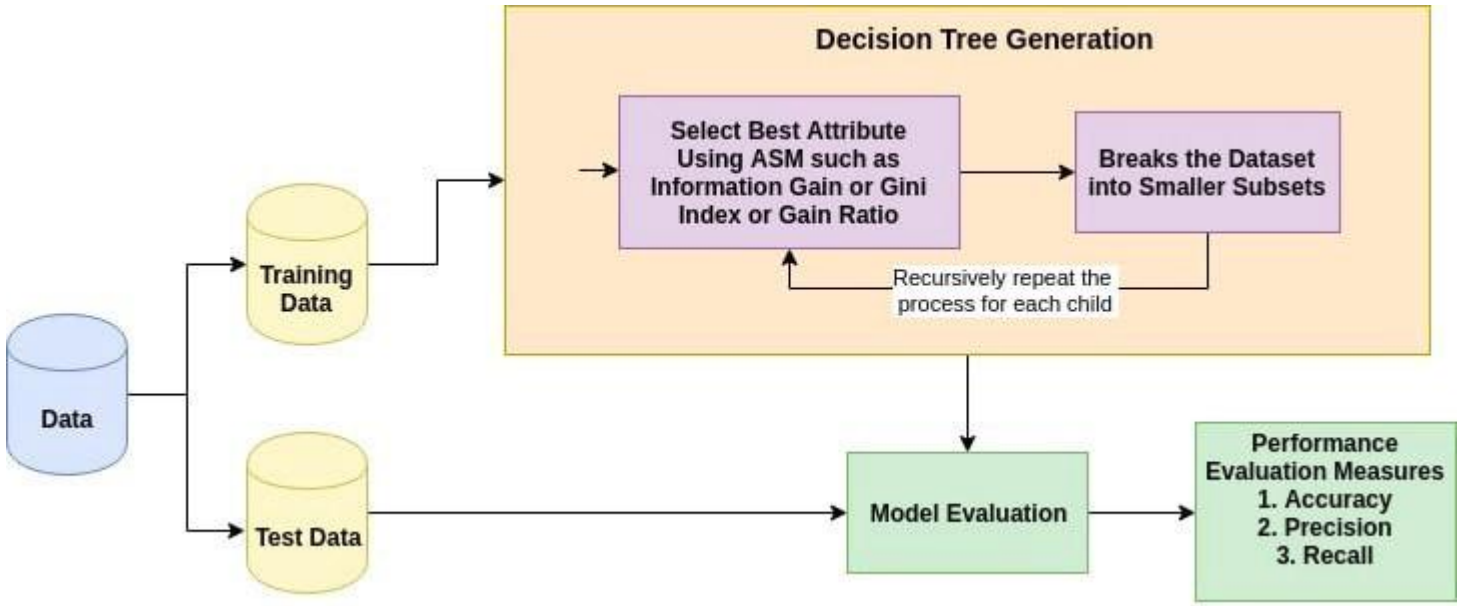
- Este proceso es **recursivo** y se repite para cada subárbol enraizado en los nuevos nodos.



Árbol de decisión - Terminología

1. **Nodo raíz (nodo de decisión superior):** Representa a **toda la población o muestra** y esto se divide en dos o más conjuntos homogéneos.
2. **División:** Es un proceso de división de un nodo en dos o más subnodos.
3. **Nodo de decisión:** Cuando un subnodo se divide en subnodos adicionales, se llama **nodo de decisión**.
4. **Nodo de hoja / terminal:** Los **nodos sin hijos** (sin división adicional) se llaman Hoja o nodo terminal.
5. **Poda:** Cuando reducimos el tamaño de los árboles de decisión eliminando nodos (opuesto a la división), el proceso se llama **poda**.
6. **Rama / Subárbol:** Una subsección del árbol de decisión se denomina rama o subárbol.
7. **Nodo padre e hijo:** Un nodo, que se divide en subnodos se denomina **nodo principal de subnodos**, mientras que los subnodos son hijos de un nodo principal.

Árbol de decisión - ¿Cómo funciona?

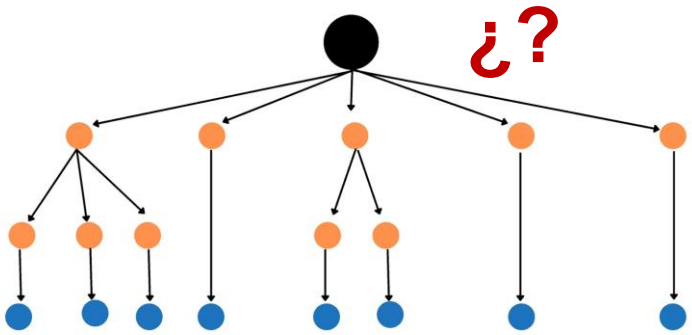


1. Seleccione el **mejor atributo** utilizando Medidas de selección de atributos (**ASM**) para dividir los registros.

1. Haga que ese atributo sea un nodo de decisión y **divida el conjunto de datos** en subconjuntos más pequeños recursivamente para cada nodo hijo hasta que una de las condiciones coincida:

    a. Todas las tuplas pertenecen al mismo valor de atributo.
    b. No quedan más atributos.
    c. No hay más instancias.

Árbol de decisión - ASM



- Ganancia de información
- GINI

La ASM es una heurística para seleccionar el criterio de división que divide los datos de la mejor manera posible.

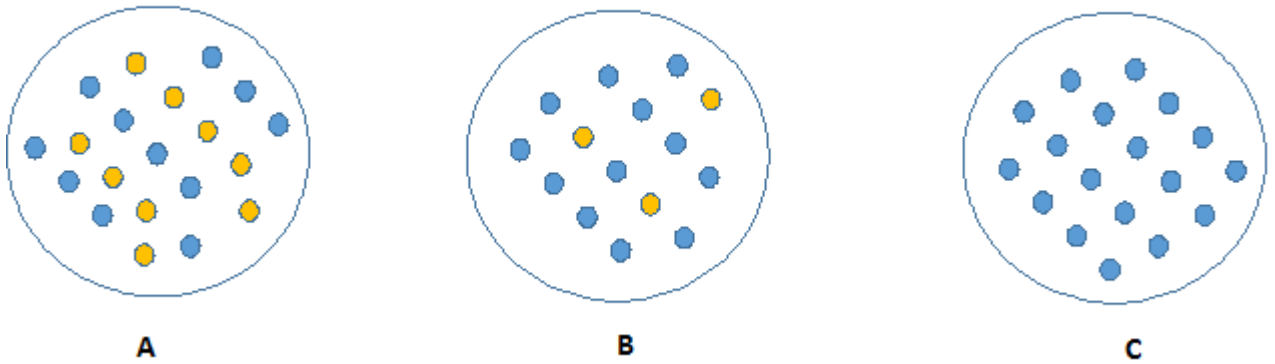
ASM proporciona un rango para cada característica (o atributo) al explicar el conjunto de datos dado. El atributo de **mejor puntuación** se seleccionará como un atributo de división (nodo decisión).

En el caso de un atributo de valor continuo, los puntos de división para las ramas también deben definirse.

Árbol de decisión - Ganancia de información

La **ganancia de información** es una propiedad estadística que mide qué tan bien un atributo dado separa las muestras de entrenamiento de acuerdo con sus clasificación objetivo.

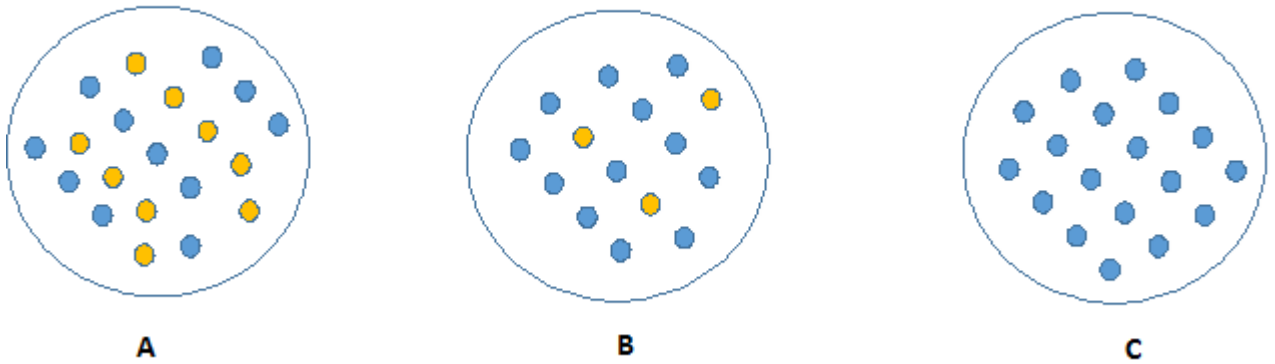
¿Qué nodo se puede describir fácilmente?



Árbol de decisión - Ganancia de información

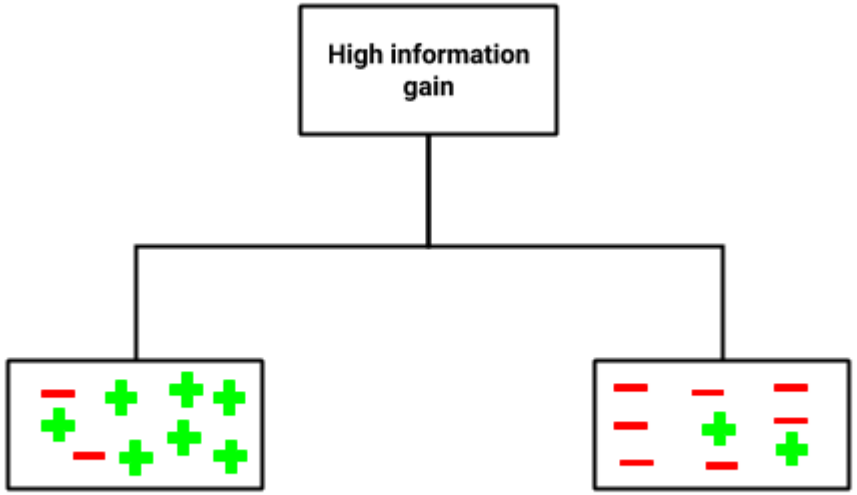
La **ganancia de información** es una propiedad estadística que mide qué tan bien un atributo dado separa las muestras de entrenamiento de acuerdo con sus clasificación objetivo.

¿Qué nodo se puede describir fácilmente?

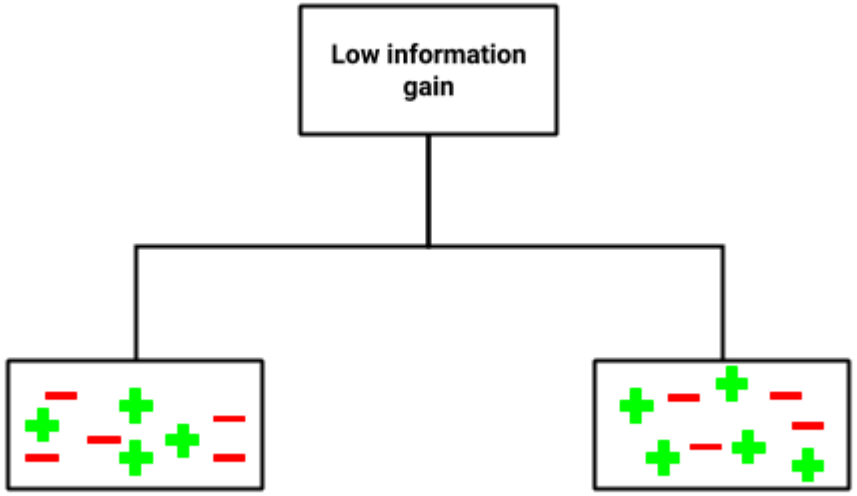


R/ **C** porque requiere menos información ya que todos los valores son similares (nodo puro). Por otro lado, **B** requiere más información para describirlo (menos impuro) y **A** requiere la información máxima (más impuro).

Árbol de decisión - Ganancia de información



Un atributo con alta GI divide los datos en grupos con un número desigual de positivos y negativos y, como resultado, ayuda a separarlos entre sí.

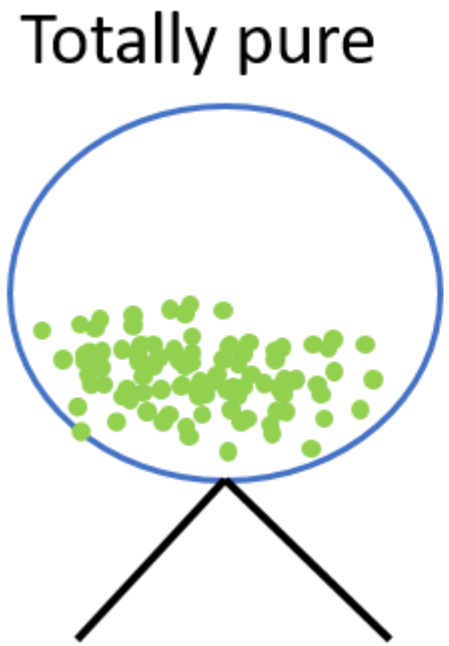


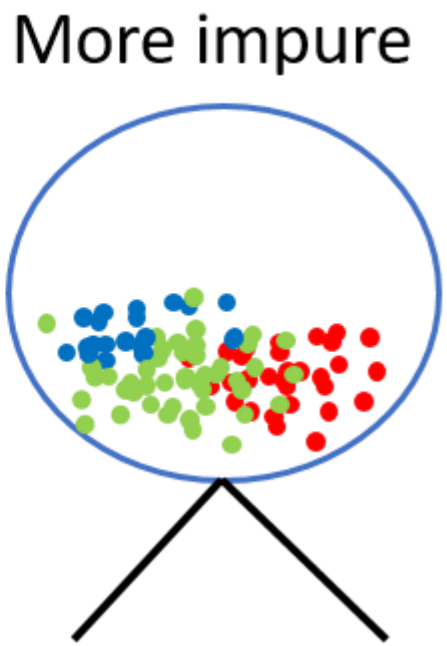
Un atributo con baja GI divide los datos de manera relativamente uniforme y como resultado la decisión no es clara.

Para poder calcular la ganancia de información, primero tenemos que introducir el término **entropía** de un conjunto de datos.

Árbol de decisión - Entropía

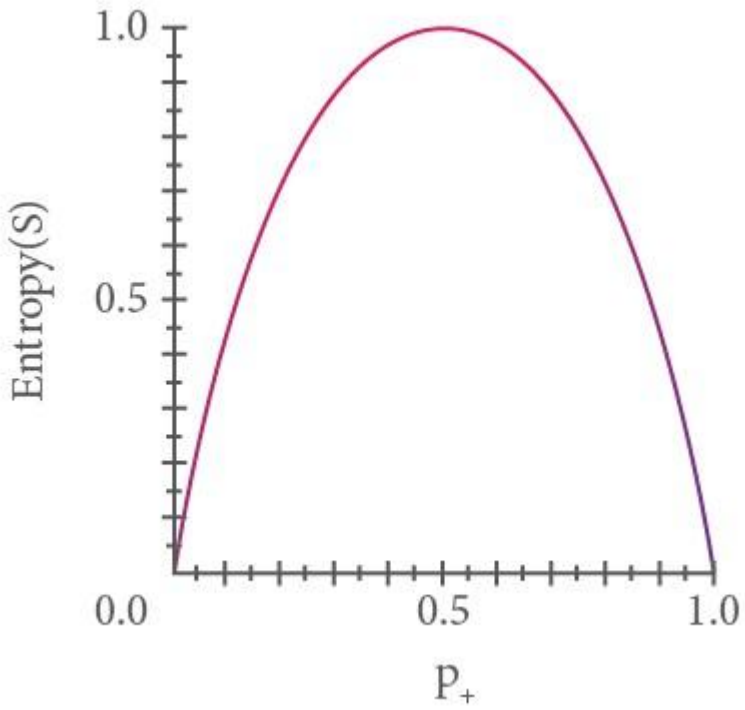
- [Shannon] - La entropía, que **mide la impureza del conjunto de entrada**.
- En física y matemáticas, la entropía se conoce como aleatoriedad o impureza en el sistema.
- En teoría de la información, se refiere a la impureza en un grupo de muestras.
- La ganancia de información es una disminución de la entropía.





Ejemplo: Rueda de lotería

Árbol de decisión - Entropía



La figura muestra la forma de la función de entropía en relación con una clasificación booleana, ya que la entropía varía entre 0 y 1.

- Si todos los miembros son positivos, *Entropía (S)* = 0.
- La entropía es 1 cuando la muestra contiene el mismo número de ejemplos positivos y negativos.
- Si la muestra contiene un número desigual de ejemplos positivos y negativos, la entropía está entre 0 y 1.

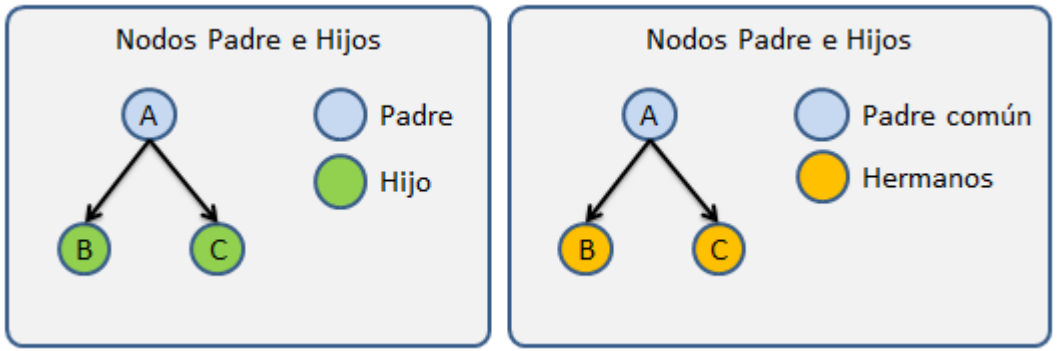
$$\text{Entropy} = -p \log_2 p - q \log_2 q$$

Aquí p y q es la probabilidad de éxito y fracaso respectivamente en ese nodo. **Cuanto menor sea la entropía, mejor será.**

Árbol de decisión - Entropía

GANANCIA DE INFORMACIÓN:

GI = Entropía(Nodo padre) - [Avg Entropía (Nodo hijo)]



CÁLCULO DE LA ENTROPÍA PARA UNA DIVISIÓN:

1. Calcular la entropía del nodo principal.
2. Calcular la entropía de cada nodo individual de división y calcular el promedio ponderado de todos los subnodos disponibles en una división.

Árbol de decisión - Entropía

Ejemplo:

- Digamos que tenemos una muestra de 30 estudiantes con tres variables Sexo (Niño / Niña), Clase (IX / X) y Altura (5 a 6 pies). **15 de estos 30** juegan al ping-pong en el tiempo libre.

Objetivo:

- Crear un modelo para predecir quién jugará al ping-pong durante un período de ocio.

En este problema, necesitamos segregar a los estudiantes que juegan al ping-pong en su tiempo libre según una variable de entrada altamente significativa entre los tres.





¿Cuál es la entropía para el nodo principal?

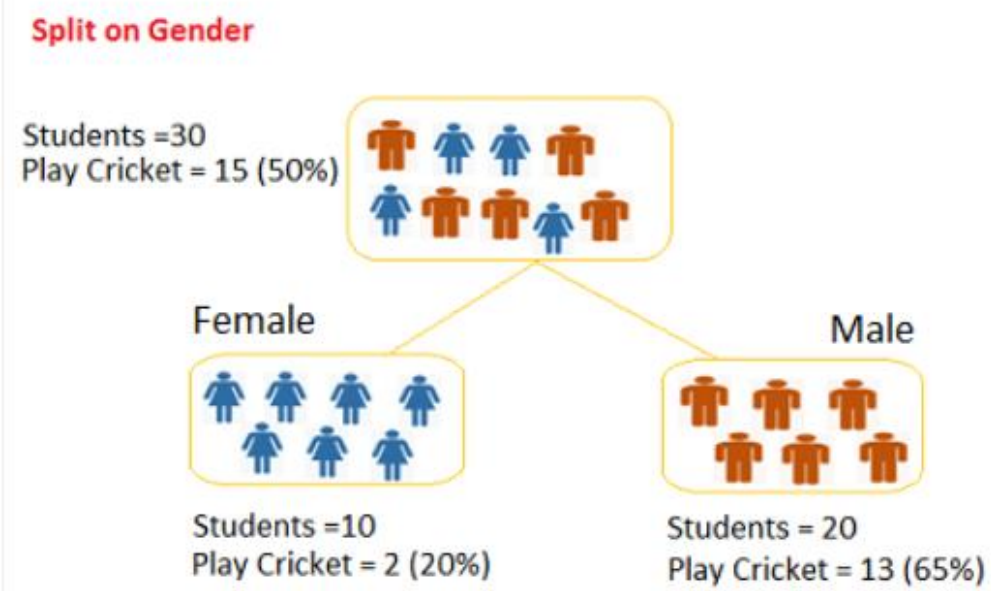
Árbol de decisión - Entropía

Para dividir en género:

Entropía para:

- *Nodo femenino* = – (2/10) log2 (2/10) – (8/10) log2 (8/10) = 0,72
- *Nodo masculino* = – (13/20) log2 (13/20) – (7/20) log2 (7/20) = 0.93
- *Por división Género* = (10/30) * 0.72 + (20/30) * 0.93 = **0.86**

Ganancia de información por división por género = 1–0.86 = ***0.14***



Árbol de decisión - Entropía

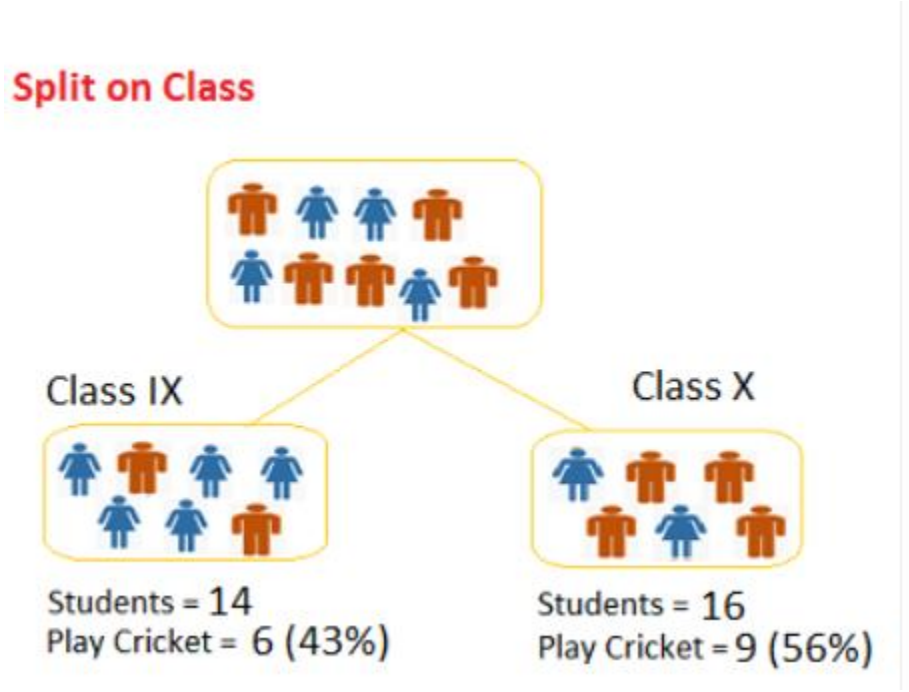
Para división en clase:

Entropía para:

- *Nodo de clase IX = – (6/14) log2 (6/14) – (8/14) log2 (8/14) = 0.99*
- *Clase Nodo X = – (9/16) log2 (9/16) – (7/16) log2 (7/16) = 0.99*
- *Por división Clase = (14/30) * 0.99 + (16/30) * 0.99 = 0.99*

Ganancia de información para división por Clase = 1– 0.99 = **0.01**

¿Quién tiene mayor ganancia de información?



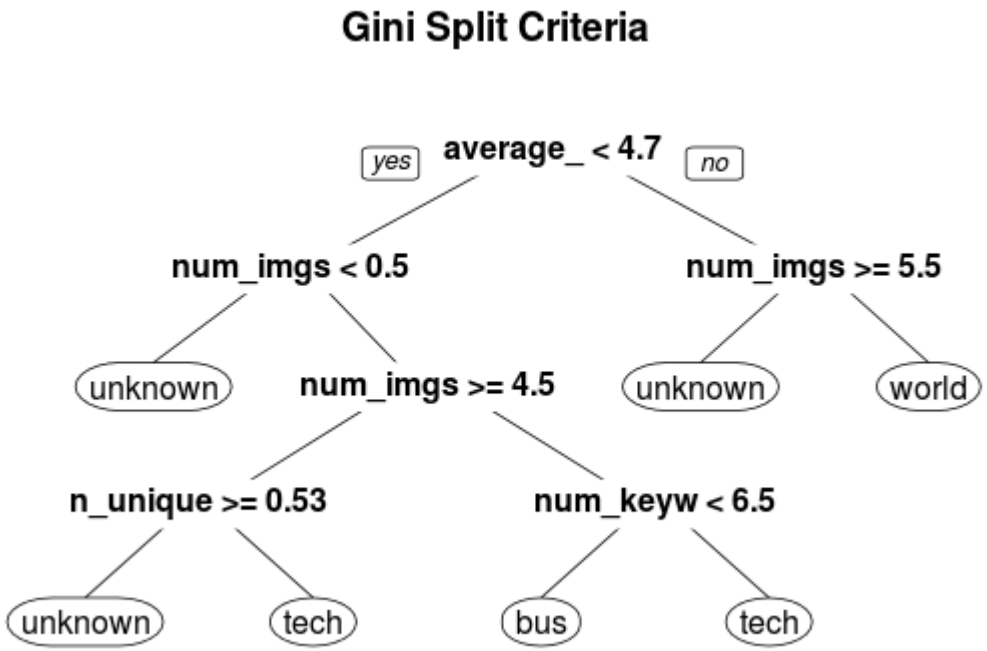
Árboles de decisión - Índice GINI

Gini dice que si seleccionamos dos elementos de una población al azar, entonces deben ser de la misma clase y la probabilidad de esto es 1 si la población es pura.

Principales características:

1. Funciona con la variable objetivo categórica “Éxito” o “Fracaso” “.
2. Realiza solo divisiones binarias
3. Cuanto **mayor** sea el valor de Gini, **mayor será la homogeneidad**.
4. CART (árbol de clasificación y regresión) utiliza el método Gini para crear divisiones binarias.

Árboles de decisión - Índice GINI

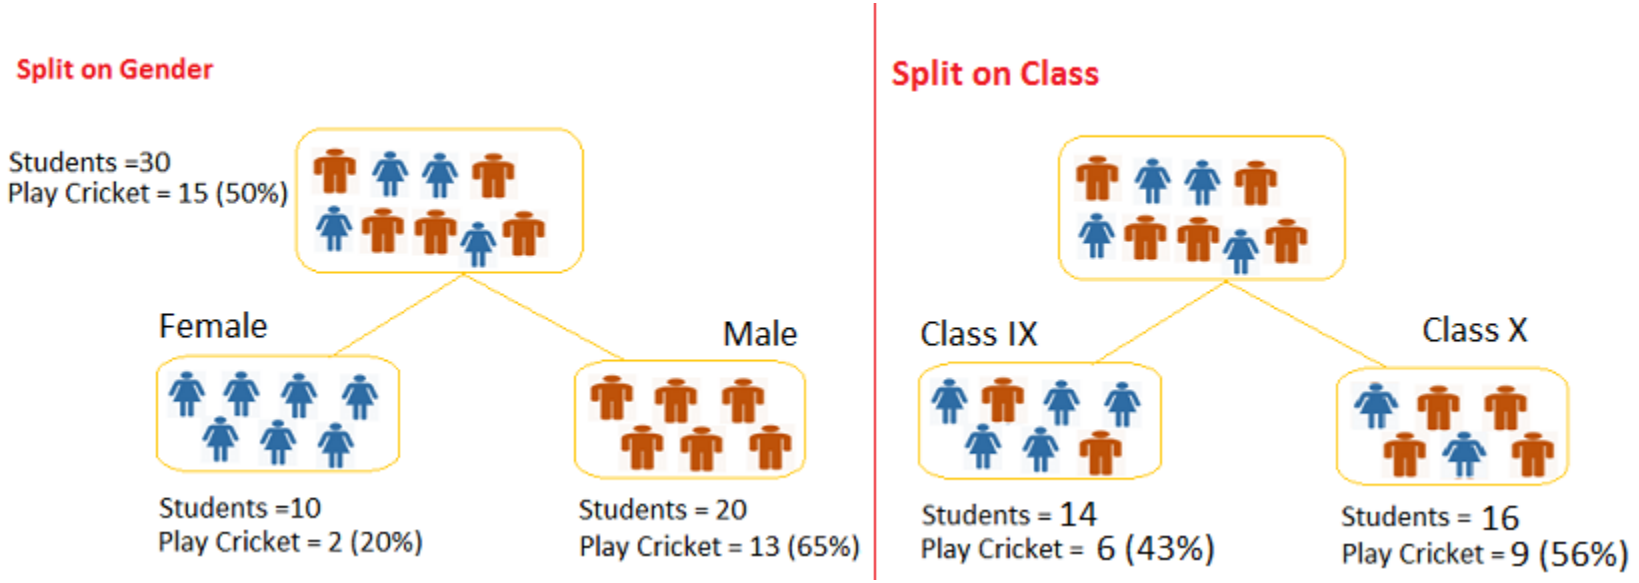


Pasos para calcular Gini para una división

1. Calcule **Gini para subnodos**, usando la suma de la fórmula del cuadrado de probabilidad de éxito y fracaso **($p^2 + q^2$)**.
2. Calcule **Gini para la división** usando la puntuación ponderada de Gini de cada nodo de esa división

Árbol de decisión - Índice GINI

Objetivo:
Refiriéndose al ejemplo utilizado anteriormente, donde queremos segregar a los estudiantes en función de la variable objetivo (jugar ping-pong o no).



¿Qué división está produciendo subnodos más homogéneos usando Gini?

Árbol de decisión - Índice GINI

División en género:

1. *Calcular, Gini para el subnodo femenino= (0.2) * (0.2) + (0.8) * (0.8) = 0.68*
2. *Gini para sub-nodo Macho = (0.65) * (0.65) + (0.35) * (0.35) = 0.55*
3. *Calcular Gini ponderado para Split Gender = (10/30) * 0.68+ (20/30) * 0.55 =* ***0.59***

División por Clase:

1. *Gini para sub-nodo Clase IX = (0.43) * (0.43) + (0.57) * (0.57) = 0.51*
2. *Gini para sub-nodo Clase X = (0.56) * (0.56) + (0.44) * (0.44) = 0.51*
3. *Calcular Gini ponderado para Clase dividida = (14 /30)*0.51+(16/30)*0.51 =* ***0.51***

La puntuación de Gini para Dividir en género es mayor que Dividir en Clase

Impureza de Gini = 1-Gini

Árbol de decisión - Pros y contras

VENTAJAS:

- **Interpretabilidad**
- **Manejo de datos mixtos**
- **Eficiencia computacional**
- **Robustez ante datos ruidosos**

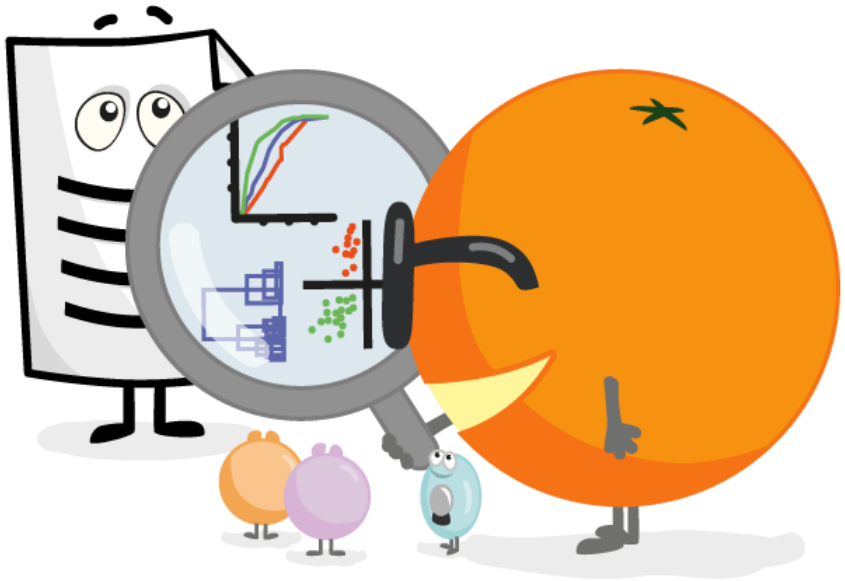
DESVENTAJAS:

- **Sobreajuste (overfitting)**
- **Inestabilidad**
- **Sesgo de clase:**
- **Robustez ante datos ruidosos**

Clasificación: detección de fraudes, clasificación de documentos, análisis de sentimientos, entre otros.

Regresión: Predicciones de precios de viviendas o estimaciones de demanda.

Selección de características: Al evaluar la ganancia de información de cada característica, se puede realizar una selección efectiva de las características más relevantes para el problema.



RAPIDMINER