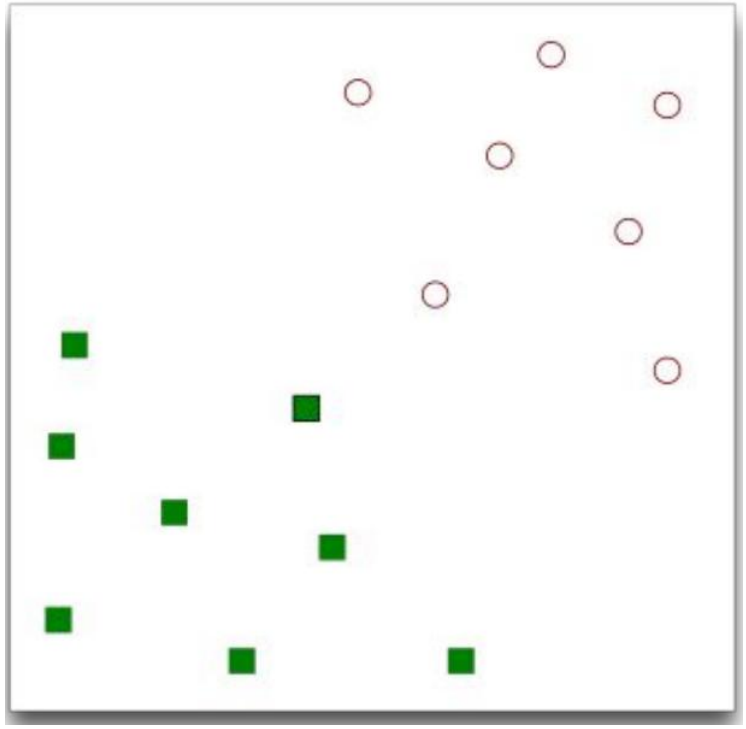
Support Vector Machines - SVMs

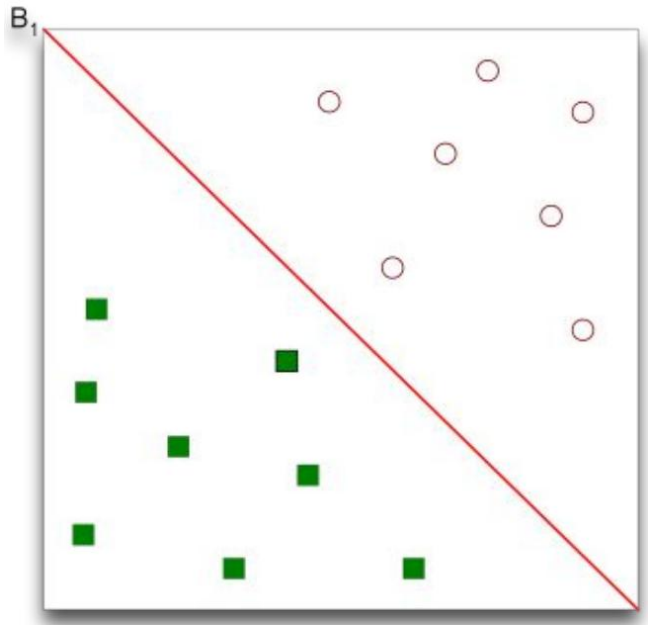
- Las SVMs son **algoritmos de aprendizaje automático** que se utilizan con fines de clasificación y regresión.

- Las SVMs pueden realizar de manera eficiente una **clasificación no lineal** utilizando el truco del kernel. Nos permite mapear implícitamente las entradas en espacios de características de alta dimensión.

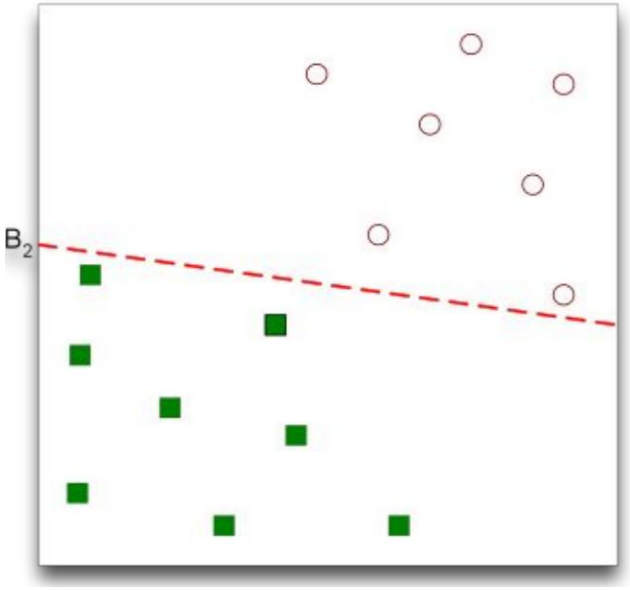


Objetivo:
Encontrar un hiperplano lineal (decision boundary) que separe los ejemplos positivos de los negativos.

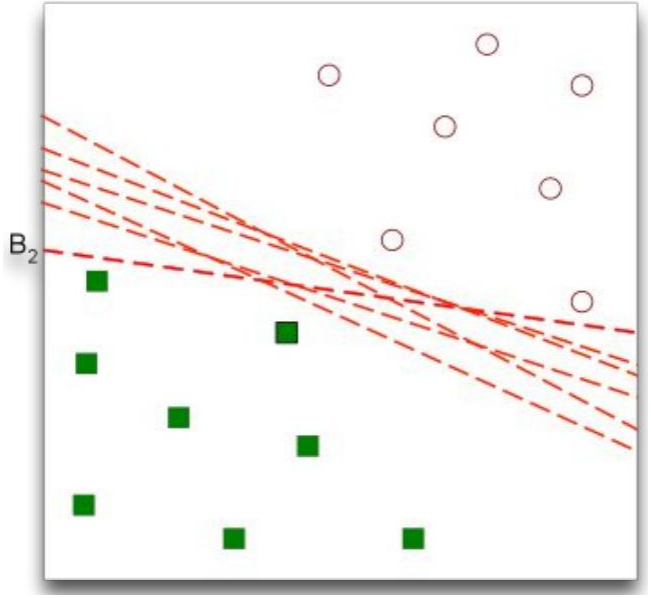
Support Vector Machines - SVMs



Una posible solución

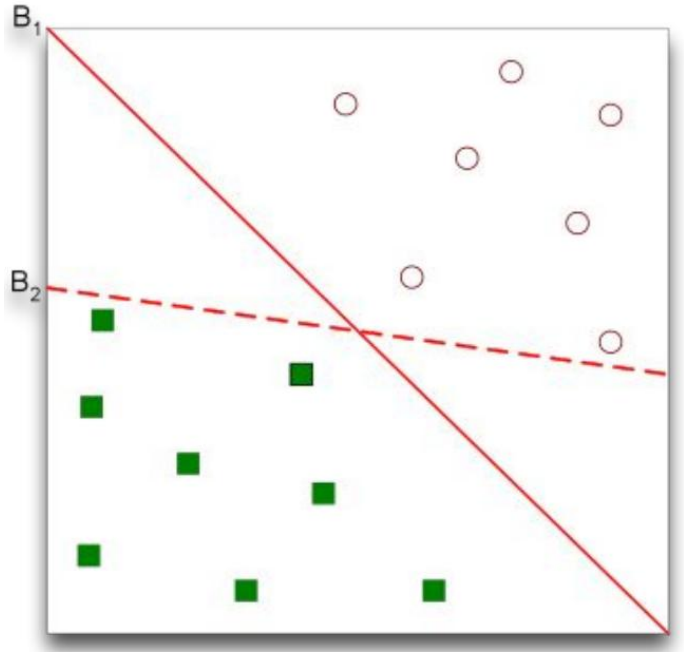


Otra posible solución



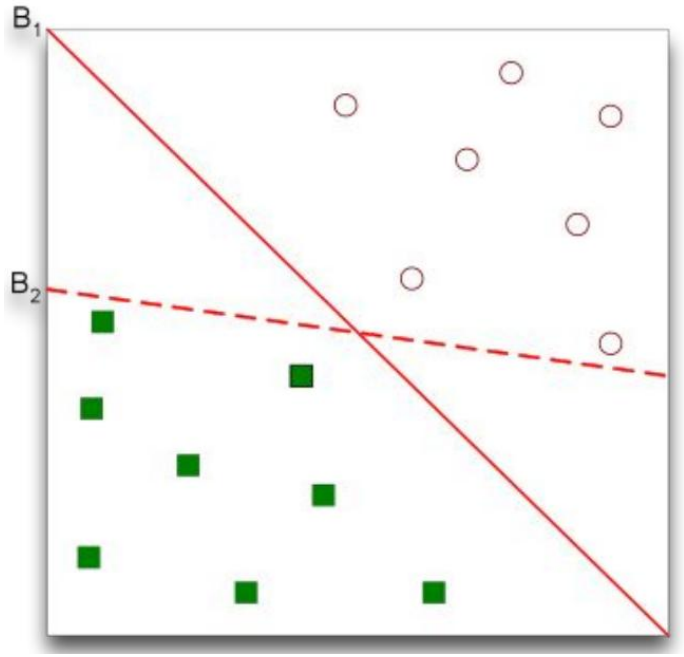
Infinitas soluciones!!!

Support Vector Machines - SVMs

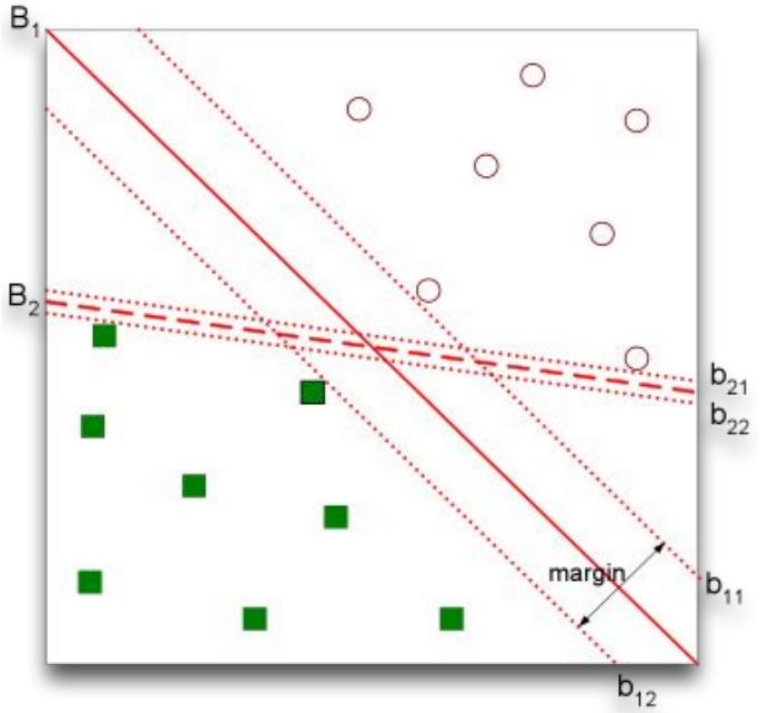


- ¿Cuál es mejor? ¿B1 o B2?
- ¿Cómo definimos qué es mejor?

Support Vector Machines - SVMs



- ¿Cuál es mejor? ¿B1 o B2?
- ¿Cómo definimos qué es mejor?



- Encontrar un hiperplano que maximice el margen (menores errores de generalización) => **B1 es mejor que B2**
- Entre más ancho el margen, mayor el poder de generalización.

Support Vector Machines - SVMs

TERMINOLOGÍA

- **Hiperplano**
  Es un límite de decisión que separa un conjunto dado de puntos de datos que tienen diferentes etiquetas de clase. El clasificador SVM separa los puntos de datos utilizando un hiperplano con la máxima cantidad de margen. **Hiperplano de márgen máximo.**

- **Vectores de soporte**
  Son los puntos de datos de muestra, **que están más cerca del hiperplano**. Estos puntos de datos definirán mejor la línea de separación o el hiperplano al calcular los márgenes.

- **Margen**
  Es un espacio de separación entre las dos líneas en los puntos de datos más cercanos. Se calcula como la distancia perpendicular desde la línea hasta los vectores de soporte o los puntos de datos más cercanos.

En SVM, intentamos maximizar esta brecha de separación para obtener el máximo margen.

Support Vector Machines - SVMs

- Sea un problema de **clasificación binaria** con N ejemplos, cada ejemplo se representa como la tupla **x_i ,y_i** (i=1,2,...,N), donde **x_i** es un vector de **d** dimensiones (x_i1,x_i2,...,x_id)^T e **y_i** ∈ {−1, 1} (ejemplos **negativos** y **positivos**).

- El **límite de decisión** de un clasificador lineal se escribe de la siguiente manera:

$$\mathbf{w} \cdot \mathbf{x} + b = 0,$$

¿Cómo formular el **margen** en función de los parámetros? y ¿Cómo formular un **problema de optimización** que permita encontrar el hiperplano de máximo margen?

Support Vector Machines - SVMs

El hiperplano **w·x+b=0** separa las muestras positivas (cuadrados) de los negativas (círculos)

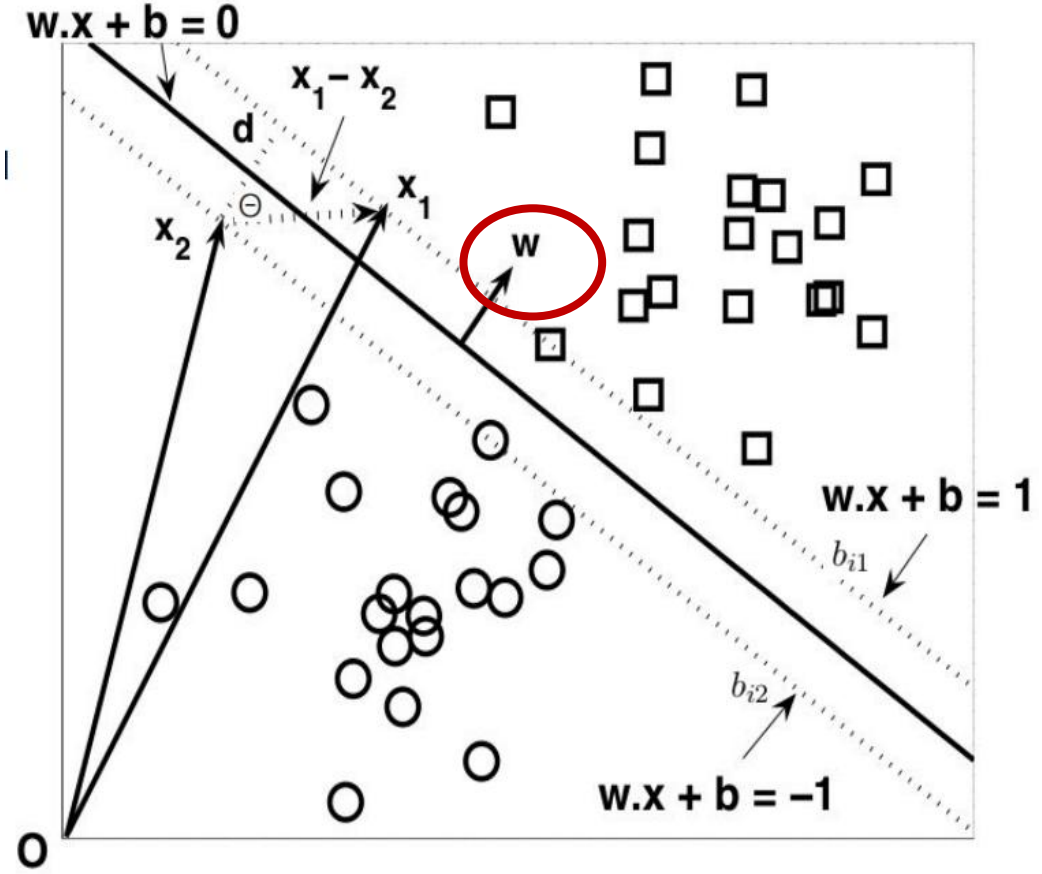
Cualquier ejemplo que se encuentre en el límite de decisión debe satisfacer la ecuación del hiperplano.

Por ejemplo, sean **x_a** y **x_b** dos puntos localizados en el límite de decisión:

$$\mathbf{w} \cdot \mathbf{x}_a + b = 0,$$
$$\mathbf{w} \cdot \mathbf{x}_b + b = 0.$$

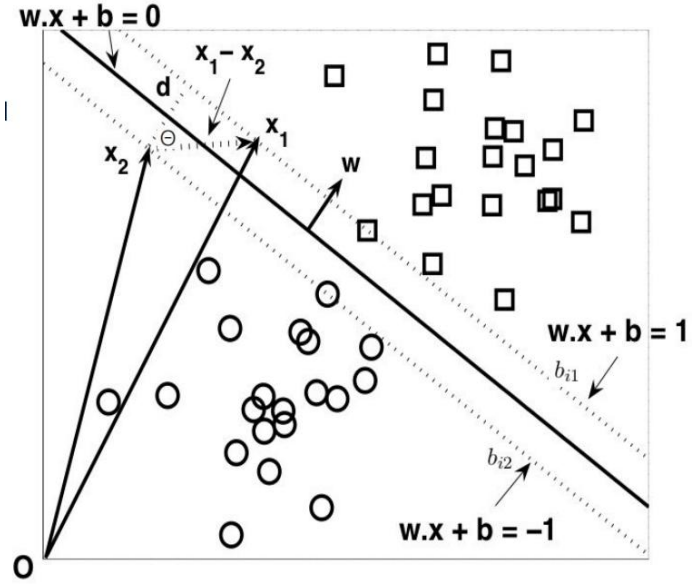
Si restamos las dos ecuaciones obtenemos:

$$\mathbf{w} \cdot (\mathbf{x}_b - \mathbf{x}_a) = 0,$$



Cómo **x_b -x_a** es paralelo al límite de decisión, entonces **w** es perpendicular al hiperplano (el producto punto de dos vectores ortogonales es cero).

Support Vector Machines - SVMs



- Para cualquier cuadrado **x_s** localizado sobre el límite de decisión, se cumple que:

donde **k > 0**.

$$\mathbf{w} \cdot \mathbf{x}_s + b = k,$$

- De manera análoga, para cualquier círculo **x_c** localizado bajo el límite de decisión, se cumple que:

donde **k' < 0**.

$$\mathbf{w} \cdot \mathbf{x}_c + b = k',$$

- Si etiquetamos todos los cuadrados como la **clase positiva +1** y todos los círculos como la **clase negativa -1**, podemos predecir la etiqueta y para cualquier ejemplo de test **z** de la siguiente manera:

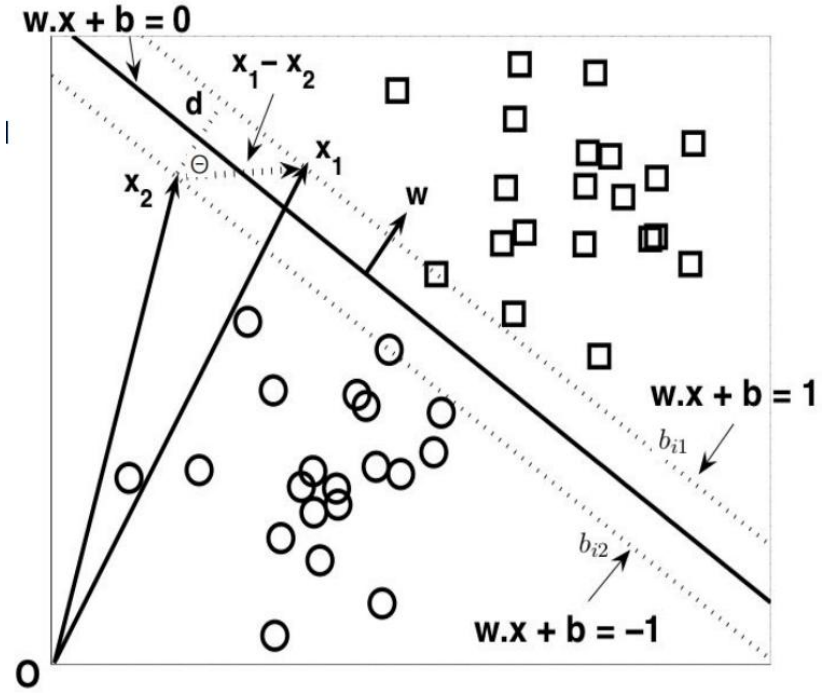
$$y = \begin{cases} 1, & \text{if } \mathbf{w} \cdot \mathbf{z} + b > 0; \\ -1, & \text{if } \mathbf{w} \cdot \mathbf{z} + b < 0. \end{cases}$$

Support Vector Machines - SVMs

- Consideremos el cuadrado y el círculo que se encuentran más cercanos al límite de decisión como los puntos **x_1** y **x_2** **(Vectores de soporte)**.

- Sobre **x_1** pasa un hiperplano paralelo al límite de decisión llamado **b_i1** y sobre **x_2** pasa otro hiperplano paralelo al límite de decisión llamado **b_i2.**

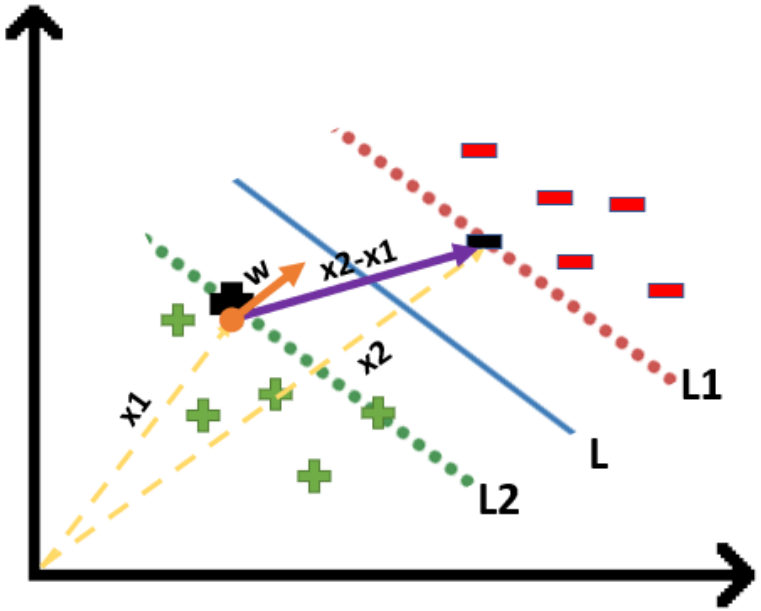
- Podemos re-escalar los parámetros **w** y **b** del límite de decisión de tal manera que los hiperplanos paralelos bi1 y bi2 puedan expresarse de la siguiente manera:



$$b_{i1} : \ \mathbf{w} \cdot \mathbf{x} + b = 1,$$
$$b_{i2} : \ \mathbf{w} \cdot \mathbf{x} + b = -1.$$

El margen del límite de decisión se calcula como la distancia entre estos dos hiperplanos.

Support Vector Machines - SVMs



La expresión para definir el margen (en función de **w**) es:

$$\|\mathbf{w}\| \times d = 2$$

$$\therefore d = \frac{2}{\|\mathbf{w}\|}.$$

La fase de entrenamiento de una SVM lineal implica la estimación de los parámetros **w** y **b** del límite de decisión a partir de los datos de entrenamiento, de manera que se cumplan las dos siguientes condiciones :

$$\mathbf{w} \cdot \mathbf{x_i} + b \geq \ 1 \text{ if } y_i = 1,$$

$$\mathbf{w} \cdot \mathbf{x_i} + b \leq -1 \text{ if } y_i = -1.$$

$$y_i(\mathbf{w} \cdot \mathbf{x_i} + b) \geq 1, \quad i = 1, 2, \ldots, N.$$

Support Vector Machines - SVMs

Maximizar el margen equivale a **minimizar** la siguiente función objetivo:

$$f(\mathbf{w}) = \frac{\|\mathbf{w}\|^2}{2}.$$

$$\max_w \frac{2}{||w||} \Leftrightarrow \min_w \frac{||w||^2}{2}$$

La **tarea de aprendizaje en SVM** puede formalizarse como el siguiente problema de optimización con restricciones:

$$\min_{\mathbf{w}} \frac{\|\mathbf{w}\|^2}{2}$$

$$\text{subject to} \qquad y_i(\mathbf{w} \cdot \mathbf{x_i} + b) \geq 1, \quad i = 1, 2, \ldots, N.$$

Support Vector Machines - SVMs

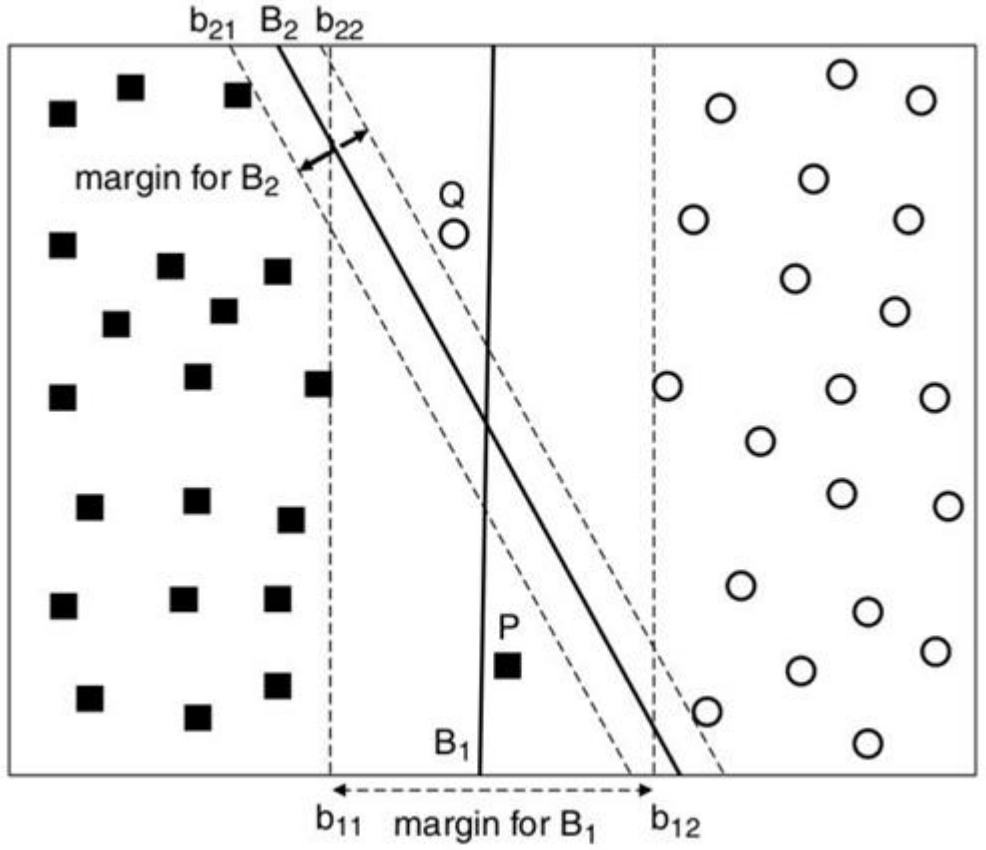
SVM DE MARGEN SUAVE

- La figura muestra un dataset con **dos ejemplos nuevos (ruidosos)**: un círculo Q y un cuadrado P.

- También muestra **dos hiperplanos separadores** posibles B1 y B2 .

- El límite de decisión B1 clasifica erróneamente los dos nuevos ejemplos, mientras que B2 los clasifica correctamente.

- Pero esto no significa que B2 sea un mejor límite de decisión que B1 .



¿Qué pasa con los márgenes?

Support Vector Machines - SVMs

SVM DE MARGEN SUAVE

¿Cómo modificar el problema de optimización para aprender un límite de decisión que sea tolerable al ruido usando un método conocido como el **margen suave (soft margin)**.?

¿Para qué?

Esto permitirá a la SVM construir una límite de decisión incluso en situaciones en las que las clases no sean linealmente separables.

¿Cómo se hace?

Para esto, el algoritmo de aprendizaje de SVM debe encontrar un balance entre el ancho del margen y el número de errores hechos por la SVM sobre los datos de entrenamiento.

Support Vector Machines - SVMs

SVM DE MARGEN SUAVE

- El límite de decisión de **B1 no satisface las restricciones** del problema original.

$$y_i(\mathbf{w} \cdot \mathbf{x_i} + b) \geq 1, \quad i = 1, 2, \ldots, N.$$

- Debemos **relajar** las restricciones para poder **soportar datos no linealmente separables**.

- Esto se puede hacer introduciendo **variables de holgura o slack variables (ξ)** a las restricciones del problema:

$$\mathbf{w} \cdot \mathbf{x_i} + b \geq 1 - \xi_i \quad \text{if } y_i = 1,$$
$$\mathbf{w} \cdot \mathbf{x_i} + b \leq -1 + \xi_i \quad \text{if } y_i = -1,$$

$$\text{where } \forall i: \ \xi_i > 0.$$

Support Vector Machines - SVMs

SVM DE MARGEN SUAVE

El **problema de optimización** quedaría formulado como minimizar la siguiente función objetivo:

$$\frac{1}{2}||w||^2 + C\sum_{i=1}^{m}\xi_i$$

$$\text{s.t.} \quad y^{(i)}(w^T x^{(i)} + b) \geq 1 - \xi_i, \quad i = 1, \ldots, m$$

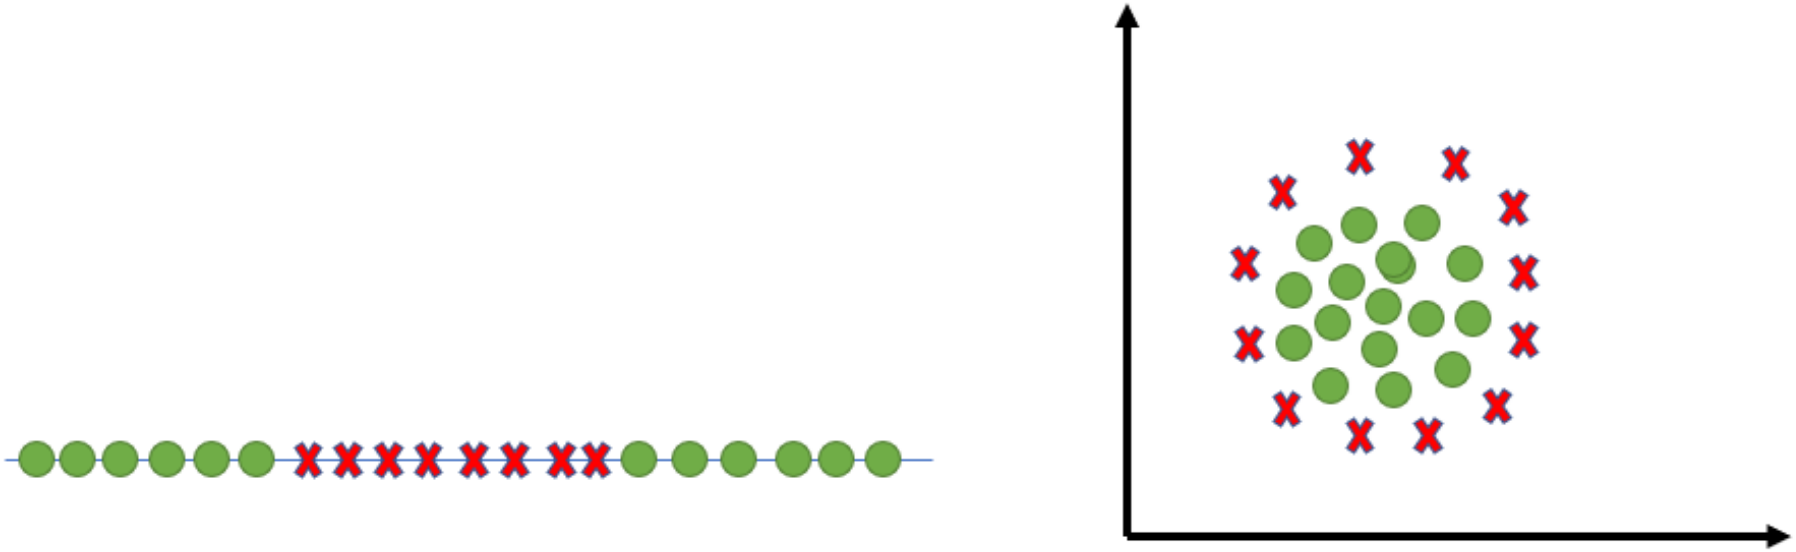
$$\xi_i \geq 0, \quad i = 1, \ldots, m.$$

Donde **ξ_i** representa la magnitud del error para el ejemplo **i** y **C** es un costo que pagamos por equivocarnos.

El valor del parámetro **C** se debe calibrar sobre un conjunto de datos independientes llamado **validación** o haciendo cross-validation.

Support Vector Machines - SVMs

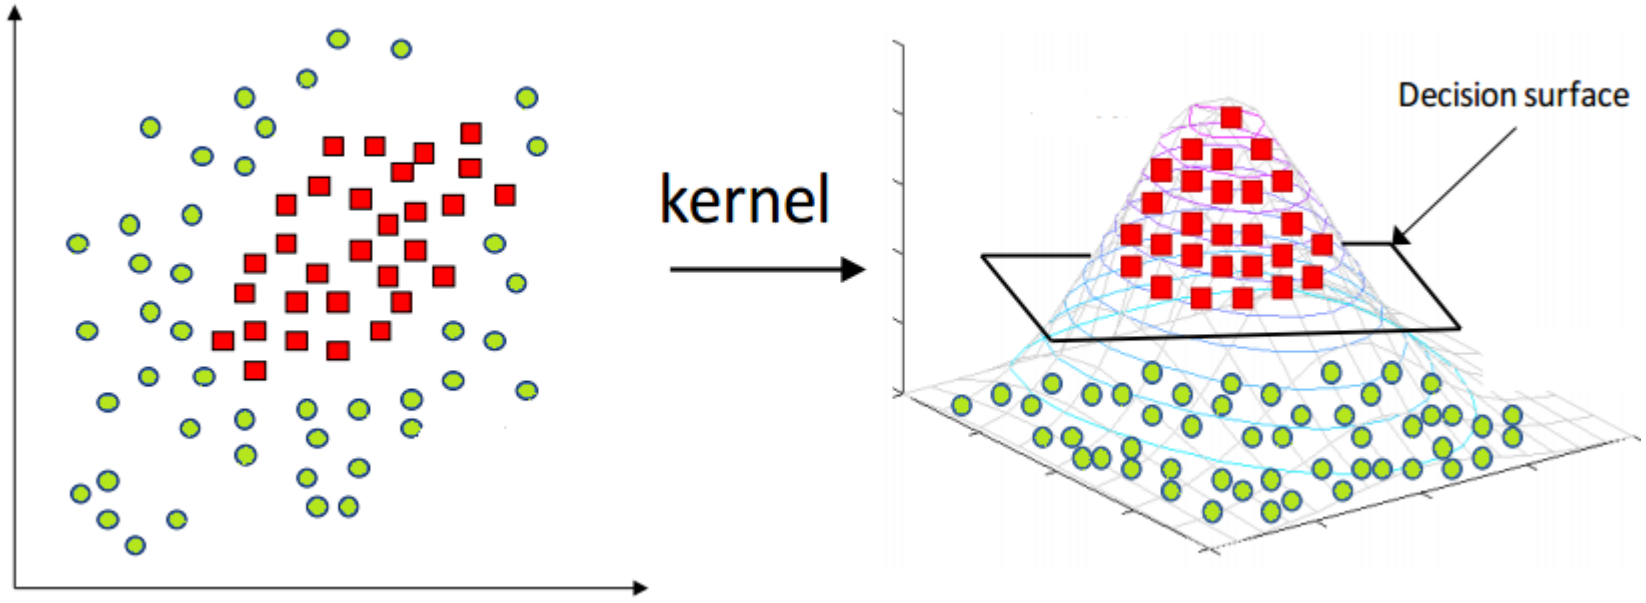
SVM NO LINEAL



SVM puede trabajar con un conjunto de datos no lineal y para esto usamos **"Kernel Trick"** que facilita la clasificación de los puntos.

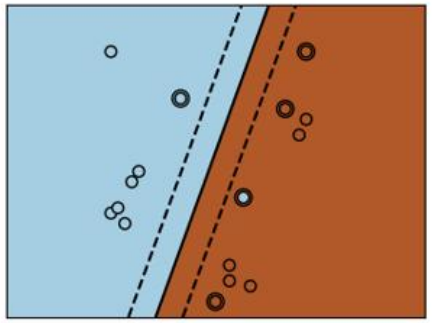
Support Vector Machines - SVMs

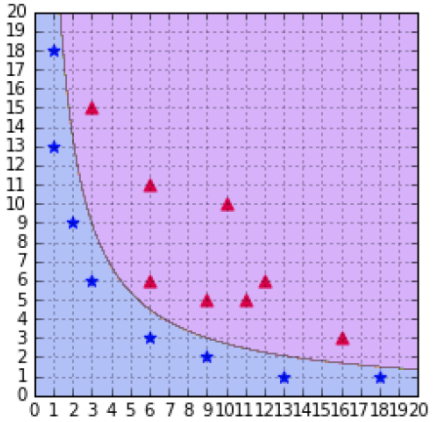
Lo que hacemos es intentar **convertir** este espacio de menor dimensión en un espacio de mayor dimensión usando algunas **funciones cuadráticas** que nos permitirán encontrar un límite de decisión que divida claramente los puntos de datos.



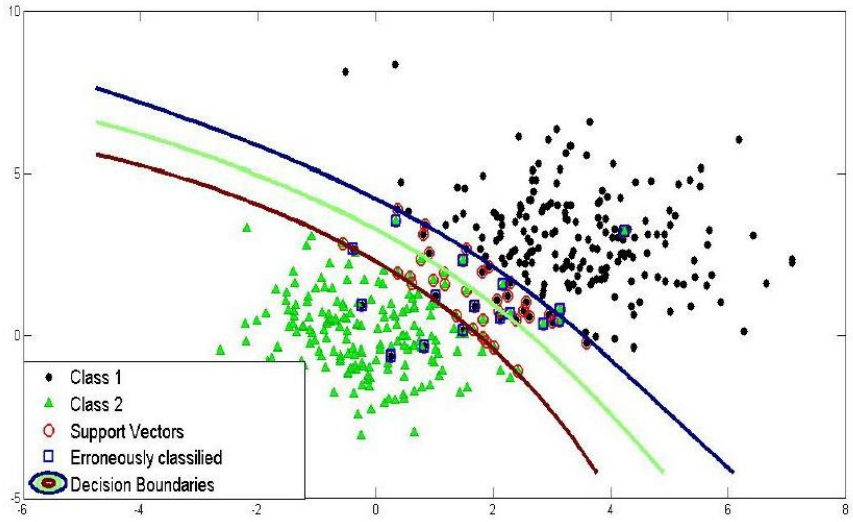
Estas funciones que nos ayudan a hacer esto se llaman **Kernels** y qué kernel usar está puramente determinado por el ajuste de hiperparámetros.

Support Vector Machines - SVMs





A SVM using a polynomial kernel is able to separate the data (degree=2)



$$k(\mathbf{x}, \mathbf{z}) = \mathbf{x}^\top \mathbf{z}$$

Kernel lineal

$$f(X1, X2) = (X1^T . X2 + 1)^d$$

Kernel Polinomial

$$k(x, y) = \exp\left(-\frac{\|x - y\|^2}{2\sigma^2}\right)$$

Kernel Gaussiano (RBF)

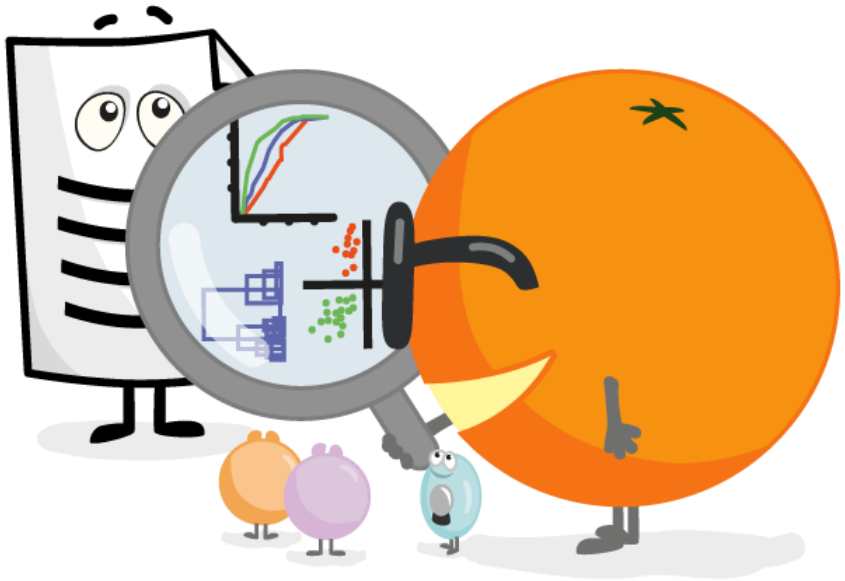
Support Vector Machines - SVMs

Usando la idea de tener una función **Φ(x)** que **mapea los datos a una dimensión mayor**, podemos redefinir el problema de optimización.

$$\min_{\mathbf{w}} \frac{\|\mathbf{w}\|^2}{2}$$

$$\text{subject to} \qquad y_i(\mathbf{w} \cdot \Phi(\mathbf{x}_i) + b) \geq 1, \quad i = 1, 2, \ldots, N.$$

Lo único que hacemos es reemplazar todas las instancia del vector **x** por **Φ(x)**.



RAPIDMINER