UNIVERSIDAD NACIONAL DE COLOMBIA

Analítica de Datos

Prof. Diego Fabian Collazos

Taller de cierre de capítulos en Orange

En este taller veremos una aproximación a un problema de análisis de datos. Haremos un repaso, desde cero, de (casi) todas las técnicas vistas en el Diplomado y veremos cómo la formulación de preguntas adecuadas a los datos puede llevarnos al descubrimiento de patrones en ellos.

Cabe decir que este enfoque NO es el único posible y que, dependiendo de los datos que se tengan y de las preguntas que queramos hacerles, las técnicas, análisis y visiones pueden cambiar.

Datos de origen

Base de datos Pruebas Saber 11 2020-2

Origen: [Saber 11° 2020-2 | Datos Abiertos Colombia]

Se le hizo un depurado previo.

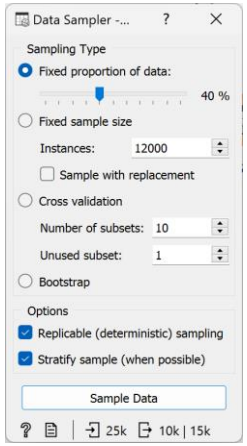
- Se seleccionaron solo registros del Eje Cafetero (Risaralda, Caldas, Quindío).
- Se eliminaron variables irrelevantes (códigos SNIES de colegios, y variables de ese tipo, etc.)

El archivo resultante <ICFES_2020-2_Eje_Cafetero.csv> quedó con:

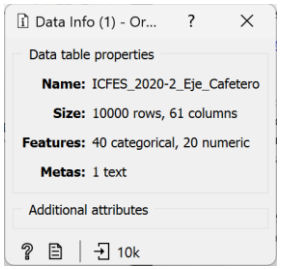
- 24999 registros
- 61 variables (40 categóricas, 20 numéricas, 1 metadato)

Preproceso

Para hacer más simple el procesamiento, se hizo un submuestreo al 40%

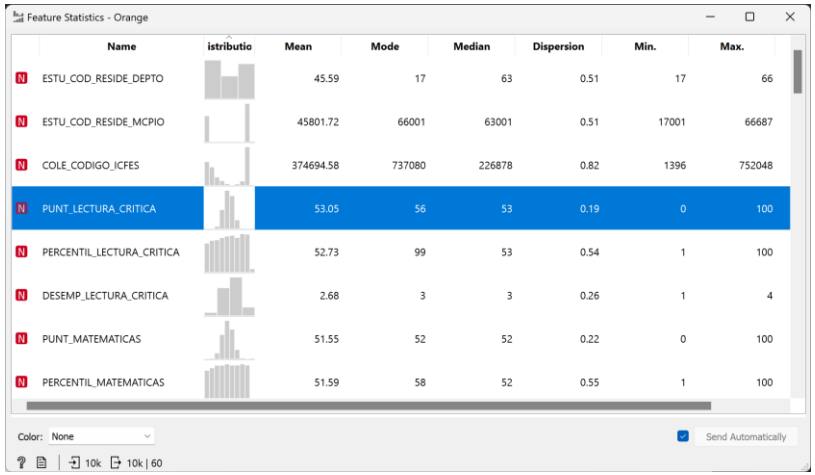


Y quedamos entonces con



Feature Statistics

Apliquemos primero el widget de **Feature Statistics** (descriptores estadísticos de los datos) y empecemos a ver cosas.



Vemos que hay variables que aparecen como **Numéricas**, pero que no tiene sentido que lo sean (las tres primeras, ya que corresponden a códigos cuyo valor numérico no representa ningún valor en sí mismo). Vamos a cambiarles su naturaleza y las pasamos a **Categóricas**.



Edit Domain

Seguimos revisando la salida del widget **Feature Statistics** y vamos tomando nota de varias cosas:

- Hay variables numéricas relacionadas con los puntajes de los exámenes.
- Hay variables categóricas relacionadas con variables socioeconómicas y características del estudiante y de su entorno. Las hay binomiales (toman dos posibles valores, ej: SI/NO, OFICIAL/NO_OFICIAL) y polinomiales (toman más de dos valores).

Vemos que los registros están medianamente balanceados respecto a los departamentos

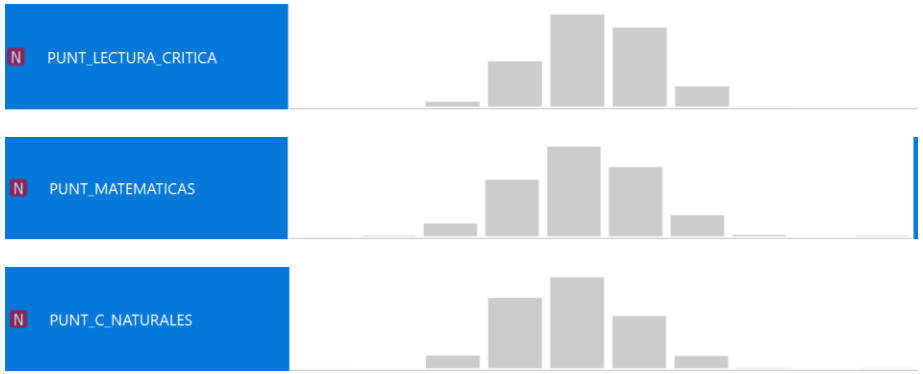


Pero que por ejemplo, parece que no lo están respecto a los municipios



Esto era esperable en esta base de datos, en donde la mayoría de estudiantes presentan sus pruebas en las capitales de departamento o en municipios grandes como Dosquebradas o Santa Rosa. Conviene que vayamos confirmando nuestras creencias previas sobre los datos y así vamos verificando y haciendo un **Sanity Check** sobre la BD (*sanity check* es el nombre que se le da a un *chequeo de sanidad de los datos*, una comprobación de que no tenemos cosas raras, que aparentemente están bien tomados y que se encuentran en formato y formas correctas).

Vemos por ejemplo que los puntajes en las disciplinas de las pruebas siguen distribuciones que parecen ser normales.



Y así para todas las disciplinas.

Vemos algo **curioso** en la variable fecha de nacimiento



UNA ALTA DISPERSIÓN

Mean	Mode	Median	Dispersion	Min.	Max.
2002-09-13 01:28:42.240000	2003-09-26 00:00:00	2003-06-15 00:00:00	~74 years	1946-02-18 00:00:00	2020-09-08 00:00:00

Y vemos cosas curiosas que luego verificaremos.

- Por ejemplo, si vemos el valor mínimo de esa variable, veremos que hay personas nacidas en 1946 que presentaron las pruebas en el 2020-2. Es decir que tenían 74 años al presentarlas. ¡Bien por ellos!
- Pero lo más curioso es que si vemos los valores máximos, hay personas nacidas en 2020 que presentaron las pruebas en 2020. ¿? ALGO RARA PASA. Luego lo analizamos.

También hay variables curiosas como Estudiante Privado de Libertad (personas que hacen las pruebas desde la cárcel).



O la frecuencia con la que la familia come Carne, Pescados o Huevos



Análisis exploratorio

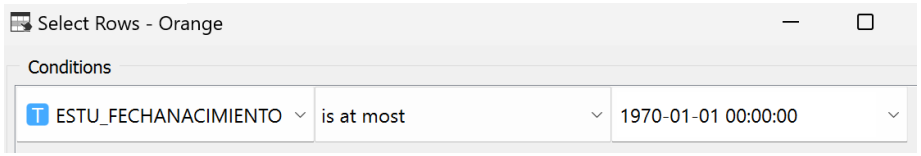
Una vez hecha esta lectura general de los datos, pasemos a analizar las cosas extrañas que vimos. Empecemos por la edad.

Hagamos una selección de filas para ver los registros que cumplan con ciertas fechas.



Select Rows

Hagamos una búsqueda mediante el widget **Select Rows** y miremos cuántos son nacidos antes de 1970



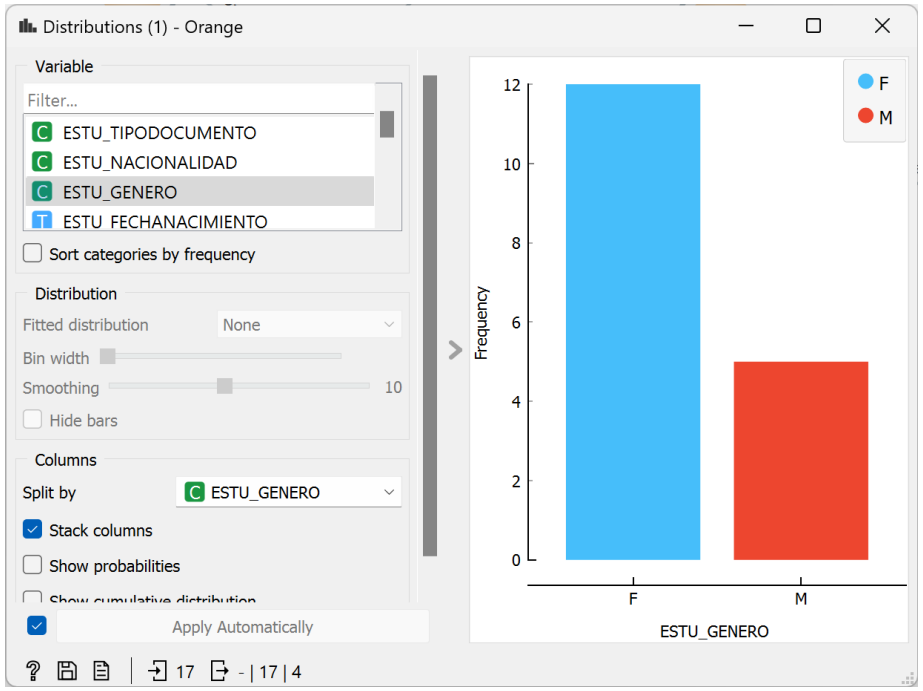
Conectemos esa salida a un **Data Table** e interpretemos.

Analizar datos en Tablas es muy incómodo. La información no es clara. Busquemos otra forma de hacerlo que nos dé **highlights** sobre lo que hay.

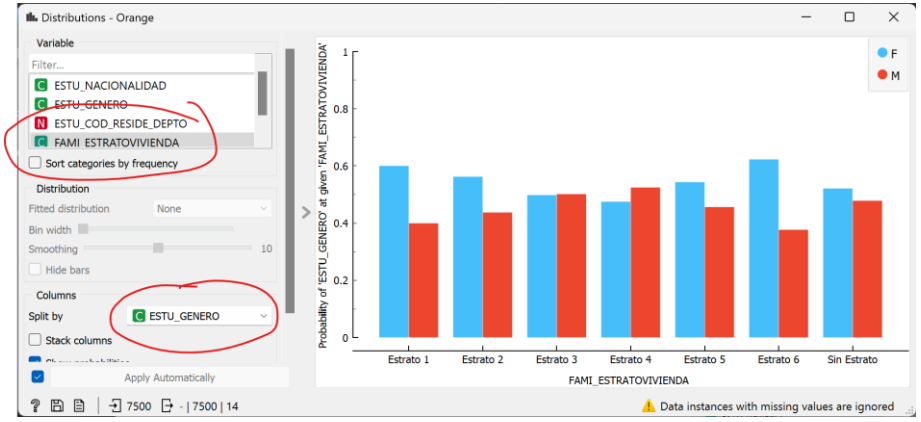
Gráfico Distributions

Conectemos un widget de distribuciones (**Distributions**) y hagamos un análisis sobre estas personas.

Veamos, por ejemplo, su distribución por género (variable **ESTU_GENERO**). Tengamos en cuenta que aquí estamos usando el widget **Distributions** para variables categóricas, pero que también podríamos usarlo para variables numéricas como veremos más adelante.



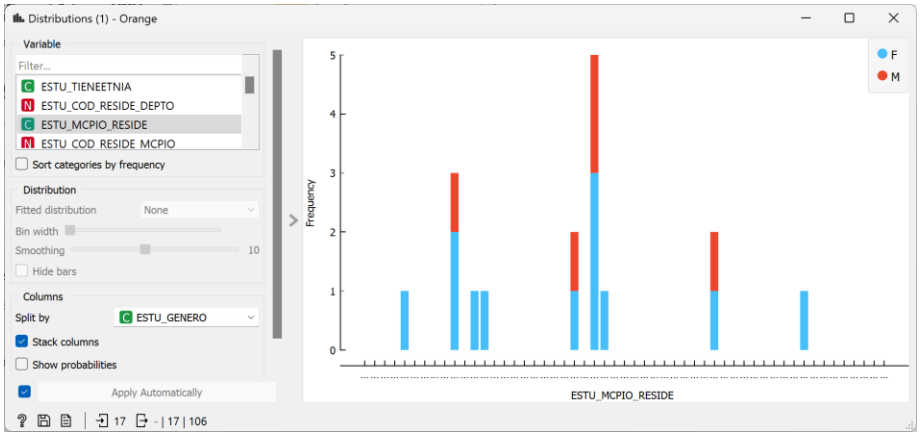
Veamos ahora una distribución condicional. Para esto selecciono una variable principal y parto (hago un ***split by***) la visualización por otra variable que sea de interés. En esta figura vemos el ejemplo de la variable estrato (**FAMI_ESTRATOVIVIENDA**), dividida en su visualización por género (**ESTU_GENERO**).



Veamos bien cómo presentar la información cambiando parámetros de este widget y entendamos qué ofrece cada uno.

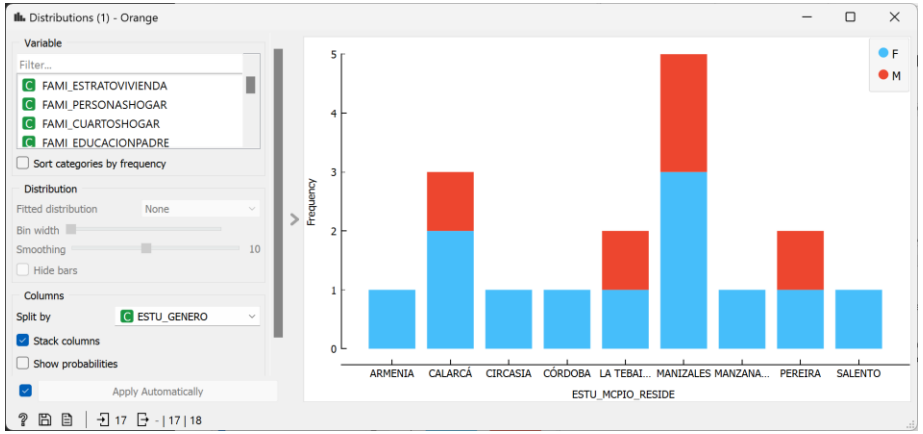
- Sort categories
- Stack columns
- Sho probabilities
- Split by
- Etc…

Si escogemos ver en qué municipio residen, se vería algo así:



Esta visualización es ruidosa, vemos muchos puntos en el eje X, pero sin información en el eje Y, esto es debido a que Orange sigue almacenando los posibles valores de esa variable, aunque los sujetos seleccionados NO tengan esos posibles valores. Recuerden que estamos viendo a los sujetos nacidos antes de 1970 os cuales son pocos.

Para evitar esta visualización tan ruidosa, lo que haremos es seleccionar **Remove unused features** desde el widget de **Select Rows** y la visualización quedará mucho mejor.



La forma de visualización mediante el widget **Distributions** es bastante informativa, pero queda limitada a solo dos posibles variables.

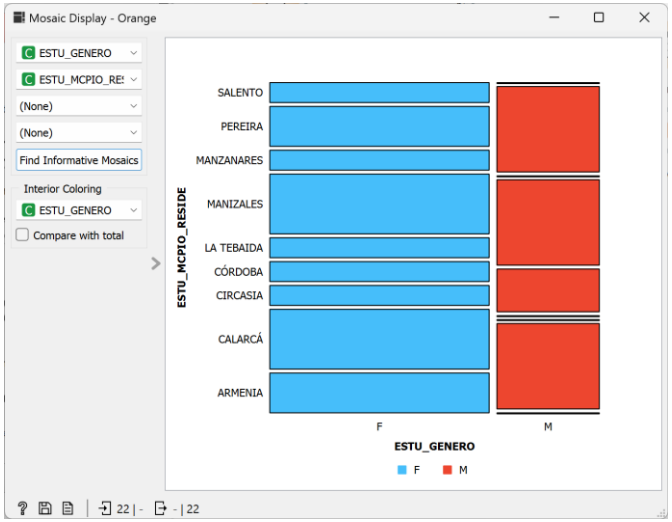
Veamos un ejemplo más de este widget.

Gráfico MOSAIC

Si quisiéramos meter más variables tendríamos que seleccionar otra herramienta de visualización como por ejemplo la herramienta mosaico (widget **Mosaic**). Esta herramienta permite visualizar más de dos variables (hasta 5) en diversas dimensiones:

- Divide el eje x inferior
- Divide el eje x superior
- Divide el eje y a la derecha
- Divide el eje y a la izquierda
- Rellena el color de cada división

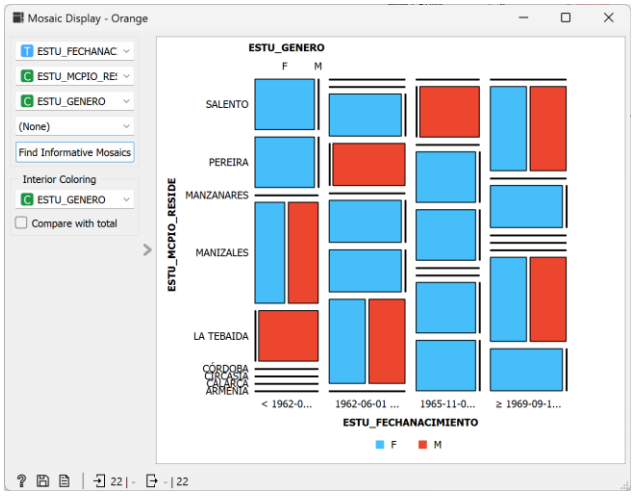
Veamos qué podemos hacer con él. Empecemos con algo sencillo. Seleccionemos la variable Género y la variable Municipio. Pongamos en color interior Género.



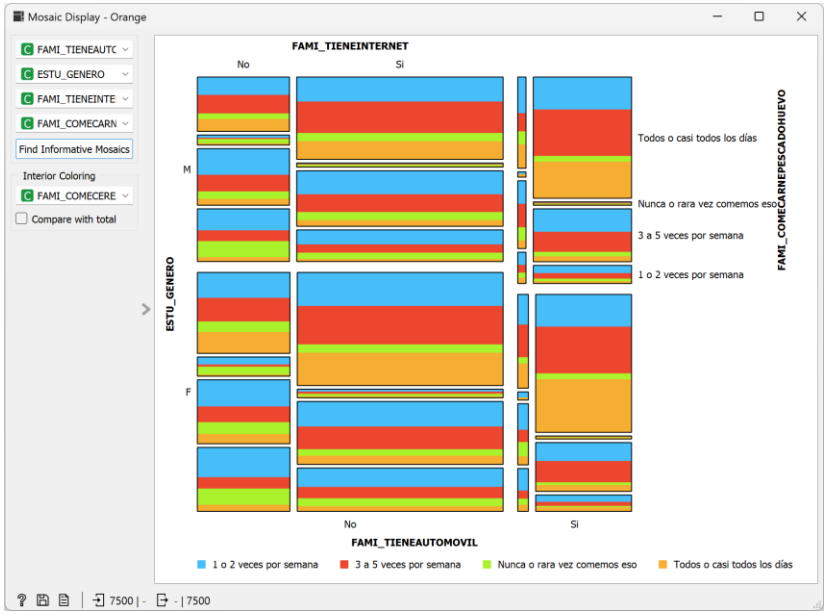
Explicar bien el diagrama y entender bien qué hay ahí. Cambiar la opción **Compare with total**.

Hasta aquí no ha cambiado en casi nada a lo que podíamos hacer con **Distributions**.

Metamos ahora una tercera variable



Y metamos incluso 5 variables y veamos qué sale



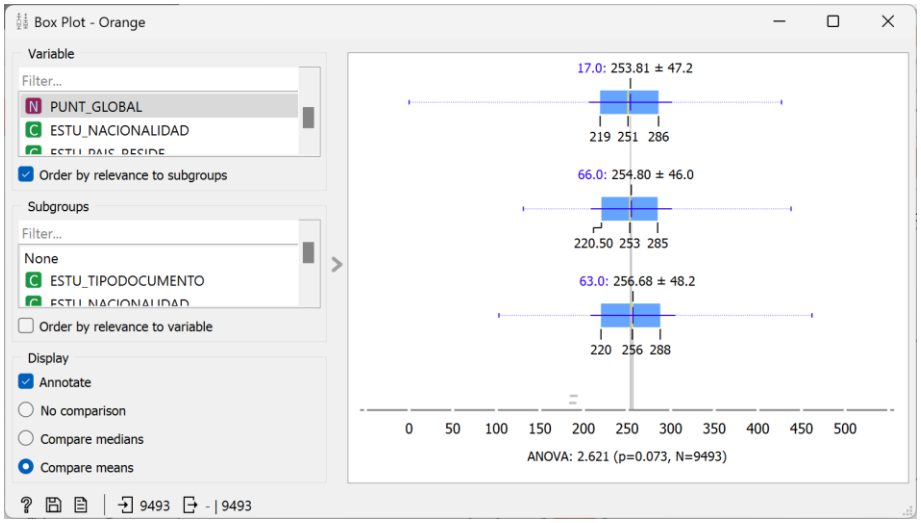
Recordemos que hay técnicas de visualización que son adecuadas para variables categóricas y otras adecuadas para variables numéricas. También las hay para visualizar series de tiempo y para visualizar metadatos.

Veamos qué hace el botón de **Encontrar Mosaicos Informativos**, pero antes de hacerlo seleccionemos unas poquitas variables y reduzcamos el espacio de datos. Este proceso puede tomar MUCHO tiempo si no reducimos la cantidad de datos y variables.

Las técnicas que hemos visto hasta ahora en este taller son para variables categóricas (**Distributions** y **Mosaic**). Veamos ahora algunas para variables numéricas.

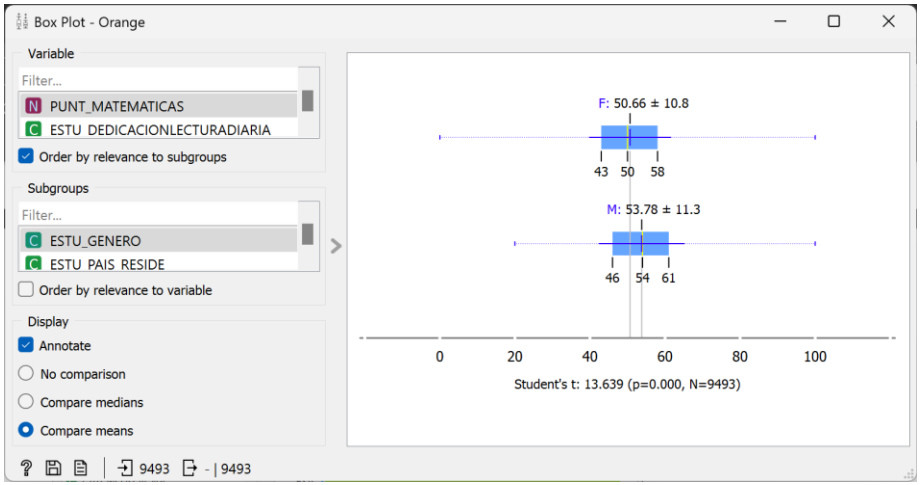
Gráfico BOX-PLOT

Box Plot. Hagamos el box-plot de la variable **Puntaje Global** y la agrupamos en estudiantes de los 3 departamentos. Seleccionemos antes a los nacidos entre el 2000 y el 2004.

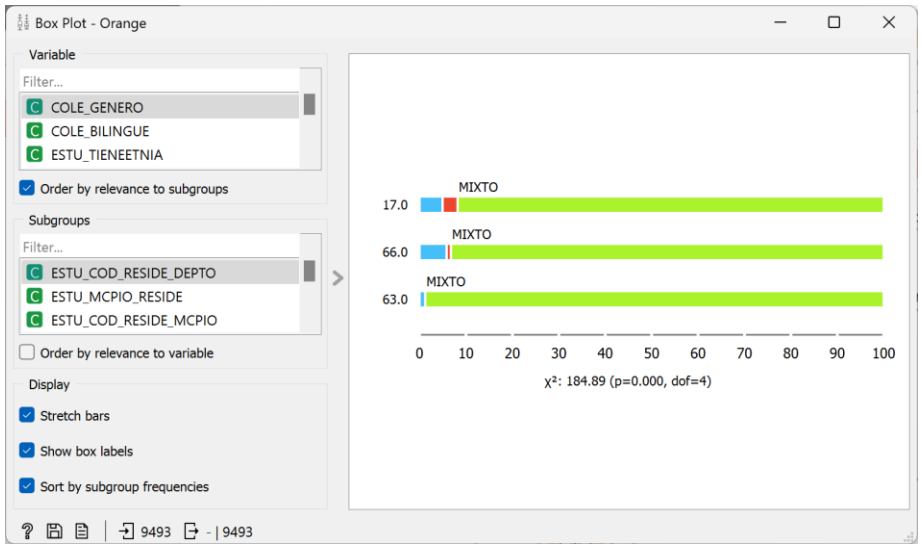


De este gráfico podemos decir por ejemplo que Caldas tiene la media más baja entre los tres departamentos para esta población. Quindío la más alta. El mejor puntaje lo obtuvo Quindío y el peor Caldas. Risaralda está en el medio. Vemos algo también particular en estos datos y es un valor muy bajo en los puntajes de Caldas. Lo podríamos considerar un valor atípico.

Veamos otro ejemplo.



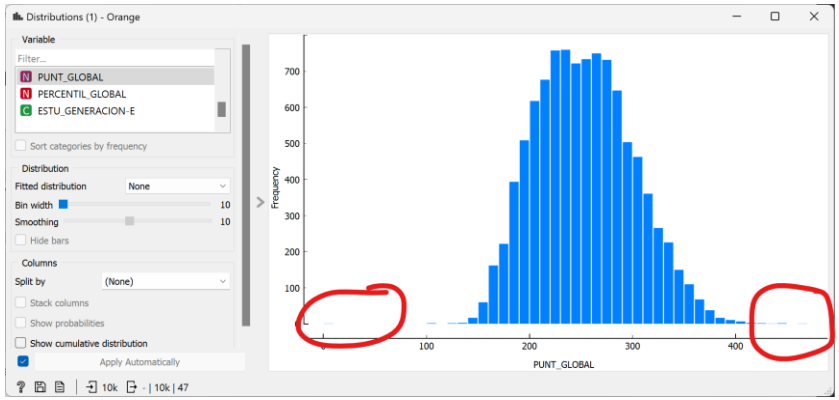
Aquí vemos que los estudiantes hombres obtuvieron mejores puntajes en matemáticas



Esta gráfica es un box plot para variables categóricas y aunque no vemos una distribución numérica de los datos, se pueden ver organizados y comparables. Podemos decir que Caldas tiene el mayor número de estudiantes de colegios masculinos entre los tres departamentos y que entre la muestra no hay estudiantes de colegios masculinos en Quindío.

Outliers y missing values

Recordemos que las distribuciones también nos dan información sobre la distribución de las variables en todos sus posibles valores y al igual que los **box-plots** nos permiten identificar valores atípicos.



Habiendo visto esto, ponemos un **Select Rows** para ver puntajes globales por debajo de 100 y analizamos. Creo que ese valor que aparece puede ser un error o un caso extremo.

Aquí una nota bien importante: ¿Qué hacer con ese valor?

Supongamos que lo queremos quitar. Hacemos un **Select Rows** y seleccionamos los que en **puntaje global** tienen por encima de 100 y listo. Ese dato quedó por fuera.

Pero si quisiéramos buscar valores atípicos de forma general y automática podemos usar el widget **Outliers**.

Este widget busca los **outliers** teniendo en cuenta TODAS las variables, no solamente la variable puntaje que es la que estamos mirando nosotros. De hecho, veamos ejemplos de los **outliers** que la herramienta detecta.

Este widget es **PESADO** y puede bloquear la máquina cuando se hace con muchos datos. Antes de mostrar este widget nos quedamos con menos **features** y con menos datos. Veamos distintas salidas y hablemos de lo bueno y lo malo de hacerlo con este widget.

Recordemos que la identificación de *outliers* se hace con varios fines. Expliquemos para qué la hacemos.

También tenemos valores faltantes. Miremos quiénes son y si son relevantes para el análisis. Al ver el **Data Table** vemos que los faltantes están relacionados con las variables socioeconómicas y no con los puntajes. Puedo eliminarlos o imputarlos.

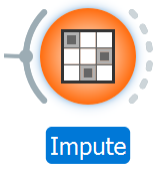
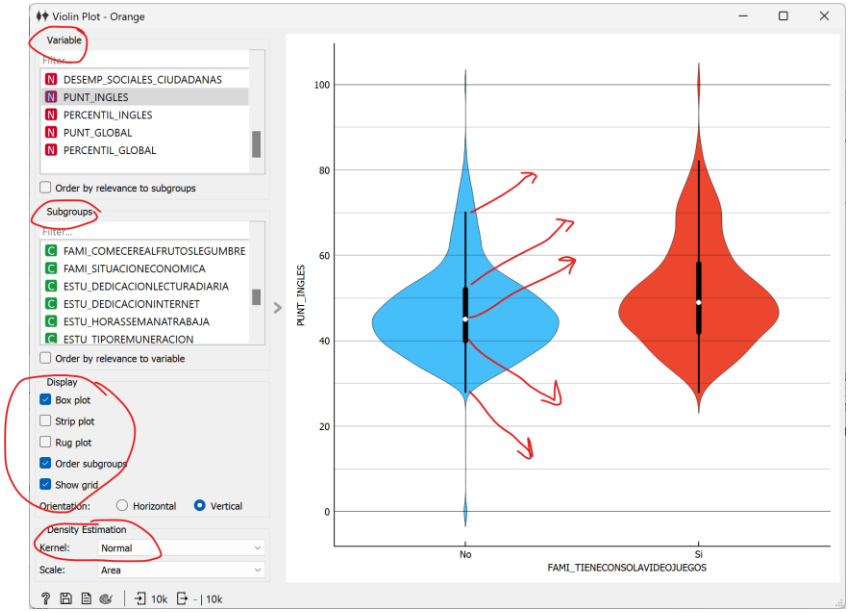


Gráfico Violin Plot

Orange tiene distintas formas de visualizar datos. Miremos por ejemplo el **Violin plot**. Es bastante parecido a un box-plot y a un histograma, pero integra toda esa información en un único plot.

Varias cosas importantes:

- Dependiendo del subgrupo que uno seleccione, muestra unas variables numéricas u otras. Muestra las que son relevantes de acuerdo con el subgrupo seleccionado.
- Si selecciono ***NONE*** en subgrupo, puedo verlas todas.



Y expliquemos qué estamos viendo.

Generación de reportes

¿Para qué me sirve todo este análisis exploratorio?

Para entender mejor mis datos. Y lo bueno de irlos entendiendo es que podemos ir describiendo cómo se van comportando las variables conforme vamos analizando relaciones entre ellas.

Lo bueno es que **Orange** me permite ir haciendo un reporte mientras voy trabajando.

Explicar la opción **Reporte** de cada *widget*. E ir llenando un reporte con varios ejemplos.

Generar un **html** y mostrárselo.

Veamos también qué pasaba con esos datos de fechas tan atípicos que vimos cercanos al 2020.

Formulación de pregunta

Algo que siempre hemos dicho es saber qué le preguntamos a los datos. ¿Qué preguntas podríamos hacerles a estos datos? (Ejemplos)

- ¿Los estudiantes que sacan puntajes **altos** comparten características socioeconómicas similares?
- ¿Los estudiantes que sacan puntajes **bajos** comparten características socioeconómicas similares?
- ¿Tener buenos hábitos de lectura es indicador de que me va a ir bien en el ICFES?
- ¿Estudiar en colegio privado es una variable que tiene correlación con sacar buenos puntajes?
- ¿Saber inglés me garantiza altos puntajes en otras áreas?
- ¿Las personas con mejores puntajes en competencias ciudadanas vienen de colegios públicos o privados?
- ¿Hay relación entre el estrato y los resultados en competencias ciudadanas?
- ¿La alimentación familiar podría tener que ver con los resultados de las pruebas?
- ¿Le va mejor a los colegios públicos de Caldas, de Quindío o de Risaralda?
- Todas las que se nos ocurran…

Para responder a estas preguntas podemos hacer análisis, visualizaciones o transformaciones en nuestros datos. Todo esto haría parte de lo que es **Análisis Exploratorio** o en algunos casos **Análisis Confirmatorio**.

Veamos esta pregunta

- ¿Estudiar en colegio privado es una variable que tiene correlación con sacar buenos puntajes?

¿Cómo la resolvemos?

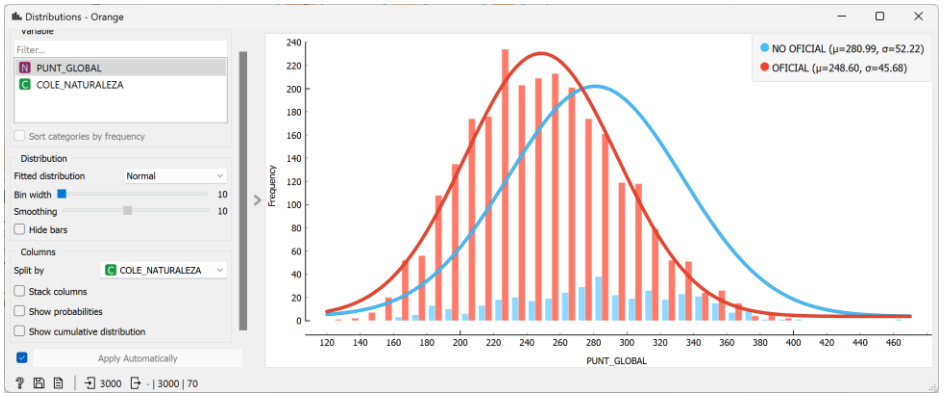
Estudiar en colegio privado es CATEGÓRICA

Puntaje es NUMÉRICA

Por tato no podemos calcular correlaciones entre estas dos variables.

Una solución sería codificar (**Continuize**) la variable CATEGÓRICA y calcular la correlación. Pero hacer esto estaría mal ya que la codificación no garantiza que el valor numérico de la variable tenga sentido, por tanto, la correlación no significará nada. Hagámoslo y veamos resultados.

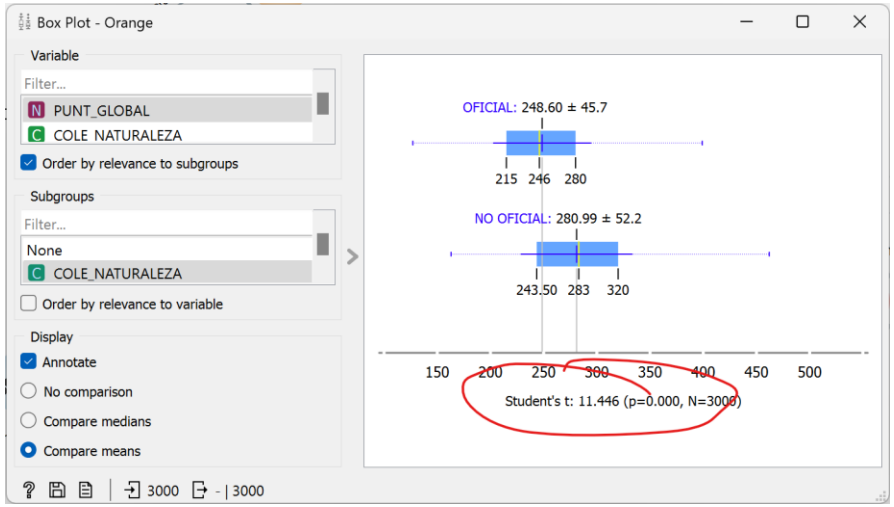
Pero lo que sí podemos hacer es analizar la distribución condicional y ver si podemos sacar conclusiones a partir de cómo se comportan las dos variables.



Esas diferencias entre las medias, ¿qué nos dicen?

¿Podemos decir CLARAMENTE que estudiar en colegio oficial está directamente relacionado con sacar puntajes altos? Solo haciendo un análisis de la significancia estadística podremos confirmarlo.

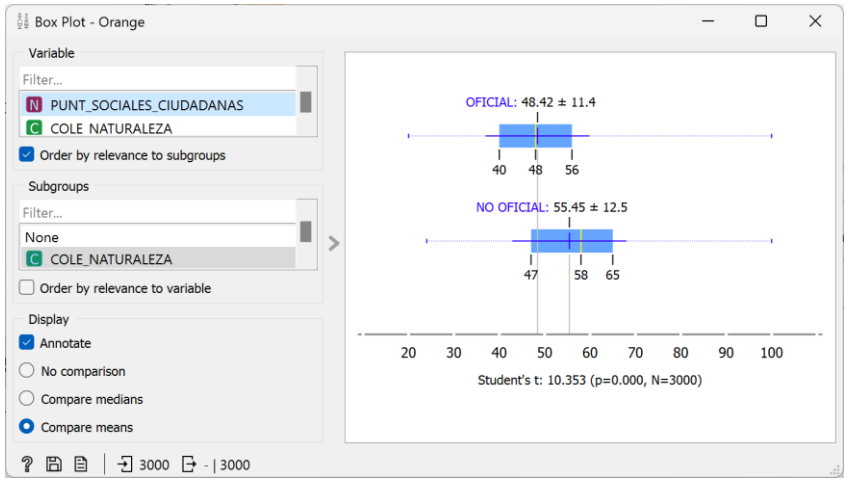
El widget **box-plot** permite calcular parámetros de test de significancia estadística sobre variables.



A la pregunta

- ¿Las personas con mejores puntajes en competencias ciudadanas vienen de colegios públicos o privados?

Veamos esto:



Más adelante veremos cómo interpretar los resultados de significancia estadística en los datos.

Selección de variables

Supongamos que queremos preguntarnos cuáles son las variables más relevantes para diferenciar entre estudiantes con puntajes altos, medios y bajos.

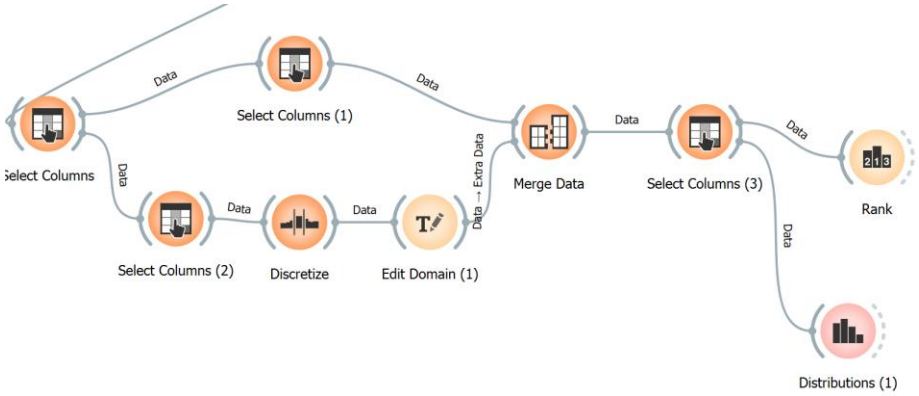
Recordemos que la selección de variables depende de que tengamos una variable **Target**. Podemos volver la variable puntaje global nuestra variable **Target**.

Lo primero que hay que pensar es qué entendemos por Altos, Medios y Bajos.

La variable Puntaje es Numérica, y si queremos representar los puntajes por ALTOS, MEDIOS y BAJOS, eso significa que debo convertirla a tipo categórica o, mejor dicho, que debemos discretizarla. Entonces vamos a hacerlo con el widget **Discretize**.

En este momento tengo todas las variables. Me interesa discretizar la variable **Puntaje_global** y luego, una vez convertida a categórica, remplazarla por la variable **Puntaje_global** numérica que tenemos en nuestros datos.

Para eso partimos los datos por dos caminos. Todas las variables menos **PUNTAJE_ GLOBAL** por un camino (en este caso, por el camino superior) y **PUNTAJE_GLOBAL** por otro (el camino inferior).



Veamos distintas opciones para discretizarla y comparemos lo bueno y malo de cada una. También podemos hacerlo de forma manual.

Una vez hecha la discretización, volvemos a unir todas las variables (**Merge Data**), seleccionamos nuestra nueva variable categórica como variable **Target** y la pasamos al **Rank**. Analicemos los resultados del **Rank**.

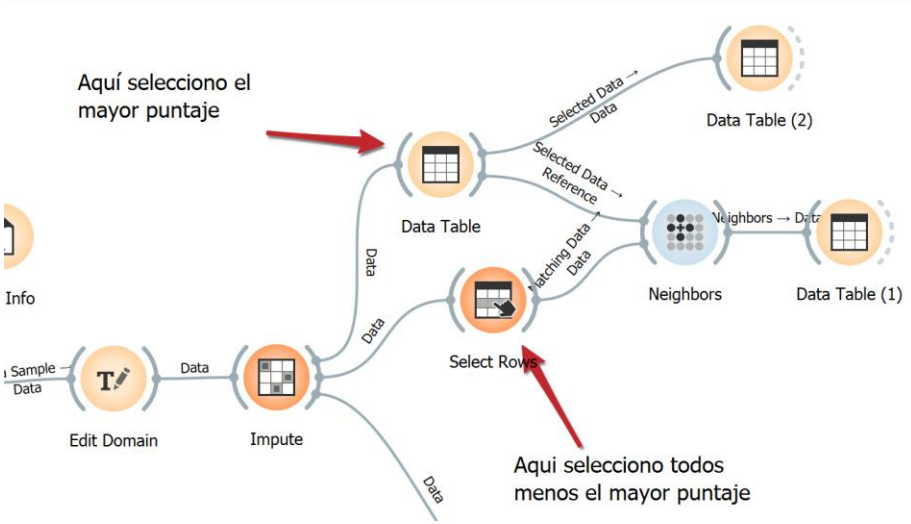
Discutamos un rato sobre esto.

Distancias y vecinos

Pensemos que queremos analizar cuáles son los factores socioeconómicos que caracterizan al estudiante (o a los estudiantes) con el (los) puntaje(s) más alto(s) en las pruebas. A partir de esa información queremos calcular sus vecinos y qué parámetros tienen en común. Quizás haya condicionantes sociales y económicos que determinen la obtención de un puntaje alto. Para esto:

- Se selecciona el mayor puntaje
- Se seleccionan todos los datos menos el mayor puntaje
- Se lleva a un widget de **Neighbors**

Probemos distintas distancias y veamos los resultados. Podemos pensar que, si queremos analizar variables categóricas, la distancia más coherente es la distancia Jaccard.



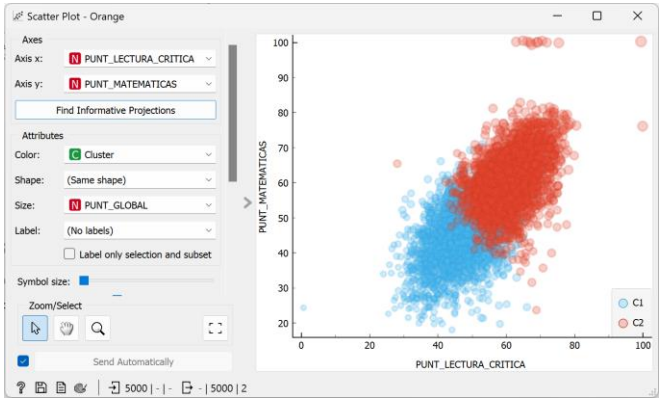
Analicemos los vecinos que el sistema encuentra y veamos qué cosas tienen en común con los datos de referencia. ¿Podemos concluir al respecto?

Agrupamiento

Hagamos un agrupamiento no supervisado de los datos y veamos qué podemos encontrar.

Probemos varias cosas:

- Seleccionemos solo las variables numéricas y hagamos un agrupamiento. Quedémonos con el mejor agrupamiento (según coeficiente **Silhouette**) y miremos qué nos da.



Este resultado era esperable y obvio ya que usamos las variables numéricas de los puntajes de cada área de las pruebas Saber. Si basados en estos datos, le pedimos dos grupos, nos dará los puntajes altos y los bajos.

- Probemos ahora otra cosa. En este otro intento usemos solo las variables categóricas. **k-means** es un algoritmo definido únicamente para variables numéricas, sin embargo, **Orange** es capaz de procesar variables categóricas. **Orange** realiza un preprocesamiento de los datos definido así (ver ayuda del **widget**)

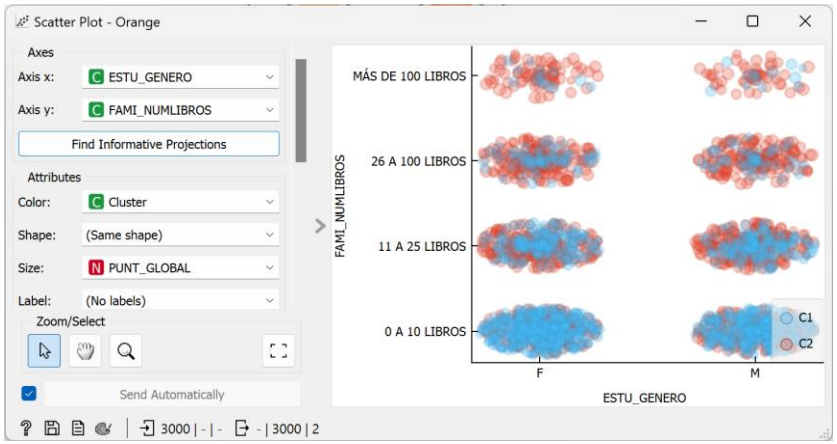
Preprocessing

k-Means uses default preprocessing if necessary. It executes it in the following order:

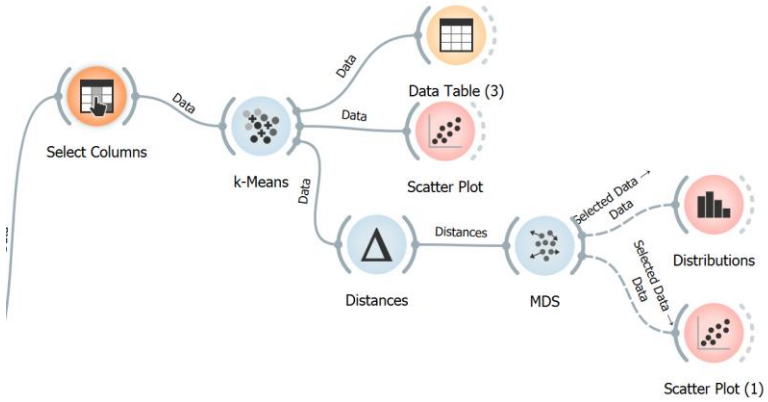
- continuizes categorical variables (with one feature per value)
- imputes missing values with mean values

To override default preprocessing, preprocess the data beforehand with Preprocess widget.

Los resultados de esto son muy difíciles de interpretar en el espacio bidimensional de dos variables categóricas. Por ejemplo, la siguiente gráfica, ¿qué me dice?

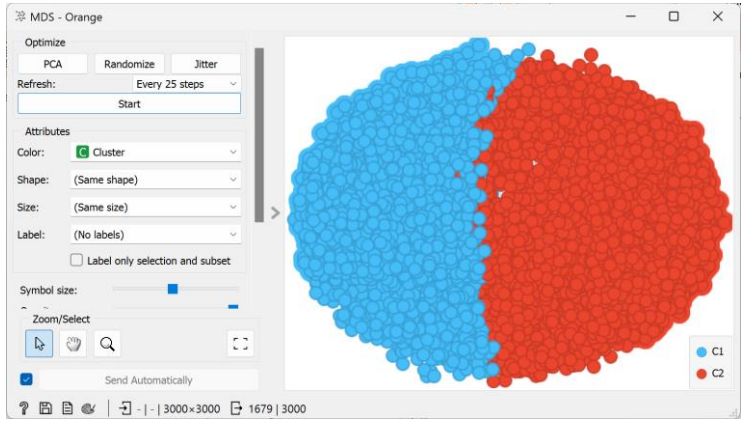


En ese orden de ideas hagamos una proyección de esas variables a dos dimensiones (widget **MDS**) e intentemos interpretar de otra forma los resultados.

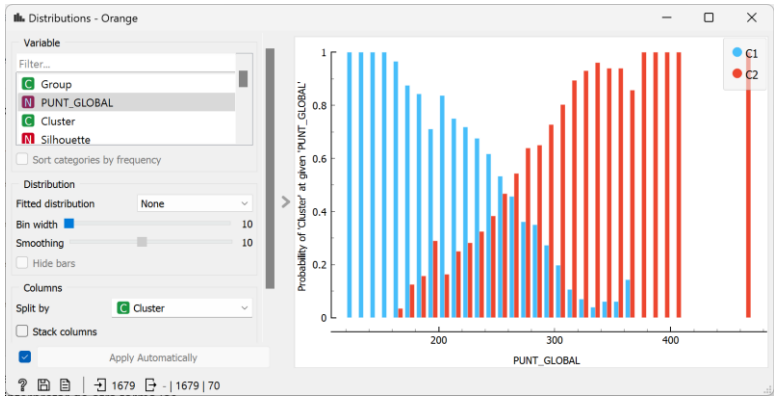


Podemos ver cosas como estas:

Haciendo un **MDS** y visualizando clústeres.



Y si revisamos la distribución de esos datos en función del puntaje global vemos:



Lo que indica que el algoritmo agrupo en dos clústeres y que esos clústeres parecen tener una estrecha relación con los puntajes. Esto indicaría que efectivamente las variables socioeconómicas (en este caso son categóricas) juegan un papel importante en la posible predicción o estimación de los resultados de las pruebas SABER 11.