Universidad Nacional de Colombia — Sede Manizales
Facultad de Ingeniería y Arquitectura
Departamento de Ingeniería Eléctrica, Electrónica y Computación

Taller Guiado en Orange

Cierre de capítulos: un repaso de extremo a extremo

Curso: Analítica de Datos (Aprendizaje de máquina) — Código 4200729

Docente: Diego Fabián Collazos Huertas

Modalidad: guiado en clase, individual o en parejas

Dataset: `ICFES_2020-2_Eje_Cafetero.csv`

Este taller se desarrolla **en el horario de clase**, guiado en vivo por el docente. El archivo `.ows` resultante, con las respuestas a las preguntas de concepto escritas sobre el lienzo, se entrega según se indique en clase.

1 Objetivos

- Repasar, de extremo a extremo y sobre un **único problema real**, (casi) todas las técnicas de análisis exploratorio, selección de variables y agrupamiento vistas en el curso, usando **Orange Data Mining**.
- Practicar la formulación de preguntas sobre un conjunto de datos y la elección de la técnica adecuada para responderlas.
- Hacer un **sanity check** de los datos antes de sacar conclusiones, identificando valores extraños, atípicos y faltantes.
- Distinguir cuándo una diferencia observada es **estadísticamente significativa** y cuándo una correlación no implica causalidad.

Nota

Este enfoque **no es el único posible**: dependiendo de los datos y de las preguntas que queramos hacerles, las técnicas, los análisis y las conclusiones pueden cambiar. Lo importante de este taller es la **forma de pensar** el problema, no memorizar una receta fija.

2 Datos de origen

Trabajaremos con un extracto de la base de datos de las **Pruebas Saber 11, segundo semestre de 2020** (origen: Saber 11° 2020-2 — Datos Abiertos Colombia). Se le hizo un depurado previo:

- Se seleccionaron solo registros del **Eje Cafetero** (Risaralda, Caldas, Quindío).
- Se eliminaron variables irrelevantes (códigos SNIES de colegios y variables similares).
- Se hizo un submuestreo al 40 % para simplificar el procesamiento.

El archivo resultante, `ICFES_2020-2_Eje_Cafetero.csv`, queda con **24999 registros** y **61 variables** (40 categóricas, 20 numéricas, 1 metadato de texto): puntajes y percentiles por competencia (lectura crítica, matemáticas, ciencias naturales, sociales y ciudadanas, inglés, y el puntaje global), variables socioeconómicas y del entorno familiar del estudiante, y variables del colegio.

3 Parte 1 — Carga y lectura general de los datos

1. Abre Orange y crea un workflow nuevo. Arrastra el widget **File** y carga `ICFES_2020-2_Eje_Cafetero.csv`. Confirma en el panel del widget que quedan **24999 filas, 40 categóricas, 20 numéricas, 1 meta**.
2. Agrega el widget **Feature Statistics** (categoría *Data*) conectado a *File* y revisa, variable por variable, la media, moda, mediana, dispersión, mínimo y máximo.
3. Fíjate en las tres primeras variables de código (`ESTU_COD_RESIDE_DEPTO`, `ESTU_MCPIO_RESIDE`, `ESTU_COD_RESIDE_MCPIO`): aunque Orange las detecta como **Numéricas** por estar hechas de dígitos, no tiene sentido promediarlas — son códigos, no cantidades. Agrega un widget **Edit Domain** conectado a *File* y cambia su tipo a **Categórica**.

de los datos) y empecemos a ver cosas.

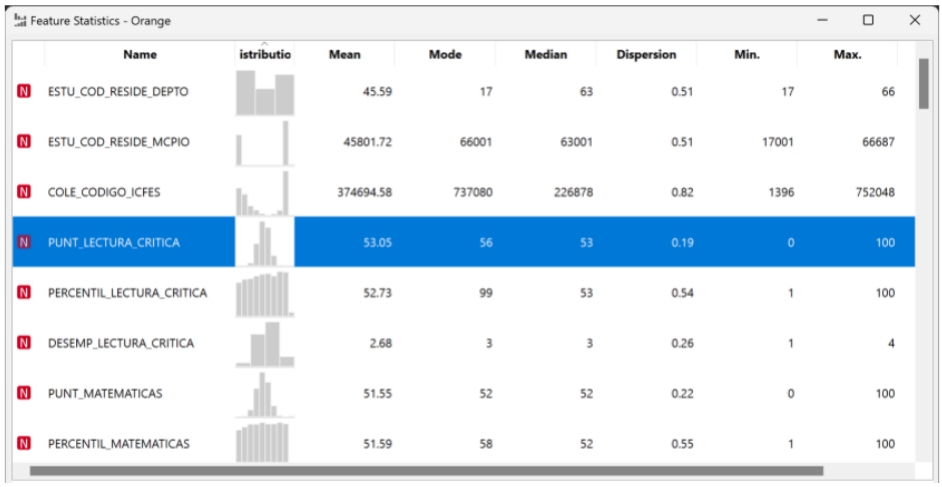


Figura 1: *Feature Statistics*: las tres primeras filas (`ESTU_COD_RESIDE_DEPTO`, `ESTU_COD_RESIDE_MCPIO`, `COLE_CODIGO_ICFES`) aparecen como **N** (Numérica) aunque son códigos.

● Pregunta de concepto

¿Por qué un código numérico como `ESTU_COD_RESIDE_MCPIO` no debería tratarse como variable numérica, aunque esté compuesto solo por dígitos? Den un ejemplo concreto de una conclusión sin sentido que se obtendría si se calculara su **media** o se le aplicara una **correlación**.

4 Parte 2 — Sanity check: ¿los datos son lo que deberían ser?

Antes de analizar, conviene verificar que no haya datos mal tomados o en un formato incorrecto — a esto se le llama **sanity check**.

1. En *Feature Statistics*, observa la variable `ESTU_FECHANACIMIENTO`: su **dispersión** es de aproximadamente 74 años, con un mínimo en 1946 y un máximo en 2020.

2. Agrega el widget **Select Rows** conectado a *File* con la condición `ESTU_FECHANACIMIENTO is at most 1970-01-01`. Conecta la salida a un **Data Table** e inspecciona esos registros.

3. Conecta ahora un widget **Distributions** a la salida de *Select Rows* y mira la variable `ESTU_MCPIO_RESIDE`. Notarás un eje X muy ruidoso, con muchas categorías sin barra: Orange sigue mostrando **todos** los municipios posibles del dataset completo, aunque esta selección casi no tenga datos en la mayoría. En el panel de *Select Rows*, activa **Remove unused features** y observa cómo se limpia la visualización.

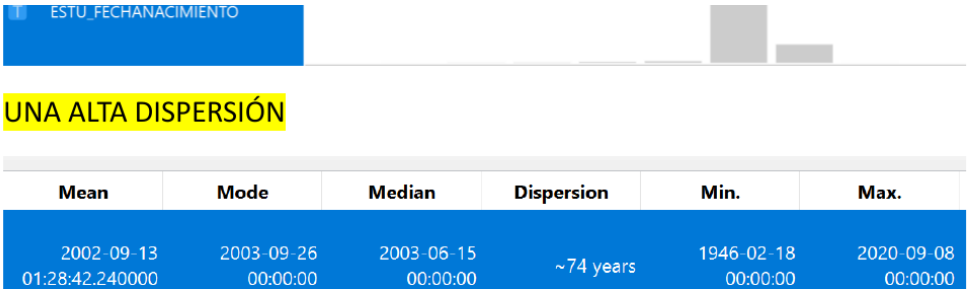


Figura 2: *Feature Statistics* de `ESTU_FECHANACIMIENTO`: dispersión ≈ 74 años, mínimo 1946-02-18 y máximo 2020-09-08.

Pregunta de concepto

¿Por qué es importante hacer un sanity check **antes** de interpretar los resultados de un análisis exploratorio? En este dataset hay personas que, según la fecha de nacimiento, tenían 74 años al presentar la prueba, y otras que nacieron el mismo año en que la presentaron (2020). ¿Cuál de las dos situaciones les parece más plausible como dato real y cuál como posible error de captura? Justifiquen.

5 Parte 3 — Visualización de variables categóricas

5.1 3.1 Distributions

1. Conecta un widget **Distributions** a *File* (sin el filtro de la Parte 2) y selecciona `ESTU_GENERO`.
2. Usa **Split by** para condicionar la distribución de `FAMI_ESTRATOVIVIENDA` según `ESTU_GENERO`, y explora las opciones *Sort categories by frequency*, *Stack columns* y *Show probabilities*.

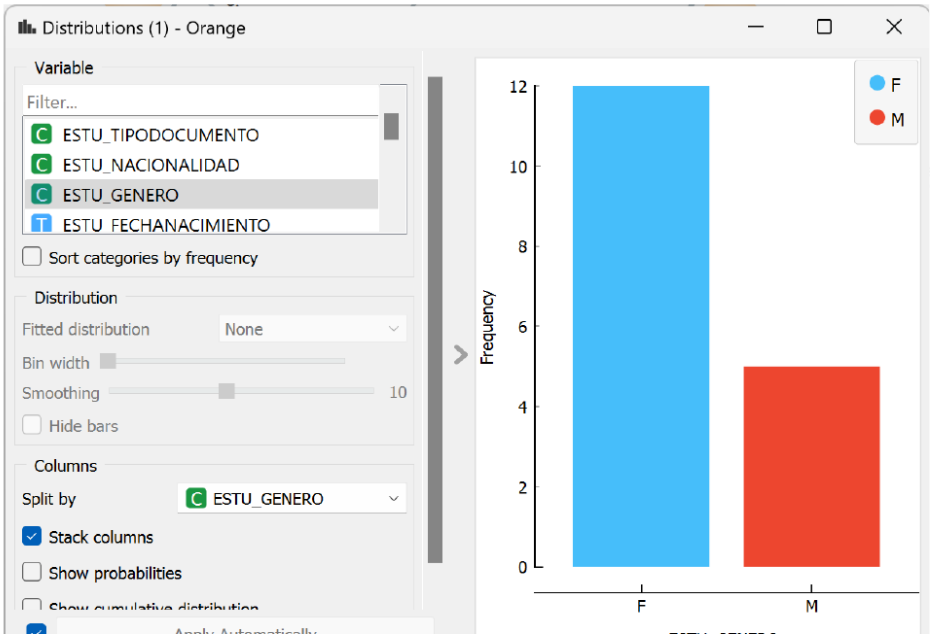


Figura 3: *Distributions* de `ESTU_GENERO` sobre la selección de nacidos antes de 1970 (distribución marginal).

● Pregunta de concepto

¿Qué diferencia hay entre una distribución **marginal** (una sola variable, como el histograma de `ESTU_GENERO`) y una distribución **condicional** (*split by*, como `FAMI_ESTRATOVIVIENDA` dividida por género)? ¿Qué pregunta puede responder la segunda que la primera no puede?

5.2 3.2 Mosaic

1. *Distributions* queda limitado a dos variables (una principal y un *split by*). Agrega el widget **Mosaic** conectado a *File* para visualizar más variables a la vez (hasta 5): selecciona `ESTU_GENERO` y `ESTU_MCPIO_RESIDE`, con color interior `ESTU_GENERO`.

2. Activa **Compare with total** y observa cómo cambia la lectura del gráfico.

3. Agrega una tercera variable (por ejemplo `ESTU_FECHANACIMIENTO` discretizada, o cualquier otra categórica) y luego hasta una cuarta o quinta. Prueba el botón **Find Informative Mosaics — con pocas variables y datos reducidos**, ya que puede tardar mucho con el dataset completo.

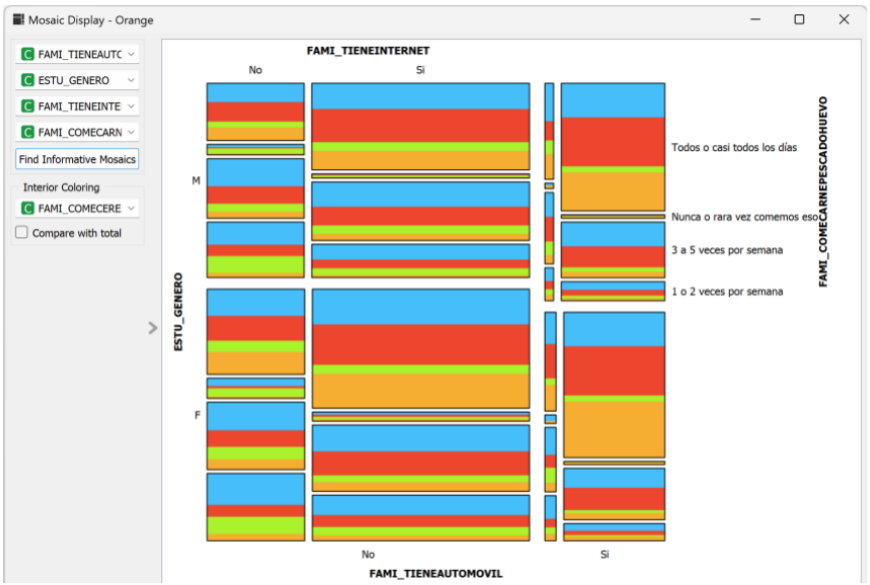


Figura 4: *Mosaic* con 4 variables: `FAMI_TIENEINTERNET`, `FAMI_TIENEAUTOMOVIL`, `ESTU_GENERO` y `FAMI_COMECARNEPESCADOHUEVO`.

● Pregunta de concepto

Mosaic permite visualizar hasta 5 variables categóricas a la vez, mientras que *Distributions* solo permite 2. ¿Qué ventaja ofrece poder ver más variables al tiempo? ¿Qué desventaja, en términos de qué tan fácil es **interpretar** el gráfico, aparece a medida que agregan más variables?

6 Parte 4 — Variables numéricas: atípicos y faltantes

6.1 4.1 Box Plot

1. Agrega un widget **Select Rows** conectado a *File* para quedarte solo con estudiantes nacidos entre 2000 y 2004.

2. Conecta un **Box Plot** a esa salida: variable `PUNT_GLOBAL`, **Subgroups** = `ESTU_COD_RESIDE_DEPTO`, con **Compare means** activado. Observa el valor de **ANOVA** que reporta el widget.

3. Prueba también un *Box Plot* con una variable **categórica** como variable principal (por ejemplo `COLE_GENERO`) agrupada por otra categórica (`ESTU_COD_RESIDE_DEPTO`): el widget reporta entonces un estadístico χ^2 en vez de ANOVA.

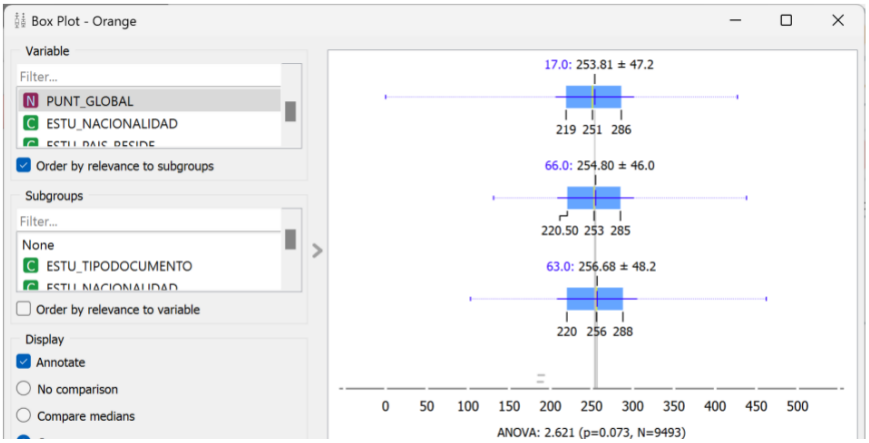


Figura 5: *Box Plot* de `PUNT_GLOBAL` por `ESTU_COD_RESIDE_DEPTO`: ANOVA = 2.621 (p = 0.073, N = 9493).

● Pregunta de concepto

El *Box Plot* de `PUNT_GLOBAL` por departamento reporta un ANOVA con cierto valor p. Si ese valor p es mayor a 0.05, ¿pueden concluir que hay una diferencia **estadísticamente significativa** entre los departamentos al 95 % de confianza? ¿Qué significa, en términos simples, el valor p de una prueba de significancia?

6.2 4.2 Outliers y valores faltantes

1. Conecta un **Distributions** a *File* con la variable `PUNT_GLOBAL`. Observa las colas de la distribución: hay valores muy por debajo de 100 que no deberían ser posibles en una escala que llega a 500.

2. Agrega un **Select Rows** con la condición `PUNT_GLOBAL is at most 100` y revisa esos registros en un *Data Table*. Decide si te parecen datos reales o errores de captura.

3. Agrega el widget **Outliers** (categoría *Unsupervised*) conectado a *File* para detectar valores atípicos considerando **todas** las variables numéricas a la vez, no solo una.

4. Con un **Data Table** conectado a *File*, identifica qué variables tienen valores faltantes — notarás que están relacionadas con el entorno socioeconómico, no con los puntajes. Agrega un widget **Impute** para tratarlos.

box-plots nos permiten identificar valores atípicos.

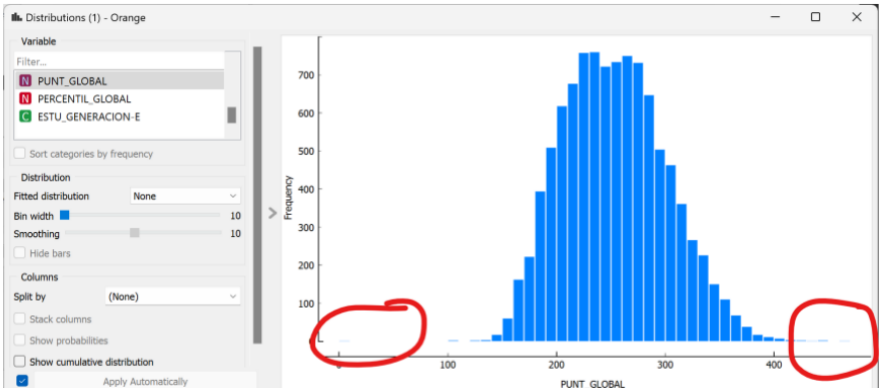


Figura 6: *Distributions* de `PUNT_GLOBAL`: colas con valores extremos (resaltadas en rojo) por debajo de 100 y por encima de 400.

Nota

El widget *Outliers* es **pesado**: puede ser lento o bloquear Orange si se usa con muchos datos y muchas variables. Redúcelo primero (*Select Columns* y/o una muestra con *Data Sampler*) antes de usarlo sobre el dataset completo.

● Pregunta de concepto

¿Cuál es la diferencia entre un **valor atípico legítimo** (una observación real, pero poco común) y un **error de captura de datos**? En el caso de los puntajes globales por debajo de 100, ¿qué evidencia usarían para decidir a cuál de los dos casos corresponde, en vez de simplemente eliminarlos sin revisar?

Nota

Como complemento opcional, el widget **Violin Plot** (categoría *Visualize*) combina en un solo gráfico lo que muestran por separado el *Box Plot* y un histograma: la silueta es la distribución completa, y dentro se puede superponer la caja del *Box Plot*. Pruébalo con alguna variable de puntaje, agrupada por una variable categórica de interés.

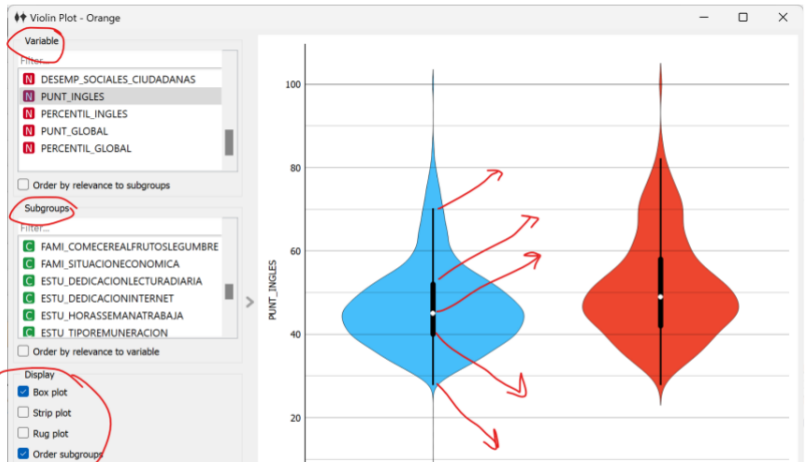


Figura 7: *Violin Plot* de `PUNT_INGLES`, agrupado por `FAMI_TIENECONSOLAVIDEOJUEGOS`.

7 Parte 5 — Formulación de preguntas y significancia estadística

Una vez hecha la lectura general de los datos, el análisis exploratorio se vuelve más potente cuando parte de **preguntas concretas**. Algunos ejemplos:

- ¿Los estudiantes que sacan puntajes altos comparten características socioeconómicas similares?
- ¿Tener buenos hábitos de lectura es indicador de que me va a ir bien en el ICFES?
- ¿Estudiar en colegio privado es una variable que tiene correlación con sacar buenos puntajes?
- ¿Las personas con mejores puntajes en competencias ciudadanas vienen de colegios públicos o privados?
- ¿Hay relación entre el estrato y los resultados en competencias ciudadanas?
- ¿La alimentación familiar podría tener que ver con los resultados de las pruebas?

Tomemos la pregunta **¿Estudiar en colegio privado tiene relación con sacar buenos puntajes?** `COLE_NATURALEZA` es **categórica** y `PUNT_GLOBAL` es **numérica**, así que **no podemos calcular directamente un coeficiente de correlación** entre ellas.

1. Conecta un **Distributions** a *File*: variable `PUNT_GLOBAL`, **Split by** = `COLE_NATURALEZA`. Observa cómo se desplazan las dos distribuciones condicionales una respecto a la otra.
2. Conecta un **Box Plot**: variable `PUNT_GLOBAL`, **Subgroups** = `COLE_NATURALEZA`, con **Compare means**. Esta vez el widget sí reporta una prueba de significancia (t de Student) entre las dos medias.
3. Repite el mismo *Box Plot* para la pregunta sobre competencias ciudadanas (`PUNT_SOCIALES_CIUDADANAS` por `COLE_NATURALEZA`).

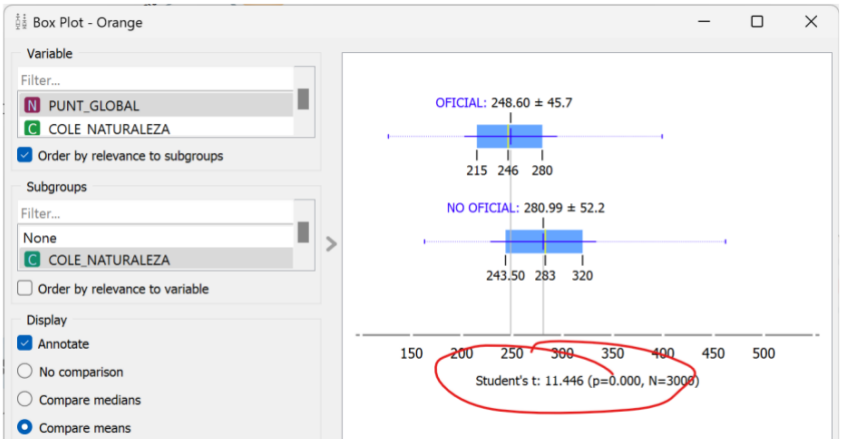


Figura 8: *Box Plot* de `PUNT_GLOBAL` por `COLE_NATURALEZA`: Student's t = 11.446 (p = 0.000, N = 3000).

● Pregunta de concepto

Podríamos codificar (*Continuize*) la variable categórica `COLE_NATURALEZA` como 0/1 y calcular su correlación de Pearson con `PUNT_GLOBAL`. ¿Por qué el número resultante no significaría realmente lo que esperamos? Y aunque el *Box Plot* muestre una diferencia de medias **estadísticamente significativa** entre colegios oficiales y no oficiales, ¿pueden concluir que estudiar en colegio privado **causa** mejores puntajes? ¿Qué otras explicaciones alternativas se les ocurren?

8 Parte 6 — Selección de variables y vecinos

8.1 6.1 Selección de variables con Rank

Queremos identificar qué variables socioeconómicas distinguen mejor entre puntajes **altos**, **medios** y **bajos**. Para eso necesitamos una variable **Target** categórica.

1. Agrega el widget **Discretize** conectado a *File*, y discretiza `PUNT_GLOBAL` en tres categorías (por ejemplo, *Equal frequency* con 3 intervalos: altos/medios/bajos).
2. Con **Select Columns**, separa por un lado todas las variables **menos** `PUNT_GLOBAL`, y por otro solo `PUNT_GLOBAL` discretizada. Une ambas de nuevo con **Merge Data**.
3. En el widget resultante (o con **Edit Domain**), marca la versión discretizada de `PUNT_GLOBAL` como **Target**.
4. Conecta un widget **Rank** y revisa qué variables socioeconómicas quedan mejor rankeadas para distinguir altos/medios/bajos.

variable **Puntaje_global** numérica que tenemos en nuestros datos.

Para eso partimos los datos por dos caminos. Todas las variables menos **PUNTAJE_ GLOBAL** por un camino (en este caso, por el camino superior) y **PUNTAJE_GLOBAL** por otro (el camino inferior).

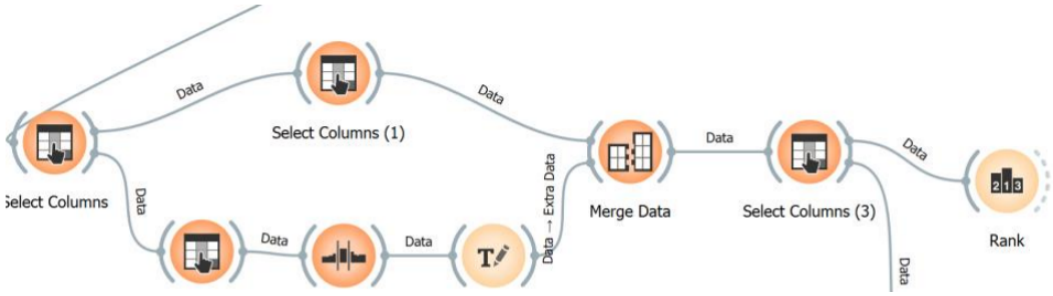


Figura 9: Workflow: `PUNT_GLOBAL` se discretiza por un camino, el resto de variables sigue por otro, y se unen de nuevo con *Merge Data* antes de llegar a *Rank*.

● Pregunta de concepto

¿Por qué fue necesario discretizar `PUNT_GLOBAL` (convertirla de numérica a categórica) antes de poder usarla como variable **Target** para el widget *Rank*? ¿Qué le pasaría a Rank si le diéramos directamente la variable numérica como *Target*?

8.2 6.2 Distancias y vecinos

1. Con un **Select Rows**, separa el registro (o los registros) con el **mayor** `PUNT_GLOBAL` de todo el dataset.

2. Conecta un widget **Neighbors**: como *Data* usa el resto del dataset, y como *Reference* el registro de mayor puntaje. Elige la métrica **Jaccard** (apropiada para variables categóricas binarias) y revisa qué estudiantes resultan más "cercanos".

3. Mira qué características socioeconómicas comparten esos vecinos con el estudiante de referencia.

distancia Jaccard.

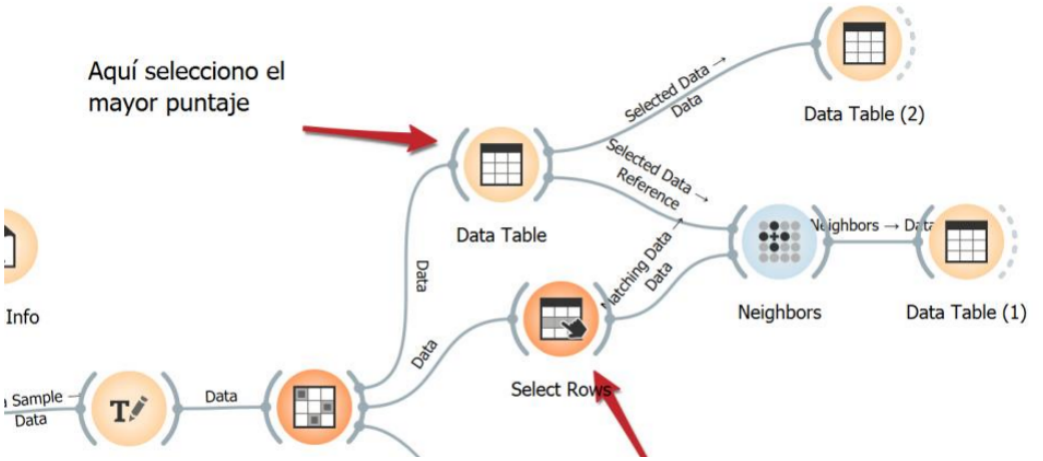


Figura 10: Workflow: se separa el registro de mayor puntaje (*Data Table*) del resto (*Select Rows*), y ambos alimentan el widget *Neighbors*.

● Pregunta de concepto

¿Por qué la distancia **Jaccard** es más apropiada que la distancia **Euclídea** para comparar variables categóricas binarias (como las de Sí/No: ¿tiene internet?, ¿tiene computador?, etc.)? (Pista: piensen en qué significaría restar numéricamente dos categorías como "Sí" y "No".)

9 Parte 7 — Agrupamiento no supervisado

1. **Con variables numéricas**: agrega **Select Columns** para quedarte solo con las variables numéricas de puntaje, luego **k-Means** (prueba varios K y quédate con el mejor según el coeficiente **Silhouette**). Visualiza el resultado en un **Scatter Plot** coloreado por `Cluster`.

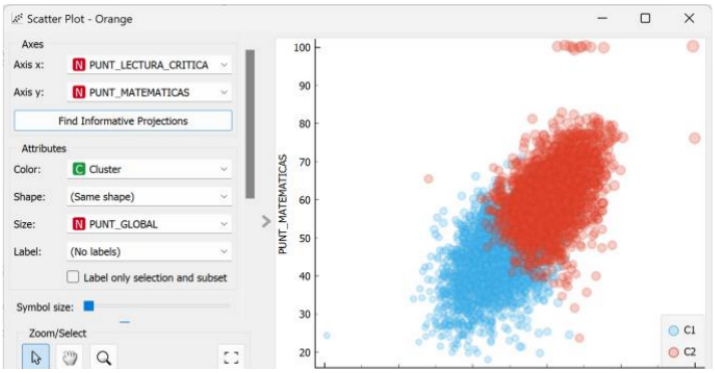


Figura 11: *k-Means* sobre variables numéricas de puntaje: separa, de forma esperable, puntajes altos (rojo) de bajos (azul).

2. **Con variables categóricas**: repite el ejercicio usando solo variables socioeconómicas (categóricas). Recuerda que *k-Means* en Orange preprocesa automáticamente las categóricas (*continuize* con una columna por valor) si no le conectas ya datos preprocesados.

3. Un *Scatter Plot* directo sobre dos variables categóricas es difícil de interpretar. Agrega un widget **MDS** (conectado a través de **Distances**) para proyectar esas variables a 2 dimensiones y visualizar los clústeres encontrados.

4. Conecta un **Distributions** a la salida del agrupamiento categórico: variable `PUNT_GLOBAL`, **Split by** = `Cluster`. Observa si los dos clústeres (formados **solo** con variables socioeconómicas, sin usar el puntaje) se relacionan con el puntaje global.

Haciendo un **MDS** y visualizando clústeres.

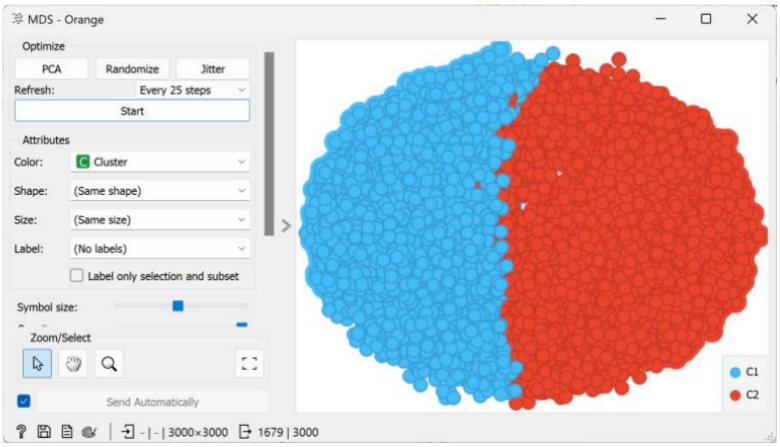


Figura 12: Proyección *MDS* del agrupamiento *k-Means* sobre variables categóricas socioeconómicas: los dos clústeres quedan claramente separados en 2D.

● Pregunta de concepto final

Al agrupar usando **solo** las variables numéricas de puntaje, era esperable que *k-Means* separara "puntajes altos" de "puntajes bajos" — esas son justo las variables que usamos para agrupar. Pero al agrupar usando **solo** variables socioeconómicas (categóricas, sin usar el puntaje) y luego comparar esos clústeres con `PUNT_GLOBAL`, ¿qué encontraron? ¿Qué les sugiere esto sobre la relación entre el contexto socioeconómico y el desempeño en las pruebas Saber 11? Y de nuevo: ¿esto es evidencia de que el contexto socioeconómico **causa** el desempeño, o solo de que están **correlacionados**?

10 Entregables

1. El archivo `.ows` del workflow completo armado durante la sesión, con las respuestas a las **8 preguntas de concepto** (●) escritas directamente sobre el lienzo, usando la herramienta de texto de Orange (clic derecho sobre un espacio vacío → *Text*), junto a la parte correspondiente del workflow.

2. Sube el archivo `.ows` desde la página de entregas del curso, seleccionando la categoría **Otra** y especificando "Taller guiado — Cierre de capítulos" — o según indique el docente en clase.

Nota

Este es un taller **guiado en clase**: no hay un procedimiento único ni una única forma correcta de armar el workflow. Lo importante es que el flujo refleje las decisiones que se discutieron en cada parte y que las respuestas a las preguntas de concepto estén justificadas con lo que efectivamente se observó en Orange.